

論文のハリボテドラフト v3.0

縦向き・本文微調整・数式整正版

Note: 添付テキストの構成を保ち、見出し・表・数式ブロックをA4縦向きで読みやすく整形したものです。

論文のハリボテドラフトv3.0

1. Introduction

- RL実験では、複数候補から良い設定を選ぶ必要がある。
- しかし全候補を高予算で評価するのは難しい。
- そのため、低予算評価で候補を絞り込んでいく必要がある。
- しかし、低予算評価は環境構造によって歪みが生まれ、信頼性が変わる可能性がある。
- 本研究は、低予算winner selection failureを環境因子ごとに診断する。
- 本研究は環境因子によるアルゴリズムの性能低下を見るのではなく、選抜の歪みに着目する。
- 本研究の貢献は以下の3つである。
 - 低予算RL候補選抜を、winner selection problemとして定式化する。
 - stochastic transition、terminal hazards、key-door structureが誤選抜を増幅する機序を制御環境で検証する。
 - tabular Q-learningを用いることで、Deep RL特有の関数近似、実装交絡を避け、環境因子と選抜失敗の関係を解釈可能にする。

2. Related Work

- RL評価は不安定である。
 - RL実験では、seed、環境の確率性、実装、評価手順によって結果が揺れやすい(Henderson et al.)。特にDeep RLでは、少数runの点推定だけに基づく比較が不安定な結果を生み出すことが繰り返し指摘されている(Agawal et al.)。
- RLの性能は複合的な要因で決まる。
 - RLの性能差は、アルゴリズムだけでなく、実装上の設計やハイパラ、環境因子といったものに強く左右される。例えば、Andrychowicz et al.は、オンポリシーRLの実装には多数の設計選択があり、それらが性能に強く影響することを大規模実験で扱っている。また、Eimer et al.はRLのハイパラ選択が最終性能やsample efficiencyに大きく影響し、tuning seedへの過適合も問題になると論じている。Adkins et al.も、RL性能がハイパラに強く依存し、環境ごとに異なる設定が必要になる問題も扱っている。
 - Patterson et al.のCHSをどこに置くか？
- winner selectionは、ノイズのある選抜問題である。
 - winner selectionとは、複数の候補を実験・評価して、観測されたスコアが一番高いものを「勝者」として選ぶ操作のことである。
 - (winner selectionの数式)
 - RL実験では、アルゴリズム、ハイパラ設定、実装選択、あるいは学習済み方策を、限られた評価結果に基づいて選択する場面が多い。本研究では、このような「観測性能に基づく最良候補の選択」をwinner selectionと呼ぶ。
 - 例えば、Jamieson & Talwalkarは、ハイパラ最適化をnon-stochastic best-arm identificationとして定式化し、限られたリソースで最良候補を同定する問題を扱っている。
 - しかし、複数候補を有限予算で評価し、観測された評価値が最も高い候補を選ぶ場合、評価値の分散やノイズによって、本来最良ではない候補が選ばれる可能性がある。Cawley & Tablotは、モデル選択基準そのものに分散があると、モデル選択過程でover fittingやselection biasが生じ、その影響がアルゴリズム間の性能差と同程度になりうると論じている。
 - 本研究では、複数のQ-learning probe configurationsをcandidate configurationsとみなし、低予算評価に基づいてwinnerを選ぶ。主眼は効率的な探索手法の提案ではなく、環境因子が低予算 winner selectionの失敗率に与える影響を診断する点にある。
 - この時、観測評価値とreference performanceのズレにより、strict misselection、partial misselection、selection regret、late-bloomer eliminationが発生しうる。
- controlled environments
 - MiniGridは、環境でカスタマイズ可能なgoal-oriented環境群として設計されており、研究目的に応じた環境開発に向いている。
 - bsuiteは、RL agentの中核的能力や失敗要因を調べるための、慎重に設計された小規模実験群として提案されている。この研究はbsuiteと同じく診断的なものだが、対象はagent capabilityそのものではなく、low-budget winner selection failureである。
 - 本研究では、現実的な大規模環境ではなく、環境因子を明示的に操作できる小規模環境を用いる。これは、汎用性能を競うためではなく、評価失敗の発生機序を診断するためである。

3. Problem Formulation

- Low-budget winner selection
 - 今回、複数のQ-learning probe configurationsをcandidate configurationsとみなし、低予算評価に基づいてwinnerを選ぶ。
 - candidate configurationsのそれぞれについて、High-budget reference and low-budget winnerを作成し、low-budgetの場合に、high-budget referenceとwinner selectionがずれるかどうか、ズれる場合はどのようにずれていて、環境因子とどのような関係にあるのかを考察する。
- High-budget reference and low-budget winner
 - High-budget reference
 - こちらは、seed:100、episode:30000とする。
 - low-budget
 - こちらは、3通り作成する。
 - 低予算 1 : seed:100、ep:3000
 - 低予算 2 : seed:5、ep:30000
 - 低予算 3 : seed:5、ep:3000
- Selection failure metrics
 - tie aware winner misselection rate
 - 低予算で選んだ設定が、高予算reference winnerと違う設定。
 - tie-awareにする。
 - low-budget score が同点の場合:
 - tied candidates の中から fixed RNG で random choice
 - reference score が同点の場合:
 - exact winner は fixed RNG で決める
 - ただし tie-aware misselection では δ によって practical tie を処理する
 - $\delta \in \{0.00, 0.02, 0.05\}$
 - reference上で最良候補とほぼ同等なら、誤選抜とはみなさない
 - $\delta = 0.00$ なら strict misselection
 - $\delta = 0.02 / 0.05$ なら practical misselection

$$C_{E,\delta}^* = \{c \in C : S_{\text{ref}}(c_E^*) - S_{\text{ref}}(c) \leq \delta\}$$

$$P_{\text{mis},\delta}(E, b) = \Pr[\hat{c}_{E,b}^{(r)} \notin C_{E,\delta}^*]$$

- selection regret
 - 単にwinnerが違って、性能差が小さいなら実務上は問題ないかもしれない。なのでregretで見る。

$$\text{Regret}^{(r)}(E, b) = S_{\text{ref}}(c_E^*) - S_{\text{ref}}(\hat{c}_{E,b}^{(r)})$$

- Rank correlation
 - winnerだけでなく、順位全体があっているか。Spearman correlation、Kendall tauなど。
- Failure mode decomposition
 - late bloomer elimination：序盤弱い後で強くなる設定を止めてしまう)

$$\text{rank}_{\text{low}}(c) > k \quad \text{and} \quad \text{rank}_{\text{ref}}(c) \leq k$$

- lucky early success selection：疎報酬環境で、たまたま早く成功したseedが評価される
 - selected_seed_success_variance
 - winner_success_concentration
 - winner changes under seed resampling
- noisy promotion：確率的環境で、真に良い設定ではないのにノイズで上手くいっているように見えるやつを評価してしまう。
 - stochastic=1 の環境で、
 - same train seed / same checkpoint のpolicyを
 - eval seed subsetだけ変えたときにwinnerが変わるか
- misleading dense reward：密報酬で早期成績は良いが、最終的なスパース報酬では劣る設定を選んでしまう。(今回は不要)
- rank instability across seeds：同じ手法(、ハイパラ設定)でも、どのseed集合で候補を評価したかによって選ばれる設定が変わる。

$$H(\hat{c}_{E,b}) = -\sum_c p(c) \log p(c)$$

- Score Sはsuccess rate ($S(E, c, \text{budget}) = \text{greedy evaluation success rate}$)
- primary score: success_rate
- secondary score: mean_return
- diagnostic: hole_rate, timeout_rate, success_conditioned_steps

4. Experimental Design

4.1 Controlled MiniGrid-like Environments

- MiniGridは、強化学習研究用の小さな2Dグリッドワールド環境群である。
- 今回は、環境の因子が与える影響について分析するのが目的のため、厳密なMiniGrid環境ではなく、個別の環境因子を分離して操作できるように簡略化したMinigrid-likeなカスタム環境を用いる。
- MiniGridと本環境の違い
 - 行動空間：Minigridは行動空間が「turn left, turn right, move forward, pickup, drop, toggle, done」であるが、本環境では、「up, down, left, right, pickup, toggle」を用いる。
 - 観測空間：本環境では部分観測ではなく、完全観測を用いる。
 - 環境因子：本環境では、確率遷移、失敗終端、keydoorタスクの要素の組み合わせで作成する。

4.2 Environment factors and hypothesized failure mechanisms

項目	設定
grid size	10×10
start	(0, 0)
goal	(9, 9)
max steps	150
actions	up, down, left, right, pickup, toggle
stochastic transition	intended 0.8, left 0.1, right 0.1
training episodes	30,000
checkpoints	300, 1000, 3000, 5000, 10000, 20000, 30000

env	stochastic	holes	keydoor	役割
E000	0	0	0	plain control
E100	1	0	0	stochastic単独
E010	0	1	0	holes単独
E110	1	1	0	stochastic × holes
E001	0	0	1	keydoor単独
E101	1	0	1	stochastic × keydoor
E011	0	1	1	holes × keydoor
E111	1	1	1	stochastic × holes × keydoor

- environment factor
 - stochastic transition
 - 移動先がアクションとズレる
 - 確定遷移ー確率遷移
 - $p_{\text{intended}} = 0.8$
 - $p_{\text{left_or_right}} = 0.1$ each
 - wall collision = stay
 - stochastic transition は movement actions のみに適用
 - pickup/toggle は deterministic
 - hazardous states
 - マップに穴マスがあり、そのマスに入ると終端状態になり、エピソードが終了する。
 - 穴なしー穴あり
 - hole termination rateを記録

- holeに入ると terminated = True
- reward = 0
- goal reward = 1
- それ以外 reward = 0
- holes位置
- 通常版：(2,2), (2,4), (4,7), (6,2), (8,6)
- KeyDoorと掛け合わさる時の簡単版(E011/E111)：(2,2),(6,2),(8,6)
- long horizon / key-door subtask
 - Door-Key型
 - 鍵をとってからゴールしないといけない。
 - 単純経路一鍵ドア式
 - 鍵とドアの位置は？
 - key cell にいる状態で pickup → has_key=True
 - door cell の隣で toggle → door_open=True if has_key
 - door_open=True なら通過可能
 - goalに到達したら reward=1, terminated=True
 - key cellに入っただけでは取得せず、pickup actionが必要
 - closed door に move しようとしたら stay
 - door_open=True なら通過可能
 - toggle は door 隣接時のみ有効
 - door_open は一度 True になったら episode中ずっと True
 - Key位置：(1,3)
 - Door位置：(5,5)
 - Wall column：5

Env ID	stochastic	holes	key-door
E000	0	0	0
E100	1	0	0
E010	0	1	0
E110	1	1	0
E001	0	0	1
E101	1	0	1
E011	0	1	1
E111	1	1	1

key-door 環境では、そのままだと難しすぎる可能性があるため、解ける範囲に収まるように穴の配置を調整した。

したがって、hazard の有無・強さを「他の要因から完全に独立した実験要因」として厳密に解釈するのではなく、「同じ環境ファミリー内で比較するために調整された hazard 条件」として扱う。

4.3 Candidate Q-learning configurations

- 全て tabular Q-learning の candidate configuration hyperparameter setting。
- $Q_{\text{init}} = 0$
- argmax tie-breaking = random among max actions

- training: random tie-breaking
- evaluation: random tie-breaking with fixed eval RNG
 - fixed eval RNG : RNGとはrandom number generator(乱数生成器)。Q値が同点のactionがある場合、評価用の乱数をseedから固定的に作っている。
 - train seed = ある固定値
 - ↓
 - eval seed = train seed から決まる固定値
 - ↓
 - 評価中のtie-breaking乱数に使う
 - そのため、「完全なランダム」ではなく、「再実行しても同じ流れになりやすい固定されたランダム性」ということ。
 - seedから固定生成されたeval RNGを使うが、各chackpointでリセットはしていない。
 - 評価時には、学習済みQ-tableに対してgreedy policyを用いる。
 - epsilon-greedy探索は評価時には使用しない。
 - ただし、複数の行動が同じ最大Q値を持つ場合には、
 - training seedから決定的に生成された評価用RNGを用いて、
 - 最大Q値行動の中から一様ランダムに選択する。
- $\text{decay_steps} = \text{epsilon_decay_ratio} * \text{max_episodes}$
- $\text{epsilon}(t) =$
 - $\text{epsilon_end} + (\text{epsilon_start} - \text{epsilon_end}) * \max(0, 1 - t / \text{decay_steps})$
- ここで重要なのは、low episode = 3000 のときも、30000 episode run の途中checkpointとして見ることです。
- つまり、low budget用にepsilon scheduleを作り直してはいけません。
- H1.早期収束型
 - ϵ を早く下げる
 - 偶然成功したら強く見えるが再現性が低い。
 - 初期に強く見えるが、高予算では伸びない可能性
- H2.標準型
 - 中庸な探索
 - 多くの環境で安定基準
- H3.長期探索型
 - ϵ を長く残す
 - 疎報酬では強いが短期評価が弱く見える
 - 初期には弱く見えるが、高予算では勝つ可能性
- H4.高学習率型
 - α が大きい
 - 初期成功に過剰反応しやすい
 - 偶然の成功に過剰反応しやすい
- H5.低学習率型
 - α が小さい
 - 遅いが高予算では安定する可能性
 - 初期は弱いだが、高予算では安定する可能性

ID	名称	α	γ	ϵ 初期値	ϵ 最終値	ϵ decay ratio	意図
C1	early exploit	0.1	0.99	1.0	0.01	0.10	早期収束型
C2	standard	0.1	0.99	1.0	0.05	0.60	標準型
C3	long explore	0.1	0.99	1.0	0.10	1.00	長期探索型
C4	high alpha	0.5	0.99	1.0	0.05	0.60	高学習率型
C5	low alpha	0.03	0.99	1.0	0.05	0.60	低学習率型

4.4 Training and evaluation budgets

- S_checkpoint、AUC_success、T_0.5、T_0.8、S_finalを出す
- evaluation rollout budgetは、
 - 5：極端に少ない評価episode
 - 10：low eval budget
 - 30：現在の標準
 - 100：reference寄り
 - のパターンで行いたい。

budget	役割
300 / 1000 / 3000	very-low budget
5000 / 10000	low-to-mid budget
20000	delayed emergence確認
30000	high-budget reference

指標	意味	なぜ必要か
S_t	checkpoint t での成功率	低budget時点の性能を見る
AUC_success	学習曲線下の面積	final successの天井効果を避ける
T_0.5	成功率0.5に初めて到達したepisode	立ち上がり速度を見る
T_0.8	成功率0.8に初めて到達したepisode	実用的成功水準への到達を見る

指標	意味
S_final	30,000 episodes時点の成功率
train goal rate	学習中にgoalへ到達した割合
train hole rate	学習中にholeで失敗した割合
timeout rate	時間切れ割合

4.5 実験前仮説

- H1：Stochastic transition
 - 確率遷移は少数seedでのwinner instabilityを増加させる。
 - 理由：同じconfigでも遷移ノイズによってseed間、episode間の成功率の揺れが大きくなり、低seedではwinnerが上振れ候補に引っ張られやすい。
- H2：Terminal hazards
 - 失敗終端は、短いhorizonで探索重視がたconfigを評価した場合に、selection regretを増幅する。
 - 理由：探索を長く残すconfigは、長期的には有利になる可能性があるしかし短期評価では、探索中に穴へ落ちる確率が高くなり、成功率や報酬が低く見積もられやすい。その結果、低budget評価では、長期的に有望なconfigが過小評価される可能性がある。
- H3：Key-Door structure
 - Key-door環境では、低いtraining-horizon budgetのもとでlate-bloomer eliminationが増加する。

- Key-Door環境では、鍵を取得し、ドアを上げ、ゴールに到達するという順序依存がある。そのため、初期checkpointでは、本来は有望な設定であっても性能がまだ表に出にくい。結果として長期的には良いcandidateが短期評価では早期に脱落する可能性がある。
- H4：Interaction
 - 最も強いselection failureは、単一の環境因子でなく、stochasticity×hazardsや、hazards × key-door structureのような相互作用によって生じる。
 - 理由：
 - stochasticity×hazards
 - 確率遷移のみがある場合はアクションにブレがありながらも繰り返しによってゴールに辿り着けるはずであるが、そこに失敗終端が入ると遷移の仕方によって理不尽に穴に落ちる可能性がある。学習の結果として確率遷移してもうまく行きやすいロバストな経路を学ぶ可能性があるが、少なくとも学習初期の探索はより困難になり、低予算下での不安定性を増加させる。
 - hazards × key-door structure
 - こちらも、本来はkey-door structureで探索の難易度が増加しているところに失敗終端が増えるので、より探索は難しくなる。よって、最初の成功体験を偶然得られるまではスコアが低い状態が続くはず。しかしこちらは確率遷移がないので、成功体験を積み始めることができれば、late-bloomerとしてある段階から急に良くなる可能性がある。もちろんそれは、Key-Door structure単体の時よりも遅い段階から始まるはずである。

5. Results

- 5.2がwhere、5.3がWhen / under what budget、5.4がWhyに相当する。

5.1 Candidate performance separates environments into saturated and hard-composite regimes

- 環境を分類する節。まだselection failureの細かい話はしない。リファレンスにどれだけ信頼性があるかを見せる。
- 最終性能を見ると、環境は、「候補間差がほぼ消える飽和環境」「弱い候補差が残る中間環境」「明確な候補差が残る複合困難環境」に分かれることを、簡単な表と共に示す。
- 結果データのサマリー表を整理して貼る。以下の表に追加して、misselectionとregretの値を書いて、misselectionは多いがregretが小さいのでwinnerが拮抗しているということを示す。←これは入れない。referenceの信頼度を見るための節で会って、winner selectionの話はまだ入らないはず。

env id	group	ref winner	reference top score	reference top2 gap	practical winner set size delta 0.05	practical winner set delta 0.05	reference top1 frequency	reference winner entropy	interpretation
E000	Saturated environments	C1	1.0	0.0	5	C1,C2,C3,C4,C5	0.2	1.608	Fully saturated; winner identity is not practically meaningful.
E001	Saturated environments	C1	1.0	0.0	5	C1,C2,C3,C4,C5	0.21	1.608	Fully saturated; winner identity is not practically meaningful.
E010	Saturated environments	C1	1.0	0.0	5	C1,C2,C3,C4,C5	0.19	1.608	Fully saturated; winner identity is not practically meaningful.
E100	Saturated environments	C1	1.0	0.0	4	C1,C2,C3,C5	0.219	1.383	Near-ceiling performance; most top candidates are practically tied.
E101	Near-saturated / weakly discriminative	C1	1.0	0.0	4	C1,C2,C3,C5	0.425	1.03	High performance with weak candidate differences among top candidates.
E110	Near-saturated / weakly discriminative	C3	0.999	0.0	4	C1,C2,C3,C5	0.505	0.996	High performance with weak candidate differences among top candidates.
E011	Discriminative hard-composite environments	C5	0.85	0.059	1	C5	0.806	0.628	Clear candidate separation; winner selection is substantively meaningful.
E111	Discriminative hard-composite environments	C3	0.813	0.102	1	C3	0.97	0.156	Clear candidate separation; winner selection is substantively meaningful.

5.2 Selection failure appears primarily in hard-composite environments

- selection failureがどこで出たかを示す節。
- saturated環境(実用的な差がない結果)の解釈
 - Saturated environmentsでは、strict winner identifyは不安定でも、practical regretは小さい。
 - この場合、winnerが一致しないことが、そのまま実的に悪い選択をしたことにはならない。
- hard-composite環境(差のある結果)との対比
 - E101,E110ではやや差があることを示す。

- selection failureがどこで出ているのか、学習の段階に応じてfailureの割合はどうなっているのか、などを示す。
- E011/E111では、reference winnerとの性能差が実用的に意味を持ち、practical misselectionが高くなる。
- selection failureがどこで出ているのか、学習の段階に応じてfailureの割合はどうなっているのか、などを示す。
- したがって、low-budget selection failureは全環境に一樣に出るのではなく、特定の複合環境で顕在化する。

表A：代表的low-budget条件での環境比較

- 条件：seed budget=5、checkpoint=30000
- 飽和環境ではstrict misselectionは起きてもpractical misselectionは小さい。
- E011/E111ではpractical misselectionとregretが大きい。

env	group	ref winner	top2 gap	tie set size	winner agreement rate S5 T30000	mean regret S5 T30000	strict misselection S5 T30000	practical misselection S5 T30000
E000	Saturated	C1	0.0	5	0.212	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.221	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.21	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.235	0.0	0.004	0.004
E101	Near-saturated	C1	0.0	4	0.267	0.008	0.505	0.034
E110	Near-saturated	C3	0.0	4	0.304	0.004	0.696	0.016
E011	Hard-composite	C5	0.059	1	0.338	0.064	0.662	0.662
E111	Hard-composite	C3	0.102	1	0.486	0.07	0.514	0.514

表B：checkpointごとの変化(S5固定)

- seed budget=5, checkpoint=3000/10000/30000
- 学習段階に応じてselection failureがどう変わるかを見る。
- 特にE101,E110,E011,E111の対比に使える。

env	group	ref winner	top2 gap	tie set size	strict mis T3000	practical mis T3000	mean regret T3000	strict mis T10000	practical mis T10000	mean regret T10000	strict mis T30000	practical mis T30000	mean regret T30000
E000	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.001	0.001	0.0	0.0	0.0	0.0	0.004	0.004	0.0
E101	Near-saturated	C1	0.0	4	0.608	0.006	0.004	0.347	0.001	0.006	0.505	0.034	0.008
E110	Near-saturated	C3	0.0	4	0.821	0.0	0.011	0.88	0.0	0.002	0.696	0.016	0.004
E011	Hard-composite	C5	0.059	1	0.815	0.815	0.093	0.87	0.87	0.089	0.662	0.662	0.064
E111	Hard-composite	C3	0.102	1	0.809	0.809	0.12	0.693	0.693	0.102	0.514	0.514	0.07

5.3 Hard-composite environments remain budget-sensitive under larger seed and evaluation budgets

- budgetの効果は環境に依存する。飽和環境やnear-saturated環境では、seed budgetやeval budgetを増やすことでpractical misselectionはほぼ消える。一方、E011/E111では、30,000 episodesまで学習し、eval rollout budgetを100まで増やしても、practical misselectionとregretが大きく残る。

5.3.1 Training seed budget

- 最終checkpointでは、training seed budgetを増やすほどpractical misselectionとmean selection regretは低下する。しかし、hard-composite環境では、この改善は緩やかであり、E011ではS5で0.662、S10でも0.557のpractical misselectionが残る。E111でもS5で0.514、S10で0.419が残る。一方、飽和環境及びnear-saturated環境では、practical misselectionとregretはいずれも小さい。
- S100の時にmisselectionが0になっているのは、S100の場合は本実験で定義したseed full-budget selectionに一致するため。

table_5_3_1_seed_budget_practical_misselection_T30000

env	group	ref winner	top2 gap	tie set size	S1	S3	S5	S10	S20	S30	S50	S100
E000	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.112	0.025	0.004	0.0	0.0	0.0	0.0	0.0
E101	Near-saturated	C1	0.0	4	0.122	0.065	0.034	0.003	0.001	0.0	0.0	0.0
E110	Near-saturated	C3	0.0	4	0.141	0.043	0.016	0.001	0.0	0.0	0.0	0.0
E011	Hard-composite	C5	0.059	1	0.771	0.692	0.662	0.557	0.459	0.353	0.233	0.0
E111	Hard-composite	C3	0.102	1	0.617	0.551	0.514	0.419	0.262	0.177	0.038	0.0

table_5_3_1_seed_budget_mean_regret_T30000

env	group	ref winner	top2 gap	tie set size	S1	S3	S5	S10	S20	S30	S50	S100
E000	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.011	0.002	0.0	0.0	0.0	0.0	0.0	0.0
E101	Near-saturated	C1	0.0	4	0.017	0.011	0.008	0.004	0.003	0.002	0.001	0.0
E110	Near-saturated	C3	0.0	4	0.017	0.007	0.004	0.002	0.001	0.001	0.0	0.0
E011	Hard-composite	C5	0.059	1	0.087	0.067	0.064	0.046	0.035	0.024	0.015	0.0
E111	Hard-composite	C3	0.102	1	0.091	0.079	0.07	0.057	0.033	0.021	0.004	0.0

5.3.2 Training horizon

- training horizonはselection reliabilityに影響するが、その効果は単純な単調改善ではない。E011/E111では、短い・中間checkpointでpractical misselectionが高く、T30000では低下するものの、完全には消えない。
- これは、少数seed条件では、最終的に強い候補が短い・中間的なtraining horizonで安定して識別できないことを示している。

table_5_3_2_training_horizon_practical_misselection_S5

env	group	ref winner	top2 gap	tie set size	T3000	T10000	T30000
E000	Saturated	C1	0.0	5	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.001	0.0	0.004
E101	Near-saturated	C1	0.0	4	0.006	0.001	0.034
E110	Near-saturated	C3	0.0	4	0.0	0.0	0.016
E011	Hard-composite	C5	0.059	1	0.815	0.87	0.662
E111	Hard-composite	C3	0.102	1	0.809	0.693	0.514

table_5_3_2_training_horizon_mean_regret_S10

env	group	ref winner	top2 gap	tie set size	T3000	T10000	T30000
E000	Saturated	C1	0.0	5	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.0	0.0	0.0
E101	Near-saturated	C1	0.0	4	0.002	0.006	0.004
E110	Near-saturated	C3	0.0	4	0.014	0.001	0.002
E011	Hard-composite	C5	0.059	1	0.1	0.09	0.046
E111	Hard-composite	C3	0.102	1	0.12	0.1	0.057

table_5_3_2_training_horizon_mean_regret_S5

env	group	ref winner	top2 gap	tie set size	T3000	T10000	T30000
E000	Saturated	C1	0.0	5	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.0	0.0	0.0
E101	Near-saturated	C1	0.0	4	0.004	0.006	0.008
E110	Near-saturated	C3	0.0	4	0.011	0.002	0.004
E011	Hard-composite	C5	0.059	1	0.093	0.089	0.064
E111	Hard-composite	C3	0.102	1	0.12	0.102	0.07

table_5_3_2_training_horizon_practical_misselection_S10

env	group	ref winner	top2 gap	tie set size	T3000	T10000	T30000
E000	Saturated	C1	0.0	5	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.0	0.0	0.0
E101	Near-saturated	C1	0.0	4	0.001	0.0	0.003
E110	Near-saturated	C3	0.0	4	0.0	0.0	0.001
E011	Hard-composite	C5	0.059	1	0.862	0.895	0.557
E111	Hard-composite	C3	0.102	1	0.822	0.679	0.419

5.3.3 Evaluation rollout budget

- evaluation rollout budgetを増やすと一部条件ではわずかに改善するが、E011ではほぼ改善せず、E111でも大きくは改善しない。したがって、失敗の主因は評価episode数の少なさだけでなく、training seed budgetとtraining horizonによる学習結果の不確実性にもある。
- near-saturated環境では、eval badgetを100まで増やしてもpractical misselectionとregretが大きく残る。
- practical misselectionは、stochasticity、hazards、key-doorの単独環境因子によって一様に増えるわけではない。むしろ、key-doorによる順序依存とterminal hazardsによる失敗終端が組み合わさったE011に明確化し、さらにstochastic transtitionが加わったE111でもperctiacl misselectionは大きく残った。また、E011とE111とでは、頑強な候補の種類も変化した。
- eval011/E11では、eval rollout budgetを増やしても、E011やR111では失敗が完全には消えないことを示している。

table_5_3_3_eval_budget_practical_misselection_S5_T30000

env	group	ref winner	top2 gap	tie set size	E5	E10	E30	E50	E100
E000	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.035	0.013	0.004	0.004	0.002

env	group	ref winner	top2 gap	tie set size	E5	E10	E30	E50	E100
E101	Near-saturated	C1	0.0	4	0.085	0.06	0.034	0.023	0.022
E110	Near-saturated	C3	0.0	4	0.058	0.038	0.016	0.014	0.006
E011	Hard-composite	C5	0.059	1	0.666	0.666	0.662	0.662	0.66
E111	Hard-composite	C3	0.102	1	0.559	0.541	0.514	0.506	0.487

table_5_3_3_eval_budget_practical_misselection_S10_T30000

env	group	ref winner	top2 gap	tie set size	E5	E10	E30	E50	E100
E000	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.005	0.0	0.0	0.0	0.0
E101	Near-saturated	C1	0.0	4	0.037	0.017	0.003	0.002	0.001
E110	Near-saturated	C3	0.0	4	0.017	0.007	0.001	0.001	0.001
E011	Hard-composite	C5	0.059	1	0.567	0.567	0.557	0.557	0.558
E111	Hard-composite	C3	0.102	1	0.451	0.448	0.419	0.416	0.414

table_5_3_3_eval_budget_mean_regret_S5_T30000

env	group	ref winner	top2 gap	tie set size	E5	E10	E30	E50	E100
E000	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.004	0.001	0.0	0.0	0.0
E101	Near-saturated	C1	0.0	4	0.013	0.011	0.008	0.007	0.007
E110	Near-saturated	C3	0.0	4	0.01	0.008	0.005	0.004	0.002
E011	Hard-composite	C5	0.059	1	0.065	0.065	0.064	0.065	0.065
E111	Hard-composite	C3	0.102	1	0.077	0.075	0.071	0.07	0.068

table_5_3_3_eval_budget_mean_regret_S10_T30000

env	group	ref winner	top2 gap	tie set size	E5	E10	E30	E50	E100
E000	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E001	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E010	Saturated	C1	0.0	5	0.0	0.0	0.0	0.0	0.0
E100	Saturated	C1	0.0	4	0.001	0.0	0.0	0.0	0.0
E101	Near-saturated	C1	0.0	4	0.008	0.006	0.004	0.004	0.004
E110	Near-saturated	C3	0.0	4	0.006	0.005	0.002	0.002	0.001
E011	Hard-composite	C5	0.059	1	0.048	0.048	0.046	0.047	0.047
E111	Hard-composite	C3	0.102	1	0.061	0.061	0.057	0.057	0.056

5.4 Mechanism diagnosis: hard-composite environments induce late-bloomer elimination

- 5.4では、5.3の結果に対するmechanism diagnosisを書く。なぜE011/E111でselection failureが起きるのか？に答える節。
- E011
 - 確定遷移、hazardあり、key-doorあり
 - final reference winnerはC5
 - しかし、短いcheckpointではC5の優位が見えにくい。
 - 低budgetではC5を選び損ねる。
 - これをlate-bloomer eliminationと解釈する。

- E011では、key-door構造が、「鍵を取ってから扉を開ける」という順序依存を作り、terminal hazardが探索失敗を不可逆な失敗として扱う。このため、最終的には高性能に到達する候補であっても、短いtraining horizonや少数seed条件で十分には優位が観測されず、低予算referenceから落とされやすい。
- E111
 - 確率遷移あり、hazardあり、key-doorあり
 - final reference winnerはC3
 - stochastic + key-door + hazardsではlong explorationが最終的に効く。
 - しかし短いtraining horizonではC3が上位に見えない。
 - したがって、早期選抜ではC3が落とされやすい。
 - E111では、E011の順序依存と失敗終端にクォえて、stochastic transitionが軌道レベルの分散を増やす。その結果、単に最短経路を学ぶだけではなく、確率線のもとで安定してkey-door手続きを実行できる候補が有利になる。これにより、E011とは異なるcandidateがreference winnerになり、低予算selectionではその候補を安定して識別しにくくなる。
- E011/E111では、高予算リファレンスではC5/C3が最も高いパフォーマンスを出しているが、短いホライズンや低seedでの選択では確実に識別できるわけではない。
- stochasticityは単に同じ問題をノイズ化しただけではなく、hard-composite構造のもとで頑強な候補の種類を変えた。

6. Discussion

6.1 Environment structure determines whether low-budget selection error matters

- selection failureは全環境に一樣に出たわけではない。
- 優しい環境ではfinal successが飽和した。
- 飽和環境では、strict winner identityは不安定でも、practical regretは小さい。
- failureはkey-door + hazardsのようなhard-composite conditionではwinner不一致が実用的損失になる。
- したがって、これはselection failureはbudgetだけでなく environment structureに依存する

6.2 Performance degradation vs selection distortion

- performance degradation：環境が難しくなって全候補の成功率が下がること
- selection distortion：低budgetで選んだ候補が、high-budget reference上では劣ること。
- hard-composite環境は、単に全候補の性能を一樣に下げただけでなく、低予算条件での候補順位を歪める。
 - 5.resultのどっかで、hard-composite環境において、低予算ではどれが勝ってて、その後最終的にどれが勝つようになったのか明示したい。

6.3 Why tabular Q-learning is used

- 本研究でtabular-Q-learningを用いたのは、深層RLにした時に発生する関数近似、ネットワーク初期値、optimizer、実装差などの不安定性を意図的に避け、環境構造がlow-budget selectionに与える影響を分離して観察するためではる。
- C1-C5は「最良ハイパラ探索」ではなく probe configurations
 - probe configurations：失敗メカニズムを調べるために、意図的に設計した候補設定

6.4 Implications for low-budget RL experimentation

- 少数seed training horizonだけでwinnerを決めるのは危険な場合があるが、全環境で同様に危険なわけではない。
- key-door / irreversible failure / stochastic transitionを含む環境では、seed budgetとtraining horizonを増やす必要がある。
- eval episodesを増やすだけでは不十分な場合がある。
 - eval episodesを増やすと解決できるのは、evaluation noise。
 - 低予算選択の失敗は、評価ノイズだけでなく、学習過程そのものの不安定性や、短すぎる training horizonによる候補の早期脱落からも生じる。したがって、eval episodesを増やして評価を精密化するだけでは、winner selectionの信頼性は十分に回復しない場合がある。
- reportingでは、winner identityだけでなく、selection regret practical misselection / reference stabilityを出すべき。

6.5 Limitations

- Why controlled diagnostic environments is used
 - 本研究で用いたcontrolled environmentsは外部妥当性よりも、因果解釈、診断性を優先している。
- hazard layoutが完全直行factorialではない。
 - 穴の数は鍵付きドア環境で解決可能性を考慮して矯正しているため、明確な直行factorialでの結果として解釈されるべきではない。

- E011/E111中心にpositive resultが出ている
 - 大きな差として結果が出たのはE011/E111程度だった。
- candidates C1-C5は限定的なprobe
 - 今回、設計意図に基づきC1-C5を作成したが、全てのハイパラの組み合わせを網羅できている訳ではない。
- high-budget referenceも有限seed、有限eval episodes
 - high-budget referenceも、単に多い予算で作ったものであるため、完璧な正解というものではない。
- deep RL / larger benchmarks / real tasksへの一般化は未検証。
- $\delta=0.05$ は実用閾値として設定したもので、別 δ でのrobustnessが必要。

7. Conclusion

- 本研究では、tabular Q-learningとcontrolled environmentsを用いて、環境因子が低予算winner selectionをどう歪めるのかについて実験し考察した。
- 結果としては、単一の環境因子はwinner selectionにそこまで強い影響をしなかったが、環境因子が複合的になると学習過程のパターンが代わり、winner selectionに強い不安定さを与えることになった。
- また、winner selectionにおいては特に学習中の予算が重要であり、eval時の予算を増やすとevalそのものの評価は正確になる一方で、評価の対象のモデルが不安定な場合には結果がぶれやすくなるということがわかった。
- 本研究は深層RLを使用していないところ、環境がcontroll可能にカスタムしたもので、外部妥当性が十分でないことなどに限界がある。次の展望としては、こちらに取り組んでいきたいと思う。