

論文のハリボテドラフト v3.0

低予算 RL 評価失敗の環境因子診断：構成整理版

要旨

状態：未完了ドラフト。Introduction と Related Work の骨格を、先生への説明用に読みやすく整形。

主眼：アルゴリズム性能そのものではなく、低予算評価で「どの候補を勝者として選ぶか」が環境構造により歪む過程を診断する。

方針：Deep RL 特有の関数近似・実装交絡を避けるため、tabular Q-learning の probe configurations を用いる。

1. Introduction

強化学習（RL）の実験では、複数の候補設定から良い設定を選ぶ必要がある。候補には、アルゴリズム、ハイパーパラメータ、実装上の設計、あるいは学習済み方策が含まれる。しかし、すべての候補を高予算で十分に評価することは、多くの場合、計算資源・時間・実験管理の観点から現実的ではない。

そのため実務上も研究上も、低予算評価で候補を絞り込み、より有望そうな候補に追加予算を配分する操作が発生する。しかし、低予算評価は単なる「少ないデータ」ではない。環境の構造、報酬の疎さ、遷移の確率性、失敗終端、鍵と扉のような順序依存構造によって、候補の見え方が歪み、観測された勝者が高予算での勝者と一致しない可能性がある。

本研究は、この問題を low-budget winner selection failure として捉える。すなわち、限られた seed、training episodes、evaluation episodes のもとで候補を選抜するとき、どのような環境因子が誤選抜、選抜 regret、late-bloomer elimination を増幅するのかを診断する。

重要なのは、本研究が「環境因子によってアルゴリズム性能が下がる」こと自体を見る研究ではない点である。焦点は、環境因子が候補間比較の信頼性をどう変え、低予算での winner selection をどのように歪めるかにある。

本研究の貢献

- 低予算 RL 候補選抜を、winner selection problem として定式化する。
- stochastic transition、terminal hazards、key-door structure、およびそれらの複合条件が、低予算 winner selection failure をどのように増幅しうるかを、制御可能な小規模環境で検証する。
- tabular Q-learning を用いることで、Deep RL 特有の関数近似・実装交絡を避け、環境因子と選抜失敗の関係を解釈可能にする。

2. Related Work

2.1 RL 評価は不安定である

RL 実験では、random seed、環境の確率性、実装、評価手順によって結果が揺れやすい。特に Deep RL では、少数 run の点推定だけに基づく比較が不安定な結論を生み出すことが繰り返し指摘されている。Henderson et al. は実装・seed・評価手続きの差が結論に影響しうることを示し、Agarwal et al. は少数 run 環境では平均や中央値などの点推定だけでは不確実性を十分に扱えないと論じている。

この流れに対して、本研究は「評価値が不安定である」という一般論を前提に置きつつ、その不安定性が複数候補の選抜操作に入ったとき、どの環境構造で誤選抜が起きやすくなるのかを診断する。

2.2 RL の性能は複合的な要因で決まる

RL の性能差は、アルゴリズムだけでなく、実装上の設計、ハイパーパラメータ、環境因子に強く左右される。たとえば、オンポリシー RL の実装には多数の設計選択があり、それらが性能に大きく影響する。また、ハイパーパラメータ選択は最終性能や sample efficiency に影響し、tuning seed への過適合も問題になりうる。

この観点から見ると、低予算評価で得られる候補順位は、候補そのものの良し悪しだけでなく、環境構造と予算の相互作用によって歪む可能性がある。したがって、単に「よいハイパーパラメータを探す」研究ではなく、「限られた予算下で観測された勝者がどの程度信用できるか」を問う必要がある。

Patterson et al. の cross-environment hyperparameter setting のような研究は、環境をまたいだハイパーパラメータ選択の一貫性という点で重要である。一方、本研究では cross-environment transfer の成功率そのものではなく、環境因子が低予算選抜の失敗率をどう変えるかに焦点を絞る。

2.3 winner selection はノイズのある選抜問題である

winner selection とは、複数の候補を実験・評価し、観測されたスコアが最も高い候補を「勝者」として選ぶ操作である。RL 実験では、アルゴリズム、ハイパーパラメータ設定、実装選択、学習済み方策などを、限られた評価結果に基づいて選ぶ場面が多い。本研究では、このような観測性能に基づく最良候補の選択を winner selection と呼ぶ。

winner selection の基本定式化

候補集合を $C = \{c_1, \dots, c_K\}$ とする。

低予算 b で観測される評価値を $S_{\text{hat}}(c)$ とすると、低予算 winner は

$$c_{\text{hat}} = \operatorname{argmax}_{c \in C} S_{\text{hat}}(c)$$

高予算 reference performance を $S_{\text{ref}}(c)$ とすると、reference winner は

$$c^* = \operatorname{argmax}_{c \in C} S_{\text{ref}}(c)$$

strict misselection: $c_{\text{hat}} \neq c^*$

selection regret: $S_{\text{ref}}(c^*) - S_{\text{ref}}(c_{\text{hat}})$

practical misselection: $S_{\text{ref}}(c^*) - S_{\text{ref}}(c_{\text{hat}}) > \delta$

Jamieson & Talwalkar は、ハイパーパラメータ最適化を non-stochastic best-arm identification として定式化し、限られたリソースで最良候補を同定する問題を扱っている。また Cawley & Talbot は、モデル選択基準そのものに分散がある場合、モデル選択過程で overfitting や selection bias が生じ、その影響がアルゴリズム間の性能差と同程度になりうると論じている。

本研究では、複数の Q-learning probe configurations を candidate configurations とみなし、低予算評価に基づいて winner を選ぶ。主眼は効率的な探索手法を提案することではなく、環境因子が低予算 winner selection の失敗率に与える影響を診断することにある。

2.4 controlled environments

MiniGrid は、カスタマイズ可能な goal-oriented 環境群として設計されており、研究目的に応じた環境開発に向いている。bsuite は、RL agent の中核的能力や失敗要因を調べるための、慎重に設計された小規模実験群である。

本研究は bsuite と同じく診断的な性格を持つ。ただし、対象は agent capability そのものではなく、low-budget winner selection failure である。現実的な大規模環境で汎用性能を競うのではなく、環境因子を明示的に操作できる小規模環境を用いて、評価失敗の発生機序を切り分ける。

3. 本研究の位置づけ

既存研究の主な問い	本研究の問い
RL 評価はどの程度不安定か。	不安定な評価を使って候補を選んだとき、どの環境因子で誤選抜が増えるか。
どの統計指標・信頼区間で比較すべきか。	低予算 winner と高予算 reference winner のズレをどう測るか。
どの環境・ベンチマークで汎用性能を測るか。	環境因子を制御し、選抜失敗の発生機序を診断できるか。
どのハイパーパラメータが性能に効くか。	ハイパーパラメータ候補の見え方が、予算と環境構造によってどう歪むか。

4. 現時点での注意点

- 「環境因子」と呼んでいるものは、環境ファミリーが変わると意味が変わる。terminal hazards であっても、FrozenLake、CliffWalking、MiniGrid 風環境では同じ現象とは限らない。
- したがって、本研究の主張は「すべての RL 環境に一般化する法則」ではなく、「制御環境で観測される低予算選抜失敗の機序」として弱める必要がある。
- Deep RL への接続を主張する場合、tabular Q-learning で見えた現象がどこまで環境側の要因であり、どこからアルゴリズム・関数近似側の要因になるのかを明確に分ける必要がある。
- 先生に見せる場合は、実験結果の完成度よりも、「既存研究の問い」と「本研究がずらす問い」の説明を優先した方が伝わりやすい。

関連研究一覧（最終ページ）

スクリーンショット内の重複を統合し、研究説明に使いやすい順に整理。概要は本研究との接点が見えるように短く圧縮。

論文名	著者名	概要
Deep Reinforcement Learning that Matters	Peter Henderson, Riashat Islam, Philip Bachman, Joelle Pineau, Doina Precup, David Meger	Deep RL 実験の再現性問題を整理。seed、実装、評価手順の揺れが結論を変えうることを示す。
Deep Reinforcement Learning at the Edge of the Statistical Precipice	Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron Courville, Marc G. Bellemare	少数 run の点推定比較の危険性を指摘。IQM、performance profile、bootstrap CIなどを提案。
Empirical Design in Reinforcement Learning	Andrew Patterson, Samuel Neumann, Martha White, Adam White	RL 実験設計の総合的ガイド。変動、仮説検定、複数比較、ハイパーパラメータ、実験者バイアスを扱う。
Evaluating the Performance of Reinforcement Learning Algorithms	Scott M. Jordan, Yash Chandak, Daniel Cohen, Mengxue Zhang, Philip S. Thomas	単一環境・複数環境での性能評価方法を整理し、信頼できる RL 比較のための評価手順を提案。
How Many Random Seeds? Statistical Power Analysis in Deep RL Experiments	Cédric Colas, Olivier Sigaud, Pierre-Yves Oudeyer	seed 数と統計的検出力・誤検出の関係を解説。低 seed 比較の危険性を示す。
A Hitchhiker’s Guide to Statistical Comparisons of RL Algorithms	Cédric Colas, Olivier Sigaud, Pierre-Yves Oudeyer	RL アルゴリズム比較に使う統計検定を整理し、sample size・effect size・仮定違反への注意点を示す。
Measuring the Reliability of Reinforcement Learning Algorithms	Stephanie C. Y. Chan, Samuel Fishman, John Canny, Anoop Korattikara, Sergio Guadarrama	RL の信頼性を変動性・リスクの観点から測るメトリクス群を提案。training 中と固定 policy 後の信頼性を扱う。
Showing Your Offline Reinforcement Learning Work: Online Evaluation Budget Matters	Vladislav Kurenkov, Sergey Kolesnikov	offline RL 比較では online evaluation budget によって好ましい手法が変わることを示し、予算依存の評価を提案。
On the consistency of hyper-parameter selection in value-based deep RL	Johan Obando-Ceron, João G. M. Araújo, Aaron Courville, Pablo Samuel Castro	value-based deep RL におけるハイパーパラメータ選択の一貫性を検証。設定の転用可能性を測る。
The Cross-environment Hyperparameter Setting Benchmark for RL	Andrew Patterson et al.	環境をまたぐハイパーパラメータ設定の一貫性・転用性を問う。CHS として本研究との差分整理に重要。
Hyperparameters in Reinforcement Learning and How To Tune Them	Theresa Eimer, Marius Lindauer, Roberta Raileanu	RL のハイパーパラメータ最適化手順を整理。tuning seed への過適合と、HPO 実践の必要性を示す。
Behaviour Suite for Reinforcement Learning	Ian Osband, Yotam Doron, Matteo Hessel, John Aslanides, et al.	bsuite を提案。RL agent の中核能力や失敗要因を診断する小規模・制御実験群。
Minigrid & Miniworld: Modular & Customizable RL Environments for Goal-Oriented Tasks	Maxime Chevalier-Boisvert, Bolun Dai, Mark Towers, Rodrigo de Lazcano, et al.	2D/3D のカスタマイズ可能な goal-oriented 環境群。制御環境を自作する基盤として重要。
MiniHack the Planet: A Sandbox for Open-Ended RL Research	Mikayel Samvelyan, Robert Kirk, Vitaly Kurin, Jack Parker-Holder, et al.	NetHack 由来の豊かな環境要素を使い、探索・汎化・環境設計を扱うサンドボックス。
BabyAI: A Platform to Study the Sample Efficiency of Grounded Language Learning	Maxime Chevalier-Boisvert, Dzmitry Bahdanau, Salem Lahlou, Lucas Willems, et al.	合成言語指示を用いる段階的タスク群。sample efficiency と構成的課題の設計例として参考になる。
Leveraging Procedural Generation to Benchmark Reinforcement Learning	Karl Cobbe, Christopher Hesse, Jacob Hilton, John Schulman	Procgen Benchmark を提案。procedural generation による汎化評価と環境分布の重要性を示す。
Measuring Sample Efficiency and Generalization in RL Benchmarks: NeurIPS 2020 Procgen Benchmark	Sharada Mohanty, Jyotish Poonganam, Adrien Gaidon, Andrey Kolobov, et al.	Procgen 競技の設計と結果を整理。sample efficiency と generalization の標準化された評価例。
Revisiting the Arcade Learning Environment	Marlos C. Machado, Marc G. Bellemare, Erik Talvitie, Joel Veness, Matthew Hausknecht, Michael Bowling	ALE の評価プロトコルを再検討。sticky actions など、評価手順と環境設定が結論に与える影響を整理。
Atari-5: Distilling the Arcade Learning Environment down to Five Games	Matthew Aitchison, Penny Sweetser, Marcus Hutter	ALE 全体の代表性を保ちながら少数ゲームへ圧縮する試み。低コスト評価の代表性問題と接続。
First Return, Then Explore / Go-Explore	Adrien Ecoffet, Joost Huizinga, Joel Lehman, Kenneth O. Stanley, Jeff Clune	hard exploration で、まず到達済み状態へ戻り、その後探索する方針を提案。疎報酬・探索困難タスクの基礎文献。
There Is No Turning Back: Reversibility-Aware RL	Nathan Grinsztajn, Johan Ferret, Olivier Pietquin, Philippe Preux, Matthieu Geist	行動の可逆性・不可逆性を自己教師ありで推定し、探索や制御に組み込む。terminal hazards の議論に接続。
On Evaluation of Embodied Navigation Agents	Peter Anderson, Angel X. Chang, Devendra S. Chaplot, Alexey Dosovitskiy, et al.	Embodied navigation の評価指標・プロトコルを整理。単純な成功率だけでは測れない評価設計の例。
Success Weighted by Completion Time	Naoki Yokoyama, Sehoon Ha, Dhruv Batra	navigation 評価で、成功だけでなく完了時間・動力学を考慮する指標を提案。評価指標設計の参考。
Why Should I Trust You, Bellman? The Bellman Error is a Poor Replacement for Value Error	Scott Fujimoto, David Meger, Doina Precup, Ofir Nachum, Shixiang Gu	Bellman error が value error の十分な代理にならないことを指摘。評価代理指標の危険性を示す。
Position: Benchmarking is Limited in Reinforcement Learning Research	Scott M. Jordan et al.	RL benchmarking は「誰が勝つか」は示せても「なぜ勝つか」は示しにくいと論じる。診断型研究の正当化に使える。
MIRA: Memory-Integrated RL Agent with Limited LLM Guidance	Narjes Nourzad, Carlee Joe-Wong	LLM ガイダンスを memory graph へ償却し、疎報酬 RL の初期学習を支援する。近年の LLM×RL 文献。
Understanding Reasoning Collapse in Multi-Turn Agent RL	Zihan Wang et al.	multi-turn LLM agent RL で、見かけの多様性が残っても入力非依存テンプレートへ崩れる現象を扱う。
Practical Applications of Bsuite for Reinforcement Learning	Loren Anderson, Bittner	bsuite の実践的利用を解説する ICLR Blogpost。制御実験を説明する補助資料として有用。