

方策勾配法： θ が 2 つの場合の勾配更新と軌跡データからの更新

会話ログ（数式保持版）

2026-05-28

目次

1	方策勾配法： θ が 2 つの場合の勾配更新と軌跡データからの更新	1
1.1	User	1
1.2	Assistant	1
1.3	あなたの現在の理解	1
1.4	賛成論：方策勾配法は「見えない山を傾きで登る」方法	2
1.5	ただし危ない点：実際には「傾き」すら直接見えていない	2
1.6	もう少し RL っぽく言うと	3
1.7	隠れた前提	3
1.7.1	1. θ が 1 次元である	4
1.7.2	2. 傾きが正確にわかる	4
1.7.3	3. 傾き方向に進めば必ずよくなる	4
1.8	より正確なスキーマ	5
1.9	具体的な次の理解ポイント	5
1.10	User	5
1.11	Assistant	5
1.12	User	5
1.13	Assistant	7
2	1. 図 1：まず $f(\theta_1, \theta_2)$ を山として見る	7
3	2. 図 3： θ_1 方向の傾きを見る	8
3.1	θ_1 方向の傾き	8
4	3. 図 4： θ_2 方向の傾きを見る	9
4.1	θ_2 方向の傾き	10
5	4. 図 5：2 つの傾きをまとめる	10
6	5. 更新する	11
7	6. 更新後、本当に上がったか確認する	12
8	7. もう 1 回更新してみる	13

9 8. 図 2 の等高線で見ると何が起きているか	14
10 9. 成分ごとの意味	15
11 10. 方策勾配法に戻すと何が違うか	16
12 11. では方策勾配法では何を「計算」しているのか	17
13 12. まとめと	17
13.1 User	18
13.2 Assistant	19
14 1. 何がズレていたか	19
15 2. 図の正しい読み替え	20
15.1 図 1：山として見る	20
15.2 図 2：等高線	20
15.3 図 3・図 4： θ_1, θ_2 方向の傾き	20
16 3. 軌跡データから更新する具体例	21
17 4. 軌跡データを集める	22
18 5. 「その行動を出しやすくする方向」を計算する	22
19 6. 今回の softmax での勾配	23
20 7. 軌跡データを使って勾配推定する	23
21 8. これを図 5 に対応させる	24
22 9. 更新する	25
23 10. 更新後、方策はどう変わるか	26
24 11. ここで山頂は一切使っていない	27
25 12. 図でいうと、こう読み替えるべき	27
26 13. より正確なスキーマ	28
26.1 User	28
26.2 Assistant	28
27 1. 前提： θ_1, θ_2 は「A/B の出やすさ」	28
28 2. なぜ $\nabla_{\theta} \log \pi_{\theta}(A) = (0.5, -0.5)$ になるのか	29
28.1 θ_1 方向の微分	30
28.2 θ_2 方向の微分	31
28.3 まとめと	31
29 3. B の場合も同じ	32
30 4. ここまでの直感	33

31 5. 次に、軌跡データを使う	33
31.1 τ_1 : A を選んで、収益 1	33
31.2 τ_2 : B を選んで、収益 0	34
31.3 τ_3 : A を選んで、収益 1	34
31.4 τ_4 : A を選んで、収益 1	34
32 6. 全部足す	35
33 7. 4 本で平均する	35
34 8. この計算の意味	35
35 9. 超要約すると	36

1 方策勾配法： θ が 2 つの場合の勾配更新と軌跡データからの更新

この PDF は、方策勾配法に関する会話を、数式が崩れないように LaTeX 形式で組版したものです。

1.1 User

方策勾配法がやってるのって、つまり、こういうことかな。つまり、横軸 θ 、縦軸 $f(\theta)$ のグラフがあったとする。ここで $f(\theta)$ は、パラメータ θ 時の方策 π_θ で動いた時の期待収益。で、横軸 θ 、縦軸 $f(\theta)$ のグラフの形の全体像が既知であれば、グラフのうち $f(\theta)$ の最大値となるような θ を目視で探せば良いのだけでも、当然、グラフの形は見えない。見えるのは、今の θ におけるグラフの傾きだけ。その時に、傾きでより $f(\theta)$ が高くなる方向に少し θ をずらすということ。

1.2 Assistant

概ねその理解で合っている。

ただし、「見えるのは今の θ における傾きだけ」という部分は、方策勾配法では少しだけ補正が必要。

1.3 あなたの現在の理解

あなたの言い方で整理すると、こう。

- 横軸：方策パラメータ θ
- 縦軸：その θ の方策で動いたときの期待収益

$$f(\theta) = J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[G(\tau)]$$

理想的には、このグラフ全体が見えていれば、

一番高い場所にある θ を選べばいい

となる。

でも実際には、グラフ全体は見えない。

だから、今いる θ の近くで、

右に少し動かしたら上がりそうか？
左に少し動かしたら上がりそうか？

を見て、期待収益が増えそうな方向へ θ を少し更新する。
これはかなり本質を掴んでいる。

1.4 賛成論：方策勾配法は「見えない山を傾きで登る」方法

1次元の θ なら、かなり直感的にこうなる。

$$\theta \leftarrow \theta + \alpha \frac{dJ(\theta)}{d\theta}$$

- 傾きがプラス
→ θ を増やす方向に進む
→ 右へ動く
- 傾きがマイナス
→ θ を減らす方向に進む
→ 左へ動く
- 傾きがゼロ付近
→ そこが山頂・谷底・平坦地かもしれない

つまり、方策勾配法は「期待収益 $J(\theta)$ を直接最大化したいが、全体図が見えないので、局所的な傾きだけを頼りに θ を動かす」方法と言ってよい。

これは普通の勾配上昇と同じ構造。

1.5 ただし危ない点：実際には「傾き」すら直接見えていない

ここが重要。

あなたの説明では、

見えるのは、今の θ におけるグラフの傾きだけ

となっている。

でも強化学習では、実際には **傾きそのものも直接は見えない**。

見えるのはもっと粗い。

今の方策 π_θ で何回かエピソードを走らせたときの、状態・行動・報酬のサンプルだけ。

そこから、

$$\nabla_\theta J(\theta)$$

を推定している。

だから正確にはこう。

グラフ全体は見えない。

さらに、今の地点の正確な傾きも見えない。

見えるのは、今の θ で動いたときのサンプル軌跡と報酬だけ。

そのサンプルから「たぶんこっちに動かせば期待収益が上がるだろう」という傾きを推定して θ を更新する。

ここが普通の微分問題との大きな違い。

1.6 もう少し RL っぽく言うと

方策勾配法は、

良い結果につながった行動を、その状態で今後もっと出やすくする

悪い結果につながった行動を、その状態で今後出にくくする

という処理を、 θ の更新としてやっている。

REINFORCE なら、だいたいこういう更新になる。

$$\theta \leftarrow \theta + \alpha \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t$$

意味はこう。

- $\pi_{\theta}(a_t | s_t)$
→ 状態 s_t で行動 a_t を選ぶ確率
- $\log \pi_{\theta}(a_t | s_t)$ の勾配
→ その行動をもっと選びやすくするには θ をどう動かせばいいか
- G_t
→ その後どれくらい良い結果になったか

だから、

- G_t が大きい
→ その行動を選びやすくする方向に θ を動かす
- G_t が小さい、またはベースラインより悪い
→ その行動を選びにくくする方向に θ を動かす

ということをしている。

1.7 隠れた前提

あなたの理解には、いくつかの前提が隠れている。

1.7.1 1. θ が1次元である

説明としては正しい。

ただし実際のニューラルネット方策では、 θ は数千、数万、数百万次元ある。

だから実際には、

横軸 θ 、縦軸 $J(\theta)$

という 2D グラフではなく、

超高次元空間の中で、期待収益が高くなる方向へ進む

という感じ。

1次元では「右か左」だが、多次元では、

$$\nabla_{\theta} J(\theta)$$

というベクトルが、最も急に期待収益が増えそうな方向を示す。

1.7.2 2. 傾きが正確にわかる

これも実際には違う。

RL ではサンプルから推定するので、勾配はノイズを含む。

だから、方策勾配法はしばしば、

霧の中で、足元の傾斜をノイズ混じりに測りながら山を登る

に近い。

しかも、1回のエピソードがたまたま良かっただけかもしれない。

だから複数エピソードを集めたり、ベースラインを引いたり、Advantage を使ったり、PPO のように更新幅を制限したりする。

1.7.3 3. 傾き方向に進めば必ずよくなる

小さく進めば改善する可能性は高いが、必ずではない。

理由はある。

- 勾配推定がノイズを含む
- 学習率が大きすぎると飛びすぎる
- 局所最適にハマる
- 方策を少し変えたつもりでも、行動分布が大きく変わる場合がある
- 環境の確率性で、良し悪しの評価がブレる

だから PPO では、

良い方向に更新したいが、一気に方策を変えすぎると壊れる

という問題に対処している。

1.8 より正確なスキーマ

あなたの理解を一段だけ精密化すると、こう。

方策勾配法は、方策パラメータ θ によって決まる期待収益 $J(\theta)$ を最大化したい。
しかし $J(\theta)$ の全体像は見えないし、正確な勾配も直接は見えない。
そこで、現在の方策でサンプル軌跡を集め、その軌跡の報酬から「どの行動確率を上げれば期待収益が上がりそうか」を推定し、その方向に θ を少し更新する。
これは、見えない山を、ノイズ混じりの局所的な傾きだけで登る方法である。

この理解でよい。

1.9 具体的な次の理解ポイント

次に腹落ちさせるなら、順番はこれがよい。

1. 1次元の θ で、 $J(\theta)$ の山を登るイメージ
 - ・これは普通の勾配上昇
2. θ が方策の行動確率を変えるというイメージ
 - ・ θ を増やすと右に行く確率が上がる、など
3. 良い報酬が出た行動の確率を上げる
 - ・これが $\nabla_{\theta} \log \pi_{\theta}(a|s)G$
4. ただし報酬が大きいだけでは雑なので、平均との差を見る
 - ・これがベースラインやアドバンテージ
5. 更新しすぎると方策が壊れる
 - ・これが PPO のクリップの動機

結論として、君の説明はほぼ正しい。
ただし一番大事な修正はこれ。

方策勾配法は「今の θ での傾きが見えている」のではなく、
「今の θ で試した経験から、傾きを推定している」。

1.10 User

θ が2つの場合の、勾配計算して更新するイメージを掴みたい。グラフをふんだんに使ってグラフィカルに理解できないか？

1.11 Assistant

1.12 User

計算の過程をその図を使って解説してください。

θが2つあるときの勾配更新のイメージ

方策勾配法の直感: $f(\theta_1, \theta_2) = J(\theta_1, \theta_2)$ を大きくする方向へ少しずつ進む




図 1: θ が 2 つあるときの勾配更新のイメージ

1.13 Assistant

図の各パネルに対応させて、今回は「本当の RL」ではなく、まず計算できる玩具関数で手計算します。その後で方策勾配法では何が違うかに戻します。

はい。図の流れに沿って、 θ が 2 つある場合に、どう勾配を計算して更新するのかを手で追います。

今回は説明用に、期待収益の関数を仮にこう置きます。

$$f(\theta_1, \theta_2) = -(\theta_1 - 3)^2 - (\theta_2 - 2)^2 + 10$$

これは、山頂が

$$(\theta_1, \theta_2) = (3, 2)$$

にある山です。

つまり図でいうと、赤い山頂付近が $(3, 2)$ だと思ってください。

2 1. 図 1：まず $f(\theta_1, \theta_2)$ を山として見る

図 1 では、横方向に θ_1 、奥行き方向に θ_2 、高さ方向に

$$f(\theta_1, \theta_2) = J(\theta_1, \theta_2)$$

があります。

今、現在地をこうします。

$$\theta^{(0)} = (\theta_1, \theta_2) = (1, 1)$$

このときの高さ、つまり期待収益は、

$$f(1, 1) = -(1 - 3)^2 - (1 - 2)^2 + 10$$

$$= -4 - 1 + 10 = 5$$

つまり現在地の期待収益は

$$J(\theta) = 5$$

です。

図で言えば、まだ山頂ではなく、山の斜面にいる状態です。

3 2. 図 3 : θ_1 方向の傾きを見る

図 3 は、

θ_2 を固定して、 θ_1 だけ少し動かしたら f がどう変わるか
を見ています。

今は

$$(\theta_1, \theta_2) = (1, 1)$$

なので、 $\theta_2 = 1$ に固定します。

元の関数は

$$f(\theta_1, \theta_2) = -(\theta_1 - 3)^2 - (\theta_2 - 2)^2 + 10$$

ここで $\theta_2 = 1$ を固定すると、

$$f(\theta_1, 1) = -(\theta_1 - 3)^2 - (1 - 2)^2 + 10$$

$$= -(\theta_1 - 3)^2 - 1 + 10$$

$$= -(\theta_1 - 3)^2 + 9$$

これは、 θ_1 だけを横軸にした断面図です。

図 3 の青い曲線がこれです。

3.1 θ_1 方向の傾き

$$\frac{\partial f}{\partial \theta_1}$$

を計算します。

$$f(\theta_1, \theta_2) = -(\theta_1 - 3)^2 - (\theta_2 - 2)^2 + 10$$

なので、

$$\frac{\partial f}{\partial \theta_1} = -2(\theta_1 - 3)$$

現在地では $\theta_1 = 1$ なので、

$$\frac{\partial f}{\partial \theta_1} = -2(1 - 3) = -2(-2) = 4$$

つまり、

$$\frac{\partial f}{\partial \theta_1} = 4$$

です。

これは図 3 でいうと、

現在地での接線の傾きがプラス

ということです。

だから、

$$\theta_1$$

を増やすと、期待収益 f は増えそう、という意味になります。

4 3. 図 4 : θ_2 方向の傾きを見る

次に図 4 です。

図 4 は、

θ_1 を固定して、 θ_2 だけ少し動かしたら f がどう変わるか
を見ています。

今は

$$(\theta_1, \theta_2) = (1, 1)$$

なので、 $\theta_1 = 1$ に固定します。

$$f(1, \theta_2) = -(1 - 3)^2 - (\theta_2 - 2)^2 + 10$$

$$= -4 - (\theta_2 - 2)^2 + 10$$

$$= -(\theta_2 - 2)^2 + 6$$

これが図 4 の紫の断面図です。

4.1 θ_2 方向の傾き

$$\frac{\partial f}{\partial \theta_2}$$

を計算します。

$$f(\theta_1, \theta_2) = -(\theta_1 - 3)^2 - (\theta_2 - 2)^2 + 10$$

なので、

$$\frac{\partial f}{\partial \theta_2} = -2(\theta_2 - 2)$$

現在地では $\theta_2 = 1$ なので、

$$\frac{\partial f}{\partial \theta_2} = -2(1 - 2) = -2(-1) = 2$$

つまり、

$$\frac{\partial f}{\partial \theta_2} = 2$$

です。

これは図 4 でいうと、

θ_2 方向にも、まだ上り坂である

ということです。

5 4. 図 5 : 2 つの傾きをまとめる

ここまでで、2 つの傾きが出ました。

$$\frac{\partial f}{\partial \theta_1} = 4$$

$$\frac{\partial f}{\partial \theta_2} = 2$$

この 2 つをまとめたものが勾配です。

$$\nabla f(\theta) = \left(\frac{\partial f}{\partial \theta_1}, \frac{\partial f}{\partial \theta_2} \right)$$

したがって、現在地 $(1, 1)$ では、

$$\nabla f(1, 1) = (4, 2)$$

です。

図 5 でいうと、

- ・ 赤い横矢印： θ_1 方向に 4
- ・ 紫の縦矢印： θ_2 方向に 2
- ・ 青い斜め矢印：それらを合成した $(4, 2)$

です。

つまり、

θ_1 方向に強く増やし、 θ_2 方向にも少し増やすと、 f が上がりやすい
ということです。

6 5. 更新する

方策勾配法は、期待収益を**最大化**したいので、勾配上昇をします。

$$\theta \leftarrow \theta + \alpha \nabla f(\theta)$$

ここで α は学習率です。

今回は仮に、

$$\alpha = 0.1$$

とします。

現在地は

$$\theta^{(0)} = (1, 1)$$

勾配は

$$\nabla f(1, 1) = (4, 2)$$

なので、

$$\theta^{(1)} = (1, 1) + 0.1(4, 2)$$

$$= (1, 1) + (0.4, 0.2)$$

$$= (1.4, 1.2)$$

つまり更新後は、

$$\theta^{(1)} = (1.4, 1.2)$$

になります。

図 6 でいうと、黒点が

$$\theta^{(0)}$$

から

$$\theta^{(1)}$$

へ少し進んだ状態です。

7 6. 更新後、本当に上がったか確認する

更新前は

$$f(1, 1) = 5$$

でした。

更新後の

$$(1.4, 1.2)$$

での値を計算します。

$$f(1.4, 1.2) = -(1.4 - 3)^2 - (1.2 - 2)^2 + 10$$

$$= -(-1.6)^2 - (-0.8)^2 + 10$$

$$= -2.56 - 0.64 + 10$$

$$= 6.8$$

つまり、

$$5 \rightarrow 6.8$$

に上がりました。

期待収益が増えています。

8 7. もう1回更新してみる

次の現在地は

$$\theta^{(1)} = (1.4, 1.2)$$

です。

また勾配を計算します。

$$\frac{\partial f}{\partial \theta_1} = -2(\theta_1 - 3)$$

$$= -2(1.4 - 3) = -2(-1.6) = 3.2$$

$$\frac{\partial f}{\partial \theta_2} = -2(\theta_2 - 2)$$

$$= -2(1.2 - 2) = -2(-0.8) = 1.6$$

したがって、

$$\nabla f(1.4, 1.2) = (3.2, 1.6)$$

また学習率 $\alpha = 0.1$ で更新すると、

$$\theta^{(2)} = (1.4, 1.2) + 0.1(3.2, 1.6)$$

$$= (1.4, 1.2) + (0.32, 0.16)$$

$$= (1.72, 1.36)$$

更新後の値は、

$$f(1.72, 1.36) = -(1.72 - 3)^2 - (1.36 - 2)^2 + 10$$

$$= -(-1.28)^2 - (-0.64)^2 + 10$$

$$= -1.6384 - 0.4096 + 10$$

$$= 7.952$$

つまり、

$$5 \rightarrow 6.8 \rightarrow 7.952$$

と上がっています。

これが図 6 の、

$$\theta^{(0)} \rightarrow \theta^{(1)} \rightarrow \theta^{(2)} \rightarrow \theta^{(3)} \rightarrow \dots$$

のイメージです。

9 8. 図 2 の等高線で見ると何が起きているか

図 2・図 6 の等高線で見ると、今やっていることはこうです。

現在地：

$$(1, 1)$$

勾配：

$$(4, 2)$$

なので、右上方向へ進みます。

ただし、右上なら何でもいいわけではありません。

$$(4, 2)$$

という勾配は、

θ_1 方向には強く進め

θ_2 方向にはその半分くらい進め

という指示です。

だから更新量は、

$$(0.4, 0.2)$$

になります。

図でいうと、

- ・ 真右ではない
- ・ 真上でもない
- ・ 斜め右上
- ・ ただし θ_1 成分のほうが大きい

という進み方です。

10 9. 成分ごとの意味

今回の更新は、

$$\theta_1 \leftarrow \theta_1 + \alpha \frac{\partial f}{\partial \theta_1}$$

$$\theta_2 \leftarrow \theta_2 + \alpha \frac{\partial f}{\partial \theta_2}$$

でした。

数値を入れると、

$$\theta_1 \leftarrow 1 + 0.1 \times 4 = 1.4$$

$$\theta_2 \leftarrow 1 + 0.1 \times 2 = 1.2$$

つまり、

パラメータ	傾き	更新方向	更新後
θ_1	+4	増やす	1 → 1.4
θ_2	+2	増やす	1 → 1.2

両方プラスなので、両方増やす。

ただし、 θ_1 の傾きのほうが大きいので、 θ_1 のほうを大きく動かす。

これが図5のベクトル分解です。

11 10. 方策勾配法に戻すと何が違うか

ここまでは、説明用に

$$f(\theta_1, \theta_2) = -(\theta_1 - 3)^2 - (\theta_2 - 2)^2 + 10$$

という関数をこちらで勝手に決めました。

だから、

$$\frac{\partial f}{\partial \theta_1}$$

$$\frac{\partial f}{\partial \theta_2}$$

を普通に計算できました。

しかし、実際の方策勾配法では、これはできません。

なぜなら、

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [G(\tau)]$$

の形は、明示的な関数として見えていないからです。

つまり、実際には、

$$J(\theta_1, \theta_2) = ?$$

です。

図1の山そのものは見えません。

図2の等高線も見えません。

図3・図4の本当の接線も直接は見えません。

見えるのは、

今の方策 π_θ で動かしてみた結果、どの行動を取って、どれくらい報酬が出たかだけです。

12 11. では方策勾配法では何を「計算」しているのか

方策勾配法では、本当の

$$\nabla J(\theta)$$

を直接計算する代わりに、サンプル軌跡から推定します。

REINFORCE なら、だいたいこうです。

$$\nabla_{\theta} J(\theta) \approx \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t$$

この意味は、

その状態でその行動をもっと出しやすくするには、 θ_1, θ_2 をどう動かせばいいか
その行動のあとに得られた収益 G_t は良かったか
良かったなら、その行動の確率を上げる方向に動かす

ということです。

θ が 2 つなら、

$$\nabla_{\theta} J(\theta)$$

はこういう形になります。

$$\nabla_{\theta} J(\theta) = \left(\frac{\partial J}{\partial \theta_1}, \frac{\partial J}{\partial \theta_2} \right)$$

つまり方策勾配法でも、最終的には図 5 と同じく、

「 θ_1 方向の更新量, θ_2 方向の更新量」

を作っています。

違いは、

普通関数なら微分して勾配を出す
方策勾配法ではエピソードのサンプルから勾配を推定する

という点です。

13 12. まとめると

図に対応させると、計算の流れはこうです。

図	やっていること	計算
図 1	$J(\theta_1, \theta_2)$ を山として見る	高さが期待収益
図 2	上から見て、どちらに進めば高くなるか見る	等高線と勾配方向
図 3	θ_1 方向の傾きを見る	$\frac{\partial f}{\partial \theta_1}$
図 4	θ_2 方向の傾きを見る	$\frac{\partial f}{\partial \theta_2}$
図 5	2 つの傾きを合体させる	$\nabla f(\theta) = \left(\frac{\partial f}{\partial \theta_1}, \frac{\partial f}{\partial \theta_2} \right)$
図 6	勾配方向へ少し動く	$\theta \leftarrow \theta + \alpha \nabla f(\theta)$

今回の数値例では、

$$\theta^{(0)} = (1, 1)$$

$$\nabla f(1, 1) = (4, 2)$$

$$\alpha = 0.1$$

なので、

$$\theta^{(1)} = (1, 1) + 0.1(4, 2) = (1.4, 1.2)$$

となる。

その結果、

$$f(1, 1) = 5$$

から

$$f(1.4, 1.2) = 6.8$$

へ増えた。

これが、 θ が 2 つあるときの勾配更新の計算過程です。

13.1 User

山の山頂がわかっている前提で計算しているのはおかしくないか。集めた奇跡データから更新するんじゃないの？

13.2 Assistant

その指摘は正しいです。前の数値例は「勾配上昇そのもの」を見せるための玩具関数で、方策勾配法の実処理としては不十分でした。ここでは軌跡データから更新量を作る形に置き換えます。

その指摘は正しいです。

前の説明は、厳密には「方策勾配法そのもの」ではなく、

既知の関数 $f(\theta_1, \theta_2)$ があると仮定したときの勾配上昇
でした。

方策勾配法の本体は、君の言う通り、

山頂も、山の形も、真の勾配もわからない。

集めた軌跡データから「たぶんこっちに動かすと期待収益が上がる」という更新方向を
推定する。

です。

14 1. 何がズレていたか

前回の玩具例では、

$$f(\theta_1, \theta_2) = -(\theta_1 - 3)^2 - (\theta_2 - 2)^2 + 10$$

みたいな関数をこちらで勝手に置きました。

この場合、

$$\frac{\partial f}{\partial \theta_1}, \quad \frac{\partial f}{\partial \theta_2}$$

を普通に計算できる。

でも実際の方策勾配では、

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [G(\tau)]$$

の形は見えていません。

つまり、実際にはこうです。

理想化された勾配上昇	方策勾配法
山の式 $f(\theta)$ がわかっている	山の式 $J(\theta)$ はわからない
微分して真の勾配を出す	軌跡データから勾配を推定する
山頂の位置も説明上はわかっている	山頂はまったくわからない
更新方向は正確	更新方向はノイズ混じり

だから、君の違和感は正しい。

15 2. 図の正しい読み替え

あの図を方策勾配法として正しく読むなら、こうです。

15.1 図1：山として見る

これはあくまで概念図です。

$$J(\theta_1, \theta_2)$$

という期待収益の山が「存在する」と考える。

ただし、実際にはその山は見えない。

15.2 図2：等高線

これも概念図です。

本当は等高線も見えません。

見えているのは、

今の θ で何回か動かした結果の軌跡と報酬
だけです。

15.3 図3・図4： θ_1, θ_2 方向の傾き

ここが重要。

実際の方策勾配法では、

$$\frac{\partial J}{\partial \theta_1}$$

$$\frac{\partial J}{\partial \theta_2}$$

を直接計算しているわけではありません。

軌跡データから、

$$\widehat{\frac{\partial J}{\partial \theta_1}}, \quad \widehat{\frac{\partial J}{\partial \theta_2}}$$

を推定しています。

つまり図 3・図 4 の接線は、実際には

本物の接線ではなく、軌跡データから推定した「たぶんこの向き」
です。

16 3. 軌跡データから更新する具体例

かなり単純化した例でいきます。

状態は 1 つだけ。

行動は 2 つ。

- 行動 A
- 行動 B

方策は、2 つのパラメータで決まるとします。

$$\theta = (\theta_1, \theta_2)$$

θ_1 は行動 A を出しやすくするパラメータ、
 θ_2 は行動 B を出しやすくするパラメータだと思ってください。

方策は softmax で、

$$\pi_{\theta}(A) = \frac{e^{\theta_1}}{e^{\theta_1} + e^{\theta_2}}$$

$$\pi_{\theta}(B) = \frac{e^{\theta_2}}{e^{\theta_1} + e^{\theta_2}}$$

とします。

最初は、

$$\theta = (0, 0)$$

です。

このとき、

$$\pi_{\theta}(A) = 0.5$$

$$\pi_{\theta}(B) = 0.5$$

つまり A も B も半々で出ます。

17 4. 軌跡データを集める

今の方策で4回試したとします。

軌跡	選んだ行動	収益 G
τ_1	A	1
τ_2	B	0
τ_3	A	1
τ_4	A	1

ここで重要なのは、山頂を知っているわけではないことです。

ただ、

今の方策で試したら、Aを選んだ回は報酬が良く、Bを選んだ回は報酬が悪かったというデータが得られただけです。

18 5. 「その行動を出しやすくする方向」を計算する

REINFORCE では、だいたい次の形で更新方向を作ります。

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \nabla_{\theta} \log \pi_{\theta}(a_i | s_i) G_i$$

意味はこうです。

$$\nabla_{\theta} \log \pi_{\theta}(a_i | s_i)$$

は、

その行動 a_i をもっと出しやすくするには、 θ をどちらに動かせばいいかを表します。

そこに

$$G_i$$

を掛けます。

つまり、

良い収益につながった行動なら、その行動をもっと出しやすくする
悪い収益なら、あまり強化しない

という処理です。

19 6. 今回の softmax での勾配

今は

$$\theta = (0, 0)$$

なので、

$$\pi(A) = 0.5, \quad \pi(B) = 0.5$$

です。

このとき、行動 A を選んだ場合、

$$\nabla_{\theta} \log \pi_{\theta}(A) = (0.5, -0.5)$$

です。

これは、

A をもっと出しやすくするには、 θ_1 を上げて、 θ_2 を下げる
という意味です。

一方、行動 B を選んだ場合、

$$\nabla_{\theta} \log \pi_{\theta}(B) = (-0.5, 0.5)$$

です。

これは、

B をもっと出しやすくするには、 θ_1 を下げて、 θ_2 を上げる
という意味です。

20 7. 軌跡データを使って勾配推定する

さっきの軌跡データはこれでした。

軌跡	行動	収益 G	$\nabla_{\theta} \log \pi_{\theta}(a)$
τ_1	A	1	$(0.5, -0.5)$
τ_2	B	0	$(-0.5, 0.5)$
τ_3	A	1	$(0.5, -0.5)$

軌跡	行動	収益 G	$\nabla_{\theta} \log \pi_{\theta}(a)$
τ_4	A	1	$(0.5, -0.5)$

REINFORCE の推定勾配は、

$$\hat{g} = \frac{1}{4}[(0.5, -0.5) \cdot 1 + (-0.5, 0.5) \cdot 0 + (0.5, -0.5) \cdot 1 + (0.5, -0.5) \cdot 1]$$

B を選んだ 2 本目は報酬が 0 なので、更新にはほぼ効きません。

$$\hat{g} = \frac{1}{4}[(0.5, -0.5) + (0, 0) + (0.5, -0.5) + (0.5, -0.5)]$$

$$= \frac{1}{4}(1.5, -1.5)$$

$$= (0.375, -0.375)$$

つまり、軌跡データから得られた推定勾配は、

$$\hat{g} = (0.375, -0.375)$$

です。

21 8. これを図 5 に対応させる

図 5 では、

$$\nabla f(\theta) = \left(\frac{\partial f}{\partial \theta_1}, \frac{\partial f}{\partial \theta_2} \right)$$

となっていました。

方策勾配法では、ここがこう置き換わります。

$$\nabla J(\theta)$$

ではなく、

$$\hat{g} \approx \nabla J(\theta)$$

を使います。

今回なら、

$$\hat{g} = (0.375, -0.375)$$

です。

つまり図 5 の青い矢印は、実際には

軌跡データから作った推定ベクトル

です。

22 9. 更新する

学習率を仮に

$$\alpha = 0.4$$

とします。

更新式は、

$$\theta \leftarrow \theta + \alpha \hat{g}$$

です。

今、

$$\theta = (0, 0)$$

$$\hat{g} = (0.375, -0.375)$$

なので、

$$\theta' = (0, 0) + 0.4(0.375, -0.375)$$

$$= (0.15, -0.15)$$

つまり、

$$\theta_1 : 0 \rightarrow 0.15$$

$$\theta_2 : 0 \rightarrow -0.15$$

です。

23 10. 更新後、方策はどう変わるか

更新前は、

$$\pi(A) = 0.5$$

$$\pi(B) = 0.5$$

でした。

更新後は、

$$\theta = (0.15, -0.15)$$

なので、

$$\pi(A) = \frac{e^{0.15}}{e^{0.15} + e^{-0.15}}$$

だいたい、

$$\pi(A) \approx 0.574$$

になります。

$$\pi(B) \approx 0.426$$

です。

つまり、

行動	更新前	更新後
A	0.500	0.574
B	0.500	0.426

こうなります。

つまり、軌跡データから見て良さそうだった A の確率が上がり、悪そうだった B の確率が下がった。
これが方策勾配法の更新です。

24 11. ここで山頂は一切使っていない

この計算では、山頂は使っていません。

使ったのはこれだけです。

1. 今の方策パラメータ

$$\theta = (0, 0)$$

2. 今の方策で集めた軌跡データ

$$(A, 1), (B, 0), (A, 1), (A, 1)$$

3. その行動を出しやすくする方向

$$\nabla_{\theta} \log \pi_{\theta}(a)$$

4. 収益

$$G$$

この4つから、

$$\hat{g} = (0.375, -0.375)$$

を作って、

$$\theta \leftarrow \theta + \alpha \hat{g}$$

で更新しています。

25 12. 図でいうと、こう読み替えるべき

あの図を実際の方策勾配法に対応させるなら、こうです。

図	素朴な説明	方策勾配法での正しい意味
図 1	期待収益の山がある	山は存在するが見えない
図 2	等高線が見える	等高線も見えない
図 3	θ_1 方向の傾きがわかる	軌跡から θ_1 方向の傾きを推定する
図 4	θ_2 方向の傾きがわかる	軌跡から θ_2 方向の傾きを推定する
図 5	真の勾配を作る	推定勾配 $\hat{g}$ を作る
図 6	山頂へ進む	推定方向に少し進む。山頂に近づいている保証は弱い

26 13. より正確なスキーマ

前回の説明を修正すると、こうです。

方策勾配法では、期待収益 $J(\theta)$ の山が背後にあると考える。
しかし、山の形も山頂も真の傾きも見えない。
見えるのは、現在の方策 π_θ で集めた軌跡と報酬だけ。
その軌跡から、「どの行動の確率を上げると収益が上がりそうか」を計算し、 $\nabla J(\theta)$ の推定値 $\hat{g}$ を作る。
そして、 $\theta \leftarrow \theta + \alpha \hat{g}$ で少しだけ更新する。

だから、君の言い方で言えば、

山を見て登っているのではなく、足元で何回か試して、「たぶんこっちが上り坂」と推定して進んでいる

がかなり近いです。

26.1 User

ここの計算がわからん

26.2 Assistant

わからない核はたぶん2つです。ひとつは「なぜAを選んだとき $(0.5, -0.5)$ になるのか」、もうひとつは「なぜそれを報酬で掛けて平均するのか」です。順に潰します。

ここはかなり重要です。

まず、問題の計算はこの2段階です。

1. softmax 方策で、行動 A/B を出しやすくする方向を計算する
 2. 軌跡データの報酬 G を掛けて、平均する
-

27 1. 前提： θ_1, θ_2 は「A/B の出やすさ」

今回はこういう方策でした。

$$\pi_\theta(A) = \frac{e^{\theta_1}}{e^{\theta_1} + e^{\theta_2}}$$

$$\pi_\theta(B) = \frac{e^{\theta_2}}{e^{\theta_1} + e^{\theta_2}}$$

意味はこうです。

パラメータ	意味
θ_1	A の出やすさ
θ_2	B の出やすさ

最初は、

$$\theta = (0, 0)$$

なので、

$$e^{\theta_1} = e^0 = 1$$

$$e^{\theta_2} = e^0 = 1$$

したがって、

$$\pi(A) = \frac{1}{1+1} = 0.5$$

$$\pi(B) = \frac{1}{1+1} = 0.5$$

A も B も半々です。

28 2. なぜ $\nabla_{\theta} \log \pi_{\theta}(A) = (0.5, -0.5)$ になるのか

まず、

$$\log \pi_{\theta}(A)$$

を計算します。

$$\pi_{\theta}(A) = \frac{e^{\theta_1}}{e^{\theta_1} + e^{\theta_2}}$$

なので、

$$\log \pi_{\theta}(A) = \log \frac{e^{\theta_1}}{e^{\theta_1} + e^{\theta_2}}$$

分数の log は、

$$\log \frac{x}{y} = \log x - \log y$$

なので、

$$\log \pi_{\theta}(A) = \log e^{\theta_1} - \log(e^{\theta_1} + e^{\theta_2})$$

$$= \theta_1 - \log(e^{\theta_1} + e^{\theta_2})$$

ここから、 θ_1 と θ_2 でそれぞれ微分します。

28.1 θ_1 方向の微分

$$\log \pi_{\theta}(A) = \theta_1 - \log(e^{\theta_1} + e^{\theta_2})$$

これを θ_1 で微分すると、

$$\frac{\partial}{\partial \theta_1} \log \pi_{\theta}(A) = 1 - \frac{e^{\theta_1}}{e^{\theta_1} + e^{\theta_2}}$$

右側の分数は、

$$\pi_{\theta}(A)$$

そのものです。

だから、

$$\frac{\partial}{\partial \theta_1} \log \pi_{\theta}(A) = 1 - \pi_{\theta}(A)$$

今は、

$$\pi_{\theta}(A) = 0.5$$

なので、

$$1 - \pi_{\theta}(A) = 1 - 0.5 = 0.5$$

つまり、

θ_1 方向の成分は 0.5 です。

です。

28.2 θ_2 方向の微分

同じく、

$$\log \pi_{\theta}(A) = \theta_1 - \log(e^{\theta_1} + e^{\theta_2})$$

これを θ_2 で微分します。

θ_1 は θ_2 から見ると定数なので、微分すると 0 です。

$$\frac{\partial}{\partial \theta_2} \log \pi_{\theta}(A) = 0 - \frac{e^{\theta_2}}{e^{\theta_1} + e^{\theta_2}}$$

右側の分数は、

$$\pi_{\theta}(B)$$

です。

だから、

$$\frac{\partial}{\partial \theta_2} \log \pi_{\theta}(A) = -\pi_{\theta}(B)$$

今は、

$$\pi_{\theta}(B) = 0.5$$

なので、

$$-\pi_{\theta}(B) = -0.5$$

したがって、

θ_2 方向の成分は -0.5 です。

です。

28.3 まとめると

$$\nabla_{\theta} \log \pi_{\theta}(A) = \left(\frac{\partial}{\partial \theta_1} \log \pi_{\theta}(A), \frac{\partial}{\partial \theta_2} \log \pi_{\theta}(A) \right)$$

なので、

$$\nabla_{\theta} \log \pi_{\theta}(A) = (0.5, -0.5)$$

になります。

意味は、

A の確率を上げたいなら、 θ_1 を上げて、 θ_2 を下げる
です。

29 3. B の場合も同じ

B については、

$$\pi_{\theta}(B) = \frac{e^{\theta_2}}{e^{\theta_1} + e^{\theta_2}}$$

なので、

$$\log \pi_{\theta}(B) = \theta_2 - \log(e^{\theta_1} + e^{\theta_2})$$

これを微分すると、

$$\frac{\partial}{\partial \theta_1} \log \pi_{\theta}(B) = -\frac{e^{\theta_1}}{e^{\theta_1} + e^{\theta_2}} = -\pi_{\theta}(A)$$

$$\frac{\partial}{\partial \theta_2} \log \pi_{\theta}(B) = 1 - \frac{e^{\theta_2}}{e^{\theta_1} + e^{\theta_2}} = 1 - \pi_{\theta}(B)$$

今は、

$$\pi(A) = 0.5, \quad \pi(B) = 0.5$$

なので、

$$\nabla_{\theta} \log \pi_{\theta}(B) = (-0.5, 0.5)$$

になります。

意味は、

B の確率を上げたいなら、 θ_1 を下げて、 θ_2 を上げる
です。

30 4. ここまでの直感

かなり雑に言うと、こうです。

実際に選んだ行動	その行動をもっと出すには
A	θ_1 を上げ、 θ_2 を下げる
B	θ_1 を下げ、 θ_2 を上げる

だから、

$$\nabla_{\theta} \log \pi_{\theta}(A) = (0.5, -0.5)$$

$$\nabla_{\theta} \log \pi_{\theta}(B) = (-0.5, 0.5)$$

という形になります。

31 5. 次に、軌跡データを使う

軌跡データはこうでした。

軌跡	行動	収益 G
τ_1	A	1
τ_2	B	0
τ_3	A	1
τ_4	A	1

それぞれの軌跡について、

$$\nabla_{\theta} \log \pi_{\theta}(a) \times G$$

を計算します。

31.1 τ_1 : A を選んで、収益 1

A を選んだので、

$$\nabla_{\theta} \log \pi_{\theta}(A) = (0.5, -0.5)$$

収益は、

$$G = 1$$

なので、

$$(0.5, -0.5) \times 1 = (0.5, -0.5)$$

これは、

A を選んだら良かった。だから A を出しやすくする方向に更新しよう
という意味です。

31.2 τ_2 : B を選んで、収益 0

B を選んだので、

$$\nabla_{\theta} \log \pi_{\theta}(B) = (-0.5, 0.5)$$

収益は、

$$G = 0$$

なので、

$$(-0.5, 0.5) \times 0 = (0, 0)$$

これは、

B を選んだけど、収益 0 だった。だから B を強化しない
という意味です。

31.3 τ_3 : A を選んで、収益 1

$$(0.5, -0.5) \times 1 = (0.5, -0.5)$$

31.4 τ_4 : A を選んで、収益 1

$$(0.5, -0.5) \times 1 = (0.5, -0.5)$$

32 6. 全部足す

4 本分の更新候補を足します。

$$(0.5, -0.5) + (0, 0) + (0.5, -0.5) + (0.5, -0.5)$$

成分ごとに足します。

θ_1 方向では、 $0.5 + 0 + 0.5 + 0.5 = 1.5$ です。

θ_2 方向では、 $-0.5 + 0 - 0.5 - 0.5 = -1.5$ です。

だから、

$$(1.5, -1.5)$$

になります。

33 7. 4 本で平均する

今回は軌跡が 4 本あるので、平均を取ります。

$$\begin{aligned}\hat{g} &= \frac{1}{4}(1.5, -1.5) \\ &= (0.375, -0.375)\end{aligned}$$

これが推定勾配です。

34 8. この計算の意味

最終的に、

$$\hat{g} = (0.375, -0.375)$$

になりました。

これは、

θ_1 方向はプラスです。

θ_2 方向はマイナスです。

ということです。

つまり、

軌跡データを見る限り、A を出すと良さそうだった。
だから、A の出やすさを上げる θ_1 は増やす。
B の出やすさを上げる θ_2 は下げる。

という更新になります。

35 9. 超要約すると

今回の計算はこうです。

推定勾配は、次のように考える。

$$\hat{g} = d(a) \times G$$

ここで、 $d(a)$ は「その行動を出しやすくする方向」、 G は「その行動の後の収益」です。

A を選んで良かったなら、

$$(0.5, -0.5)$$

方向へ進む。

B を選んだけど良くなかったなら、

$$(-0.5, 0.5)$$

方向へは進まない。

だから全体として、

$$(0.375, -0.375)$$

つまり、

A をもっと出しやすくし、B を出しにくくする

という更新になる。