

凍った湖と格子世界における強化学習評価指標の文献レビュー

エグゼクティブサマリー

結論から言うと、Farama Foundation ^① 系の格子世界ベンチマークで実際に広く使われている評価指標は、非常に偏っています。中心は **成功率 / 平均エピソード収益 / 学習曲線 / サンプル効率** であり、これに **複数 seed での平均・標準偏差** が付く形が主流です。とくに OpenReview ^② 上の MiniGrid・BabyAI・MiniHack 系論文では、最終性能と学習速度は頻繁に報告される一方、「**最初に成功するまでの難しさ**」、「**一度成功した後に再現的に成功できるか**」、「**危険領域との接触の仕方**」、「**価値がどのように後方伝播していくか**」を体系的に評価する慣行は、少なくとも今回の対象文献群では標準化されていません。 ^③

個別に見ると、**成功率**は BabyAI で明示的に使われ、**99% 成功率に達するまでのデモ数 / RL エピソード数** がサンプル効率として定義されています。MiniHack では **median reward over at least 5 seeds** とフル学習曲線の共有が推奨され、RIDE やその後続の MiniGrid 探索論文では **平均収益の rolling mean** や **探索行動の代理指標** が使われます。つまり、「発見してから安定化するまで」を切り分けるよりも、「最終的に解けたか」「どれだけ速く曲線が上がるか」が中心です。 ^④

ナビゲーション効率や**危険接触**に近い指標は、主として 3D/embodied navigation 文献側で整備されています。代表例は **SPL** (Success weighted by Path Length) で、成功と経路効率を合成した厳しめの指標です。さらに、その補助指標として **終端時の goal までの距離**、**normalized inverse path length**、**障害物接触などの infractions** が推奨されています。ただし、これらは MiniGrid / FrozenLake の RL 論文で一般的とは言えず、むしろ「導入可能だが未移植」の状態です。 ^⑤

信頼性・統計報告の文献では、状況が逆です。Deep RL 一般では、**seed 数**、**標準偏差 / CI**、**bootstrap**、**IQM**、**performance profile**、**probability of improvement** といった報告規範が整理されてきました。しかし、それが MiniGrid/MiniHack/FrozenLake 系の個別論文に均一に浸透しているわけではありません。したがって、もし論文の狙いが「環境診断」なら、**提案フレームワークの新規性は“統計報告そのもの”ではなく、“学習プロセスの分解診断”に置くべきです。** ^⑥

総合判断として、あなたの想定する **first-success difficulty / post-discovery reproducibility / hazard interaction / value-propagation diagnostics** は、各要素ごとには近縁概念があるが、組み合わせとしては十分に標準化されていないという位置づけです。したがって新規性主張は可能ですが、「完全に新しい評価概念」ではなく、「既存の **final-return / sample-efficiency / navigation-quality / reliability** 指標の隙間を埋める診断フレームワーク」として位置づけるのが最も堅いです。 ^⑦

検索戦略とスクリーニング

検索は、指定されたクエリ群を軸に、ベンチマーク論文の題名検索、引用連鎖、公式ドキュメント確認を組み合わせる形で行いました。実際に使った検索語には、たとえば "FrozenLake" reinforcement learning success rate、"FrozenLake-v1" "Q-learning" "average reward"、"MiniGrid" reinforcement learning "success rate"、"MiniGrid" "sample efficiency" reinforcement learning、"BabyAI" "sample efficiency" "success rate"、"MiniHack" reinforcement learning "episode return"、"MiniWorld" navigation "success rate"、"reinforcement learning" "reliability metrics"、"reinforcement learning" "sample efficiency" "area under learning

curve"、"SPL" reinforcement learning navigation、および各論文タイトルの厳密検索を含めました。主要ソースは NeurIPS proceedings、OpenReview、JMLR、公式ドキュメント、補助的に arXiv/ResearchGate の公開 PDF 断片です。 ⁸

包含基準は、ユーザー指定に沿って、FrozenLake / MiniGrid / BabyAI / MiniHack / MiniWorld / 近縁ナビゲーション環境で実験評価をしていること、または RL 評価指標・統計報告・信頼性評価を明示的に扱っていることに置きました。除外したのは、チュートリアル、個人ブログ、コードリポジトリ主体のもの、環境に触れるだけで評価指標が取れないもの、理論のみで評価規範が抽出できないものです。FrozenLake については、学術的・一次ソースとしての厚い「評価文化」がかなり薄いため、MiniGrid/BabyAI/MiniHack と評価方法論の文献に重心を移して判断しました。 ⁹

近似的なスクリーニング結果は、初期に約 70 件強の候補を確認し、抄録・本文レベルで約 30 件台前半を精査し、最終的に 13 本の論文と 4 件の公式ドキュメントを補助資料として採用、という水準です。除外理由の主因は、FrozenLake 側では学術論文よりチュートリアルや実装記事が多かったこと、MiniGrid 側ではアルゴリズム提案自体は多いが評価指標の記述が典型的で新たな抽出価値が小さいものが多かったことです。これは PRISMA の厳密レビューではなく、評価指標の地図を作るための構造化スコーピングレビュー と理解するのが適切です。

採用文献の整理表

ベンチマーク環境と探索系の中核文献

論文	著者・年・媒体	環境 / タスク	評価アルゴリズム	実際に使われた評価指標	訓練中 / 事後	seed / 不確実性	指標分類	ログ計算性
Minigrid & Miniworld: Modular & Customizable Reinforcement Learning Environments for Goal-Oriented Tasks ¹⁰	Chevalier-Boisvert et al., 2023, NeurIPS D&B	MiniGrid, MiniWorld, transfer	PPO	報酬曲線の AUC, transfer improvement, 人間の平均報酬と標準偏差	両方	人間実験で mean/std、RL は AUC 比較	最終性能・学習速度	直接計算可
BabyAI: A Platform to Study the Sample Efficiency of Grounded Language Learning ¹¹	Chevalier-Boisvert et al., 2019, ICLR	BabyAI instruction following	IL, RL	成功率, 99% 成功率到達に必要なデモ数 / RL エピソード数, デモ長平均 ±SD, 最大成功率	両方	RL は 10 runs の 99% CI、IL は 99% credible interval	最終性能・サンプル効率・信頼性	直接計算可

論文	著者・年・媒体	環境 / タスク	評価アルゴリズム	実際に使われた評価指標	訓練中 / 事後	seed / 不確実性	指標分類	ログ計算性
MiniHack the Planet: A Sandbox for Open-Ended Reinforcement Learning Research ¹²	Samvelyan et al., 2021, NeurIPS D&B	MiniHack navigation / skill / ported MiniGrid tasks	IMPALA, RND, RIDE	median reward over ≥ 5 seeds , full learning curves, mean episode return vs steps, held-out seeds / generalization 推奨	主に訓練中	少なくとも 5 independent runs、SD 推奨	最終性能・学習速度・一般化・信頼性	直接計算可
RIDE: Rewarding Impact-Driven Exploration for Procedurally-Generated Environments ¹³	Raileanu & Rocktäschel, 2020, ICLR	MiniGrid hard exploration	IMPALA, Count, RND, ICM, RIDE	average return , 100-episode rolling mean, mean $\pm$ SD over 5 seeds, learned behavior / intrinsic reward analysis	主に訓練中	5 seeds, mean $\pm$ SD	最終性能・学習速度・探索分析	直接計算可
Revisiting Intrinsic Reward for Exploration in Procedurally Generated Environments ¹⁴	Wang et al., 2023, ICLR	MiniGrid	PPO + intrinsic reward variants	training curves , sparse reward setting の cumulative extrinsic reward / average return , pure exploration setting の number of explored rooms , 5 runs の平均+SD	主に訓練中	5 runs, shaded SD	学習速度・探索 / coverage	直接計算可

論文	著者・年・媒体	環境 / タスク	評価アルゴリズム	実際に使われた評価指標	訓練中 / 事後	seed / 不確実性	指標分類	ログ計算性
BeBold: Exploration Beyond the Boundary of Explored Regions ¹⁵	Zhang et al., 2020, arXiv/ICLR submission	MiniGrid, NetHack	BeBold 他	解けた難問数, 120M steps での達成度、SOTA 比較	主に訓練中	抄録レベルでは不十分	学習速度・探索	一部のみの計算可
Learning the Model While Learning Q: Finite-Time Sample Complexity of Online SyncMBQ ¹⁶	Lim et al., 2026, arXiv preprint	FrozenLake, Taxi	Q-learning, SyncMBQ	training 中の average success rate, greedy policy success rate after training, mean±SD over 20 runs, moving average	両方	20 runs, mean±SD	最終性能・学習速度・信頼性	直接計算可

評価方法論・信頼性・ナビゲーション評価の中核文献

論文	著者・年・媒体	対象	実際に使われた / 提案された指標	訓練中 / 事後	seed / 不確実性	指標分類	ログ計算性	提案枠組み・脅威
On Evaluation of Embodied Navigation Agents ¹⁷	Anderson et al., 2018, arXiv working-group report	embodied navigation	SPL, success, geodesic distance, normalized inverse path length, end distance, infractions, exploration coverage	主に事後評価	統計より評価設計	ナビゲーション効率・安全補助指標	かなり計算可	High (navigation quality 部分のみ)。success quality / completion infraction に近い
Success Weighted by Completion Time ¹⁸	Yokoyama et al., 2021, IROS	embodied navigation	SCT, success, completion time	事後評価	報告あり	ナビゲーション効率	substantial 追加が必要な場合あり	Medium-path efficiency 上位互換的 gridworld success / value 診断しない

論文	著者・年・媒体	対象	実際に使われた / 提案された指標	訓練中 / 事後	seed / 不確実性	指標分類	ログ計算性	提案枠組み・なり・脅威
Behaviour Suite for Reinforcement Learning ¹⁹	Osband et al., 2020, ICLR	RL benchmark design	core capability tests, unified scoring / analysis	両方	再現性を重視	診断ベンチマーク	指標自体は環境依存	Medium。 向は近いが、たの個別ス群とは別
Deep Reinforcement Learning that Matters ²⁰	Henderson et al., 2018, AAAI	general RL evaluation	baseline variability, significance metrics, reporting guidelines	両方	seedと有意差重視	信頼性・再現性	直接計算可	Medium。 告なら高が、環境では部分重
Deep Reinforcement Learning at the Edge of the Statistical Precipice ²¹	Agarwal et al., 2021, NeurIPS	general RL evaluation	IQM, performance profiles, probability of improvement, optimality gap, stratified bootstrap CIs	主に事後集約	few-run 不確実性を重視	信頼性・統計報告	直接計算可	High (統分のみ)。level repro 強く改善で基盤
Empirical Design in Reinforcement Learning ²²	Patterson et al., 2024, Journal of Machine Learning Research ²³	general RL experimentation	performance variation, stability, hypothesis testing, multiple comparisons, hyperparameter bias	両方	統計設計全般	再現性・設計論	直接計算可	Medium- 設計規範のいが、gri固有診断
A Study on Overfitting in Deep Reinforcement Learning ²⁴	Zhang et al., 2018, arXiv	generalization in RL	training vs test performance, different evaluation protocols, generalization gap	両方	複数条件比較	信頼性・汎化	直接計算可	Medium。 out generaliz train-test 重要性を補

指標タクソノミーと評価

最終性能指標。

このカテゴリで最も一般的なのは **success rate** と **average episodic return / mean episode return** です。BabyAI は成功率を正面から定義し、MiniHack は median reward を主要報告値として推奨し、RIDE や MiniGrid 探索論文では平均収益曲線が中心です。これらは「最終的にどれだけ解けたか」を簡潔に伝えます

が、運よく一度だけ成功した run と 発見後に安定した run を区別しません。sparse-reward・stochastic な格子世界では、その区別が特に重要です。 25

学習速度 / サンプル効率指標。

BabyAI の 99% 成功率到達までに必要なデモ数 / エピソード数は、このカテゴリの代表例です。MiniGrid & MiniWorld の case study は **reward curve AUC** を使い、探索論文群は **学習曲線の立ち上がり** そのものを比較しています。これらは first-success difficulty に近縁ですが、通常は **閾値到達** を見るため、**最初の成功の瞬間** と **その後の安定化** を分離しません。したがって、あなたの proposed metrics の「first success episode / total steps」は、既存のサンプル効率評価に自然接続できますが、まだ標準の書き方ではありません。 26

探索・発見指標。

MiniGrid 探索論文では、報酬到達前の探索を測るために **number of explored rooms** や episodic first-visit 類似の内部量が使われます。RIDE は state change に基づく intrinsic reward を、Revisiting Intrinsic Reward は **explored rooms** と sparse-reward での曲線比較を採用します。Embodied navigation 側では **coverage under path-length budget** も提案されています。つまり、探索の「広がり」を測る指標はありますが、**初報酬発見時刻や初成功までの hitting-time** を外形的・統一的な評価指標として出す慣行は、今回の採用文献では強く確認できませんでした。 27

信頼性・分散・ロバストネス指標。

深層 RL 一般では、Henderson らが seed 依存性と有意差報告の重要性を指摘し、Agarwal らが **IQM / performance profiles / probability of improvement / bootstrap CI** を提案しました。MiniHack も実務的には **5 seeds 以上・median reward・learning curves + SD** を推奨しています。したがって、「複数 seeds での reporting」を組み込まない新規指標論文は弱く見えます。ただし、これらの文献は **run 間の不確実性** は扱っても、**同一 run 内で first success 後にどれだけ再現的に成功するか** までは扱いません。そこに post-discovery reproducibility の余地があります。 28

ナビゲーション効率指標。

SPL は「成功したうえでどれだけ短い経路を通ったか」を測る、かなり洗練された効率指標です。さらに auxiliary measures として **end distance, normalized inverse path length, infractions** が提案されています。格子世界では geodesic shortest path が計算しやすいので、**success path efficiency / shortest-path ratio** は移植しやすい一方、MiniGrid/FrozenLake 論文ではまだ標準ではありません。特に、**成功したが lava/hole ぎりぎりを通った policy と 安全に再現的に成功する policy** を区別したいなら、SPL だけでは不十分です。 5

安全・失敗・危険相互作用指標。

MiniGrid には lava, dynamic obstacles, locked doors、FrozenLake には holes と slippery stochasticity があり、MiniHack には lava, monsters, traps を組み込みます。しかし評価として主流なのは依然として return/success で、**hole/lava contact count, hazard contact rate in successful episodes, recovery count, respawn-before-success** のような細粒度 metrics は標準化されていません。Embodied navigation 文献の **infractions** は最も近い既存 precedent ですが、格子世界 RL 論文群にそのまま根付いてはいません。ここは明確なギャップです。 29

価値推定・価値伝播診断。

採用した主要 benchmark 論文では、Bellman error や value-by-distance を主要評価指標にしていません。RIDE は learned representation の変化分析、FrozenLake の公式チュートリアルは **Q-tables の平均化、state-action distribution、Q-value map** を出しますが、これは「ベンチマーク標準の最終指標」というより **診断可視化** です。したがって、**Q-value heatmaps / value propagation snapshots / event-based snapshots around first success** は、概念的な先行はあるが、体系的評価指標としてはまだ弱い、というのが安全な判断です。 30

FrozenLake と格子世界系ベンチマークで何が測られてきたか

まず FrozenLake ですが、**学術文献の層は明らかに薄い**です。公式ドキュメント上の FrozenLake-v1 は、slippery な遷移不確実性と holes を持つ toy-text 環境として定義されており、成功は goal 到達、失敗は hole 落下という単純な構図です。公式チュートリアル側では、典型的なログとして **rewards, steps, episodes, qtables, states/actions distribution** を保存・可視化しており、平均 Q-table や状態行動分布も出しています。つまり、FrozenLake は「診断がしやすい」が、「論文文化として診断指標が蓄積している」わけではありません。³¹

アクセスできた FrozenLake 学術例では、SyncMBQ が **training 中の average success rate** と **training 後 greedy policy の success rate** を表・曲線で比較し、**20 runs の mean±SD** を報告していました。ここから読み取れるのは、FrozenLake 論文での標準がやはり **success-focused** であり、しかも **moving average** や **post-training evaluation** に留まりがち、という点です。**first-success episode** や **first nonzero reward timing** を主要指標として掲げる伝統は見当たりませんでした。¹⁶

一方、MiniGrid / BabyAI / MiniHack / MiniWorld では、ベンチマークとしての成熟度がかなり高いです。MiniGrid と MiniWorld の公式論文は、両環境の default reward が sparse であることを明記し、MiniGrid では mission 完了時のみ reward が非ゼロになる設計を示しています。BabyAI は 19 level と compositional instruction の difficulty ladder を持ち、MiniHack は RewardManager により reward 事象を柔軟に設計でき、lava / traps / monsters を含む richer hazards を自然に導入できます。つまり、**あなたが考えている診断メトリクスは、環境的には十分載せる場所がある**ということです。³²

実際の評価慣行は環境ごとに少しずつ違います。BabyAI は成功率と閾値到達 sample efficiency をかなり厳密に定義しています。MiniHack は報酬曲線と seed 報告の実務規範が強いです。MiniGrid 探索論文群は、平均 return と exploration proxy を併用します。MiniWorld を含む transfer 論文では AUC が現れます。ところが、**一度成功してから二度目の成功まで何エピソード空くか、成功したエピソードにおける hazard contact の質、成功前後で value map がどう変わるか**になると、共通語彙がありません。ここがあなたの論文テーマの中心的な余白です。³³

RL 評価・信頼性文献との照合

評価方法論の文献から見ると、まず避けるべき落とし穴は明確です。Henderson らは seed・実装差・環境非決定性の影響で deep RL の比較がしばしば不安定になると指摘し、より厳密な reporting を求めました。Agarwal らはさらに踏み込み、few-run regime では単純な mean / median だけでは判断を誤る恐れがあるため、**IQM, performance profiles, probability of improvement, optimality gap, bootstrap CIs** を推奨しました。Patterson らの JMLR 論文は、この流れを統計設計・仮説検定・multiple comparisons・hyperparameter bias まで拡張しています。³⁴

この系譜が意味するのは、あなたの提案指標がどれだけ面白くても、**seed 依存の不確実性を併記しないと説得力が落ちる**ということです。特に first-success 系の指標は run-to-run variance が非常に大きい可能性があり、**median, IQM, bootstrap CI, probability-of-improvement** との併用が自然です。つまり、新しい診断 metric を出すなら、**その集約方法まで reliability literature に寄せるのが望ましい**です。³⁵

ただし、評価方法論の既存研究は主に **run 間の比較の信頼性** を扱っており、**run 内の学習ダイナミクスの分解**には踏み込みません。ここがあなたの提案の立ち位置です。たとえば IQM は「総合 performance を頑健に集約する」には優れていますが、**初成功は早いのに再現不能な学習と、初成功は遅いが一度当たると安定化する学習**を分けてはくれません。したがって、あなたの枠組みは statistical-reporting literature の代替ではなく、その上に載る **within-run diagnostic layer** として位置づけるべきです。³⁶

提案フレームワークとの比較、脅威評価、計算可能性、示唆

提案指標との比較

First-success difficulty は、既存文献では **steps/episodes to threshold** や **sample efficiency** に最も近いです。BabyAI が典型で、99% success に達するまでのサンプル数を測ります。しかしこれは「初めて成功するまで」と「成功を安定して繰り返せるまで」を混ぜています。よって **部分重複はあるが別物** です。脅威レベルは **Medium** です。 ³⁷

Post-discovery reproducibility に最も近い既存概念は、一般 RL 側の **stability over training** や、単なる success-rate curve です。しかし、**re-success gap, post-50/post-100 success rate** のように「最初の成功を基点に、その後の安定再現性を測る」指標は、今回の採用文献群では強い先例を確認できませんでした。脅威レベルは **Low** です。

Hazard interaction and success quality は、embodied navigation の **SPL + infractions** が最も近いです。また MiniGrid / MiniHack には lava, monsters, traps, dynamic obstacles があり、環境上は contact-based diagnostics を計算しやすい下地があります。ただし、実際の RL 論文では **hazard contact count in successful episodes** や **respawns before success** はほぼ標準化されていません。よって、navigation-quality 部分だけ見れば **Medium-High** の先行がありますが、hazard-aware success diagnostics としてはまだ空白が大きいです。 ³⁸

Value propagation diagnostics は、Q-map 可視化や state-action visitation 可視化に概念的な前例はありますが、benchmark standard と呼べるほど一般化していません。Bellman error / TD error を評価論文が主要メトリクスとして置くことも少ないです。したがって、この部分の脅威は **Low-Medium** です。FrozenLake のような tabular 環境では非常に自然ですが、「既にeveryoneが標準でやっている」とは言えません。 ³⁹

脅威レベルの要約表

既存メトリクス / 文献群	脅威レベル	理由
成功率・平均収益・最終性能	Low	関連は強いが、発見の難しさや発見後の再現性を分離できない
閾値到達 sample efficiency / steps-to-threshold	Medium	first-success difficulty を部分的に代替するが、first success と stable mastery を混同する
AUC / learning-curve slope	Medium	学習速度の要約として有効だが、単一の lucky breakthrough と安定化を区別できない
explored rooms / coverage / visitation 系	Medium	探索の広がり測るが、reward discovery と success reproducibility は直接測らない
SPL / SCT / shortest-path 系	Medium-High	success quality・path efficiency には近いが、sparse-reward discovery / value propagation までは含まない
infractions / obstacle contacts	Medium	hazard interaction に近いが、gridworld RL では標準化不足
IQM / CI / probability of improvement / reliable	High (統計報告部分)	新規性を「better evaluation methodology」だけで主張すると既存巨人が強い

既存メトリクス / 文献群	脅威レベル	理由
Q-value heatmap / state-action distribution 可視化	Low-Medium	関連するが断片的で、組織化された診断体系ではない
re-success gap / post-50 success / post-100 success	Low	強い先例をほぼ確認できなかった

あなたのログからの計算可能性

指標	計算可能性	コメント
success rate, failure rate, average episodic return, episode length	直接計算可	episode-level logs で十分
first success episode / first success total steps	直接計算可	success/failure と cumulative steps があればよい
re-success gap, post-50 / post-100 success rate	直接計算可	first success を anchor にして window 集計可能
episodes/steps to threshold, AUC, learning slope	直接計算可	per-episode trajectories から可能
across-seed mean/median/SD, bootstrap CI, IQM, probability of improvement	直接計算可	seed ラベルがあるので可能
state coverage, unique states, visitation entropy	直接計算可	state trajectory があるため
hole/lava/hazard contact count, successful episodes 内の hazard contacts	直接計算可	contact logs があるため
respawn / recovery before success	直接計算可	respawn events が記録されるなら可能
shortest-path ratio, SPL-like success path efficiency	直接計算可	env configuration があるので offline shortest path を解ける。動的障害物がある場合は定義を明示するとよい
first reward discovery	sparse reward では直接計算可 / dense reward では軽微な追加 logging	sparse なら first nonzero return $\equiv$ first success。dense reward では step-level reward がほしい
value by distance-to-goal, Q-value heatmap, value snapshots	直接計算可	保存済み Q-table / value estimates がある前提
Bellman error / TD error	軽微～大きめの追加 logging	学習中の予測値・ターゲット値を保存していれば容易、なければ後計算が難しい

指標	計算可能性	コメント
event-based snapshots around first success	直接計算可	saved checkpoints が first-success 近傍に十分あればよい

主要ギャップと論文の位置づけ方

最も大きいギャップは、「学習が起きたか」ではなく「学習がどう起きたか」を分解する指標が欠けていることです。既存文献は、最終成功率・最終収益・学習曲線・閾値到達サンプル効率に偏っています。その結果、偶然の初成功、初成功後の再現不能性、危険回避を伴う成功の質、価値の広がり方の遅さ / 偏りが見えません。 ⁴⁰

したがって、論文のポジショニングは次のようにするのがよいです。

第一に、**新アルゴリズムではなく、診断評価フレームワーク**であることを前面に出す。第二に、既存の success / return / sample-efficiency / reliability 指標を置き換えるのではなく、**それらでは説明不能な学習ダイナミクスを補完すると主張する**。第三に、評価デザインとしては **RLiable 系の集約と CI** を採用し、統計報告の弱さを突かれないようにする。第四に、環境セットは FrozenLake だけでなく、**MiniGrid-LavaCrossing・DynamicObstacles・DoorKey・MultiRoom・BabyAI subset・MiniHack ported tasks** を並べ、hazard / sparse reward / stochasticity / instruction complexity の軸を分離するのがよいです。 ⁴¹

より具体的には、主張の仕方は次の順番が堅実です。

「**first-success difficulty は既存サンプル効率指標の finer-grained decomposition**」、
「**post-discovery reproducibility は existing stability literature があまり見ていない within-run reliability**」、
「**hazard interaction は embodied navigation の infractions を sparse gridworld に移植した補助指標**」、
「**value propagation diagnostics は tabular/deep gridworld で計算可能な interpretability layer**」。
この framing なら、新規性を誇張せず、かつ十分に差別化できます。 ⁴²

オープンクエスションと限界

FrozenLake 固有の学術論文群については、MiniGrid/MiniHack/BabyAI ほど厚いベンチマーク文化を確認できませんでした。そのため FrozenLake の評価慣行は、少数の method paper と公式ドキュメントからの補助的推定が含まれます。

また、MiniGrid アルゴリズム論文は数が多い一方、使われる指標が平均 return / success / solved tasks / training curve に収束しているため、今回のレビューは **網羅性よりも評価指標の多様性抽出** を優先しています。

したがって、「first-success / re-success / hazard quality / value propagation が本当に広く未使用か」は、より大規模な systematic review でさらに厳密化する価値があります。

参考文献とリンク付き出典

- Minigrid & Miniworld: Modular & Customizable Reinforcement Learning Environments for Goal-Oriented Tasks — NeurIPS 2023 benchmark paper. ⁴³
- BabyAI: A Platform to Study the Sample Efficiency of Grounded Language Learning — ICLR 2019. ⁴⁴
- MiniHack the Planet: A Sandbox for Open-Ended Reinforcement Learning Research — NeurIPS 2021 benchmark paper. ⁴⁵
- RIDE: Rewarding Impact-Driven Exploration for Procedurally-Generated Environments — ICLR 2020. ⁴⁶

- Revisiting Intrinsic Reward for Exploration in Procedurally Generated Environments — ICLR 2023. 47
- On Evaluation of Embodied Navigation Agents — navigation evaluation protocol paper introducing SPL. 48
- Success Weighted by Completion Time: A Dynamics-Aware Evaluation Criteria for Embodied Navigation — SPL 拡張。 18
- Behaviour Suite for Reinforcement Learning — ICLR 2020 benchmark/diagnostic suite. 19
- Deep Reinforcement Learning that Matters — AAAI 2018 reproducibility paper. 20
- Deep Reinforcement Learning at the Edge of the Statistical Precipice — NeurIPS 2021, reliable / IQM / performance profiles. 21
- Empirical Design in Reinforcement Learning — JMLR 2024. 49
- A Study on Overfitting in Deep Reinforcement Learning — generalization/evaluation protocol caution. 50
- Learning the Model While Learning Q: Finite-Time Sample Complexity of Online SyncMBQ — FrozenLake metric example. 16
- FrozenLake 公式環境ドキュメント — holes と slippery stochasticity の定義。 51
- FrozenLake 公式学習チュートリアル — rewards, steps, qtables, state/action distribution の記録例。 39
- MiniGrid Crossing / LavaCrossing 公式ドキュメント — deadly lava, reward range, safe exploration context. 52
- MiniHack の ported MiniGrid ドキュメント — LavaCrossing port と +1 goal reward. 53

1 5 17 38 42 48 https://www.researchgate.net/publication/326476932_On_Evaluation_of_Embodied_Navigation_Agents
https://www.researchgate.net/publication/326476932_On_Evaluation_of_Embodied_Navigation_Agents

2 6 21 35 36 41 <https://openreview.net/forum?id=uqv8-U4lKBe>
<https://openreview.net/forum?id=uqv8-U4lKBe>

3 4 7 11 25 33 37 40 <https://openreview.net/pdf?id=rJeXCo0cYX>
<https://openreview.net/pdf?id=rJeXCo0cYX>

8 43 https://proceedings.neurips.cc/paper_files/paper/2023/hash/e8916198466e8ef218a2185a491b49fa-Abstract-Datasets_and_Benchmarks.html
https://proceedings.neurips.cc/paper_files/paper/2023/hash/e8916198466e8ef218a2185a491b49fa-Abstract-Datasets_and_Benchmarks.html

9 29 31 51 https://www.gymlibrary.dev/environments/toy_text/frozen_lake/
https://www.gymlibrary.dev/environments/toy_text/frozen_lake/

10 26 32 https://proceedings.neurips.cc/paper_files/paper/2023/file/e8916198466e8ef218a2185a491b49fa-Paper-Datasets_and_Benchmarks.pdf
https://proceedings.neurips.cc/paper_files/paper/2023/file/e8916198466e8ef218a2185a491b49fa-Paper-Datasets_and_Benchmarks.pdf

12 <https://openreview.net/pdf?id=skFwlyefkWJ>
<https://openreview.net/pdf?id=skFwlyefkWJ>

13 27 <https://openreview.net/pdf?id=rkg-TJBFPB>
<https://openreview.net/pdf?id=rkg-TJBFPB>

14 https://openreview.net/pdf?id=j3GK3_xZydY
https://openreview.net/pdf?id=j3GK3_xZydY

- 15 https://openreview.net/forum?id=_ptUyYP19mP
https://openreview.net/forum?id=_ptUyYP19mP
- 16 https://www.researchgate.net/publication/403309648_Learning_the_Model_While_Learning_Q_Finite-Time_Sample_Complexity_of_Online_SyncMBQ
https://www.researchgate.net/publication/403309648_Learning_the_Model_While_Learning_Q_Finite-Time_Sample_Complexity_of_Online_SyncMBQ
- 18 <https://www.emergentmind.com/papers/2103.08022>
<https://www.emergentmind.com/papers/2103.08022>
- 19 <https://openreview.net/forum?id=rygf-kSYwH>
<https://openreview.net/forum?id=rygf-kSYwH>
- 20 28 34 <https://collaborate.princeton.edu/en/publications/deep-reinforcement-learning-that-matters>
<https://collaborate.princeton.edu/en/publications/deep-reinforcement-learning-that-matters>
- 22 49 <https://jmlr.org/papers/v25/23-0183.html>
<https://jmlr.org/papers/v25/23-0183.html>
- 23 45 <https://openreview.net/forum?id=skFwlyefkWJ>
<https://openreview.net/forum?id=skFwlyefkWJ>
- 24 <https://research.google/pubs/a-study-on-overfitting-in-deep-reinforcement-learning/>
<https://research.google/pubs/a-study-on-overfitting-in-deep-reinforcement-learning/>
- 30 39 https://gymnasium.farama.org/v0.28.0/tutorials/training_agents/FrozenLake_tuto/
https://gymnasium.farama.org/v0.28.0/tutorials/training_agents/FrozenLake_tuto/
- 44 <https://openreview.net/forum?id=rJeXCo0cYX&source=>
<https://openreview.net/forum?id=rJeXCo0cYX&source=>
- 46 <https://openreview.net/forum?id=rkg-TJBFPB>
<https://openreview.net/forum?id=rkg-TJBFPB>
- 47 https://openreview.net/forum?id=j3GK3_xZydY
https://openreview.net/forum?id=j3GK3_xZydY
- 50 https://www.researchgate.net/publication/324643719_A_Study_on_Overfitting_in_Deep_Reinforcement_Learning
https://www.researchgate.net/publication/324643719_A_Study_on_Overfitting_in_Deep_Reinforcement_Learning
- 52 <https://minigrid.farama.org/environments/minigrid/CrossingEnv/>
<https://minigrid.farama.org/environments/minigrid/CrossingEnv/>
- 53 <https://minihack.readthedocs.io/en/latest/envs/ported/minigrid.html>
<https://minihack.readthedocs.io/en/latest/envs/ported/minigrid.html>