

強化学習評価研究として見たあなたの研究方向の先行研究調査

エグゼクティブサマリー

結論から言うと、あなたの研究方向と「完全一致」する公開論文は見つからなかった。私が確認した主要な近接領域は、ナビゲーション評価 (SPL・SoftSPL・SCT)、RL 信頼性評価 (variability / risk / IQM / probability of improvement / CVaR)、ハード探索、不可逆性、価値誤差診断の各断片であり、それぞれが部分的にはあなたの軸を代替しうるが、**初回成功・再成功／再現性・成功の定着・失敗依存成功・空間的な価値伝播を、疎報酬・確率遷移・不可逆失敗環境**の文脈で一体の評価枠組みとして統合したものは見当たらない。したがって、現時点の新規性評価は **高い** が、個別の既存指標が一部を代替できるため、査読上の脅威は「局所的には高いが、全体としては中程度」というのが実態に近い。 ¹

あなたの研究が論文になるかという点については、**十分になりうる**。実際、RL では「アルゴリズムそのもの」ではなく、**評価法・統計報告法・ベンチマーク設計**を主題にした論文が、ICLR ²、NeurIPS ³、ICML ⁴、JMLR ⁵ のような主要 venues に成立している。とくに Chan らの reliability 指標、Jordan らの評価方法論、Agarwal らの reliable 系統、Patterson らの empirical design は、「評価の設計」自体が strong contribution になりうることを示している。あなたの企画は、そこに「疎報酬・確率遷移・不可逆失敗・成功分解」という具体的で重要な穴を埋める形で接続できる。 ⁶

ただし、そのままでは「既存指標の寄せ集め」に見られる危険がある。査読を通すには、**既存の最終性能指標・サンプル効率指標・信頼性指標では見落とす現象が、本提案の複合指標では再現よく検出できること**を、明確な ranking reversal と case study で示す必要がある。最も重要なのは、**同じ最終 success rate** でも、(a) 最初の成功に何エピソード要したか、(b) その次の成功までどれだけ gap があるか、(c) 一度成功した後どれだけ安定して成功し続けるか、(d) 成功が hole 落下や respawn に依存していないか、(e) 価値がゴール距離方向にどう広がったか、が大きく異なることを示す実験設計である。既存文献はこの「成功の分解」を個別にしか扱っていない。 ⁷

調査範囲と検索戦略

一次情報としては、主に arXiv ⁸、OpenReview ⁹、PMLR、Farama Foundation ¹⁰ の公式ドキュメント、公式 benchmark / toolkit の公開 repository を優先して確認した。対象は「RL evaluation」

「diagnostic」「reliability」「learning-progress metrics」を広く取り、そのうえで sparse reward、stochastic transitions、irreversible / dead-end failures、navigation efficiency、success reproducibility を含む領域を重点的に見た。 ¹¹

検索語は、あなたが気にしている概念が別名で存在する可能性を前提に、hitting time、first hitting time、first-passage time、time-to-threshold、sample complexity to threshold、discovery time、goal-hit rate、policy stability after first success、post-discovery robustness、success-conditioned efficiency、Bellman error、value error、value-function heatmap、Q-value propagation、reversibility-aware RL、irreversible dynamics、hard exploration を横断的に使った。実際、文献上の近い語彙は、**初回成功 difficulty** については hitting time / first-passage / time-to-threshold に、**再現性や安定性** については variability / dispersion / risk / CVaR / probability of improvement に、**経路効率** については SPL / SoftSPL / SCT / steps-on-success に、**価値伝播** については Bellman error / value error / heatmap / propagation に、それぞれ散っていた。 ¹²

調査の限界も明示しておく。今回の結論は、主要一次情報源を広く横断したうえでの高信頼の synthesis だが、**小規模 workshop・国内研究会 PDF・題名に RL evaluation と書かれていない隣接領域の論文**まで完全に尽くしたとは言わない。したがって、「完全にゼロ」と断言するよりは、**主要な公開文献群では未発見**と表現するのが正確である。¹³

一致判定と近接論文

完全一致の判定

完全一致なし。見つかった最も近い先行研究は、

- 経路効率だけを測るもの、
 - 変動性や tail risk だけを測るもの、
 - hard-exploration や irreversible dynamics を扱うが「評価軸」そのものは提案しないもの、
 - value error や visual diagnostics を扱うが「成功の分解」とは別のもの、
- に分かれていた。単一の論文があなたの 6 軸（初回成功、再成功、定着、経路効率、失敗依存、価値伝播）を中核貢献として揃えてはいない。¹⁴

最も近い論文トップ10

軸の凡例は、**初回** = first-discovery、**再** = re-success / reproducibility、**定着** = post-first-success consolidation、**経路** = path efficiency、**失敗依存** = success relying on failure / respawn、**価値** = value propagation diagnostics。

論文	年 / venue	判定	主に触る軸	主貢献	あなたの方向との差	脅威	アクセス
On Evaluation of Embodied Navigation Agents	2018 / arXiv	near miss	経路	SPL を導入し、成功と最短経路比を success-conditioned に評価	学習過程全体の初回成功・再成功・定着は扱わない	High	abstract ¹⁵ / PDF ¹⁶ / OA
Success Weighted by Completion Time	2021 / arXiv	near miss	経路	SPL の限界を補い、動力学込みで completion time を評価	training-level discovery / reproducibility / failure dependence は扱わない	Medium	abstract ¹⁷ / OA
Measuring the Reliability of Reinforcement Learning Algorithms	2020 / ICLR	near miss	再、定着（一部）	variability と risk を training / fixed-policy rollout の両方で定量化	first-success と post-success gap のイベント構造は持たない	High	abstract ¹⁸ / arXiv ¹⁹ / OA

論文	年 / venue	判定	主に触 る軸	主貢献	あなたの方向と の差	脅威	アクセ ス
Deep Reinforcement Learning at the Edge of the Statistical Precipice	2021 / NeurIPS	near miss	再（一部）、統計報告	IQM、performance profiles、probability of improvement、sample-efficiency curves を整理し reliable を公開	success decomposition ではなく aggregate statistical evaluation	High	abstract ²⁰ / PDF ²¹ / OA
Evaluating the Performance of Reinforcement Learning Algorithms	2020 / ICML	near miss	統計報告	single-env と multi-env の包括的評価方法論	あなたの軸のような event-structured diagnostic はない	Medium	abstract ²² / PDF ²³ / OA
Empirical Design in Reinforcement Learning	2024 / JMLR	near miss	再、統計報告	variation, stability, hypothesis testing, baselines, experiment bias を体系化	“何を測るか”より“どう比較するか”中心	Medium	article ²⁴ / OA
Learning to Generalize from Sparse and Underspecified Rewards	2019 / ICML	near miss	失敗依存（概念的）	sparse / underspecified reward 下で accidental / spurious success を区別する問題設定	failure-respawn 依存の明示的評価指標ではない	Medium	abstract ²⁵ / PDF ²⁶ / OA
Go-Explore: a New Approach for Hard-Exploration Problems	2019 / arXiv	near miss	初回（概念的）	Montezuma’s Revenge / Pitfall の hard exploration に対し first-return-then-explore を提示	「初回成功 difficulty」は示唆するが、評価指標として定式化しない	Medium	abstract ²⁷ / OA
There Is No Turning Back: A Self-Supervised Approach for Reversibility-Aware Reinforcement Learning	2021 / NeurIPS	near miss	失敗依存、不可逆性	action の reversibility を見積もり不可逆行動を避ける	不可逆失敗を評価軸にするのではなく、学習制御に使う	Medium	abstract ²⁸ / PDF ²⁹ / OA

論文	年 / venue	判定	主に触 る軸	主貢献	あなたの方向と の差	脅威	アクセ ス
Why Should I Trust You, Bellman? The Bellman Error is a Poor Replacement for Value Error	2022 / ICML	near miss	価値	Bellman error が value error の良い proxy ではないことを理論・実験で示す	spatial goal-distance binned value propagation そのものは扱わない	Medium	abstract 30 / PDF 31 / OA

timeline

title 近接論文トップヒットの年表

2018 : On Evaluation of Embodied Navigation Agents

2019 : Learning to Generalize from Sparse and Underspecified Rewards

2019 : Go-Explore

2020 : Measuring the Reliability of Reinforcement Learning Algorithms

2020 : Evaluating the Performance of Reinforcement Learning Algorithms

2021 : Deep Reinforcement Learning at the Edge of the Statistical Precipice

2021 : Success Weighted by Completion Time

2021 : There Is No Turning Back

2022 : Why Should I Trust You, Bellman?

2024 : Empirical Design in Reinforcement Learning

各論文の短評と一致度

Peter Anderson, Angel X. Chang, Devendra Singh Chaplot, Alexey Dosovitskiy, Saurabh Gupta, Vladlen Koltun, Jana Košecká, Jitendra Malik, Roozbeh Mottaghi, Manolis Savva, and Amir Roshan Zamir. 2018. On Evaluation of Embodied Navigation Agents. arXiv preprint arXiv:1807.06757.

SPL によって成功と最短経路比を同時に測る、あなたの「経路効率」軸に最も直接に近い文献である。ただし、これは**1 エピソードの成功 path の効率**を見る指標であり、**いつ最初に成功したか、成功が定着したか、失敗を経由した成功か**は測らない。判定は near miss、脅威は **High**。URL/PDF は arXiv から open access で取得できる。 ³²

Naoki Yokoyama, Sehoon Ha, and Dhruv Batra. 2021. Success Weighted by Completion Time: A Dynamics-Aware Evaluation Criteria for Embodied Navigation. arXiv preprint arXiv:2103.08022.

SCT は SPL の弱点を補い、経路長ではなく **dynamics-aware な completion time** を success-conditioned に評価する。ゆえに path efficiency 側では強い先行だが、やはり**学習中の first success / re-success / consolidation**を持たない。判定は near miss、脅威は **Medium**。arXiv で open access。 ¹⁷

Stephanie C. Y. Chan, Samuel Fishman, John Canny, Anoop Korattikara, and Sergio Guadarrama. 2020. Measuring the Reliability of Reinforcement Learning Algorithms. International Conference on Learning Representations.

この論文は RL の reliability を、training 中と fixed policy rollout 後の両方で **variability** と **risk** として測る。あなたの「再成功」「成功定着」に最も近い objection source の一つだが、実際には**first success を境にした phase split**をせず、**post-success gap** も定義しない。判定は near miss、脅威は **High**。

OpenReview / arXiv とともに open access。 ³³

Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron Courville, and Marc G. Bellemare. 2021. Deep Reinforcement Learning at the Edge of the Statistical Precipice. Advances in Neural

Information Processing Systems.

few-run regime の RL 評価に対して、IQM、performance profiles、probability of improvement、sample-efficiency curves を推奨し、reliable を公開した基幹論文である。査読者が「統計的比較ならこれで十分」と言ってくる可能性は高いが、これは**aggregate benchmark evaluation**であって、**成功イベントの内部構造**は捨てている。判定は near miss、脅威は **High**。NeurIPS PDF と arXiv が open access。 ³⁴

Scott M. Jordan, Yash Chandak, Daniel Cohen, Mengxue Zhang, and Philip S. Thomas. 2020. Evaluating the Performance of Reinforcement Learning Algorithms. Proceedings of the 37th International Conference on Machine Learning.

single environment と multi-environment aggregation の両方について、信頼できる performance evaluation methodology を提案している。重要な方法論論文だが、やはり focus は「比較の正しさ」であり、**success decomposition** ではない。判定は near miss、脅威は **Medium**。PMLR PDF が open access。

35

Andrew Patterson, Samuel Neumann, Martha White, and Adam White. 2024. Empirical Design in Reinforcement Learning. Journal of Machine Learning Research 25.

実験設計、variation、hypothesis testing、baseline、hyperparameter bias を横断的に整理する、現在の RL evaluation methods の総括的文献である。あなたの研究に対する threat は、「評価系の論文は既にある」という意味では中程度だが、**疎報酬・不可逆失敗・success reproducibility の専用評価軸**は提示しない。判定は near miss、脅威は **Medium**。JMLR で open access。 ²⁴

Rishabh Agarwal, Chen Liang, Dale Schuurmans, and Mohammad Norouzi. 2019. Learning to Generalize from Sparse and Underspecified Rewards. Proceedings of the 36th International Conference on Machine Learning.

この論文の要点は、**binary success でも accidental / spurious success がありうる**と明言したことにある。あなたの「失敗依存成功」軸にかなり近い問題意識を持つが、trajectory が hole / respawn に依存したかどうかを測る explicit metric ではない。判定は near miss、脅威は **Medium**。PMLR / arXiv ともに open access。 ³⁶

Adrien Ecoffet, Joost Huizinga, Joel Lehman, Kenneth O. Stanley, and Jeff Clune. 2019. Go-Explore: a New Approach for Hard-Exploration Problems. arXiv preprint arXiv:1901.10995.

Montezuma's Revenge と Pitfall を hard-exploration benchmark として強調し、「first return, then explore」という構造で sparse / deceptive reward 問題に挑む。あなたの「初回成功 difficulty」に近い現象を突いているが、**評価軸としての first-success / re-success を提案した論文ではない**。判定は near miss、脅威は **Medium**。arXiv で open access。 ²⁷

Nathan Grinsztajn, Johan Ferret, Olivier Pietquin, Matthieu Geist, and Philippe Preux. 2021. There Is No Turning Back: A Self-Supervised Approach for Reversibility-Aware Reinforcement Learning. Advances in Neural Information Processing Systems.

不可逆行動の危険性を self-supervised に見積もり、reversibility-aware に学習する。あなたの「不可逆失敗環境」の文脈では非常に重要な近接論文だが、やっているのは**評価枠組み**ではなく**学習制御**である。判定は near miss、脅威は **Medium**。OpenReview / PDF が open access。 ³⁷

Scott Fujimoto, David Meger, Doina Precup, Ofir Nachum, and Shixiang Shane Gu. 2022. Why Should I Trust You, Bellman? The Bellman Error is a Poor Replacement for Value Error. Proceedings of the 39th International Conference on Machine Learning.

Bellman error を小さくしても value error は改善しない場合があることを、理論・toy・benchmark で示した。あなたの「価値伝播」軸に対する最も強い既存 objection source はこの系統だが、これは**spatially goal-distance conditioned propagation**や**成功フェーズとの関係**までは扱わない。判定は near miss、脅威は **Medium**。PMLR / arXiv が open access。 ³⁸

評価指標

既存評価指標の分類と脅威度

以下では、**evaluation metrics** だけを分離して整理する。列の意味は次の通り。

- **初回成功**: first-success difficulty を直接測れるか
- **再成功**: post-success reproducibility を直接測れるか
- **失敗經由成功**: avoidable failure / respawn 依存の成功を切り分けられるか
- **価値伝播**: goal 距離方向の value spread を診断できるか
- **ログ算出**: FrozenLake / MiniGrid 風ログから算出可能か
- **脅威**: あなたの枠組みを置き換えうる査読上の脅威度

指標	分類	何を測るか	初回成功	再成功	失敗經由成功	価値伝播	ログ算出	査読上の脅威	残るギャップ	主な出典
平均 return / 最終 success rate	final performance	最終的にどれだけ解けたか	×	×	×	×	Yes	Medium	成功に至る過程を全て潰す	39
binary success rate を目的にした評価	final performance	success probability そのもの	×	△	×	×	Yes	Medium	first success と post-success gap を分けない	40
AUC / sample-efficiency curve	learning speed	学習曲線全体の面積や sample efficiency	△	×	×	×	Yes	Medium	しきい値到達前後の phase を混ぜる	41
time-to-threshold / sample complexity to threshold	learning speed	ある成功率しきい値に達するまでの sample 数	Yes	×	×	×	Yes	High	“最初の 1 回成功”と“安定成功率到達”を区別しない	42
hitting time / first hitting time / first-passage time	exploration and discovery	初めて goal / target に到達するまでの時間	Yes	×	×	×	Yes	High	success の再現・定着・failure dependence を見ない	43
goal-hit rate	exploration and discovery	goal に当たる頻度、初期方策の探索成否	△	×	×	×	Yes	Medium	hit の後の安定性や path quality を見ない	44

指標	分類	何を測るか	初回成功	再成功	失敗經由成功	価値伝播	ログ算出	査読上の脅威	残るギャップ	主な出典
dispersion across runs / across time	reliability / robustness / variance	seed 間・時系列のばらつき	×	△	×	×	Yes	High	“成功後に安定したか”を event-conditioned に見ない	45
risk across rollouts / CVaR	reliability / robustness / variance	rollout tail risk、worst-case performance	×	△	×	×	Yes	High	rare catastrophic post-success collapse は見えるが、first vs post-first を分けない	46
IQM / probability of improvement / optimality gap / performance profiles	reproducibility and statistical reporting	aggregate benchmark 比較を頑健に行う	×	×	×	×	Yes	High	比較統計として強いが success event を分解しない	47
SPL	navigation efficiency	success conditioned で path length を最短経路と比較	×	×	×	×	Yes	High	1回の成功 path 効率であり学習進行を見ない	32
SoftSPL / SSPL	navigation efficiency	success に至らなくても progress を加味した path efficiency	×	×	×	×	Yes	Medium	progress は測れても post-success reproducibility は測れない	48
SCT / completion-time 系	navigation efficiency	dynamics-aware に速く goal を達したか	×	×	×	×	Yes	Medium	learning-stage の success consolidation とは別物	17
steps-on-success / normalized path length	navigation efficiency	成功した試行の効率のみ	×	×	×	×	Yes	Medium	成功した episode 以外の情報を消す	49

指標	分類	何を測るか	初回成功	再成功	失敗經由成功	価値伝播	ログ算出	査読上の脅威	残るギャップ	主な出典
collision rate / failure rate / catastrophe rate	safety / dead-end / failure-recovery	失敗の頻度	×	×	△	×	Yes	Medium	失敗を経由して成功した case を success 側から見ない	50

この表から重要なのは、脅威が高いのは「個別の軸」についてだけだという点である。例えば、**初回成功 difficulty** だけなら hitting time / first-passage / time-to-threshold 系でかなり代替される。**経路効率** だけなら SPL / SCT / SoftSPL でかなり強い。**集団比較の頑健性** だけなら rliable や reliability metrics で強い。だが、**成功という現象を時間相で分解し、しかも failure-assisted success と spatial value propagation まで同居させる枠組み**にはなっていない。ここがあなたの core gap であり、査読に対して最も強く主張すべき点である。 51

ツールキットと既存フレームワークはどこまで脅威か

rliable は、IQM ・ optimality gap ・ probability of improvement ・ performance profiles ・ sample-efficiency curves を提供するが、公開 README / docs 上では **first-success** 系の指標は見当たらない。rl-reliability-metrics も variability と risk を中心に設計されており、README / paper summary に **first-success / re-success** の explicit metric は現れない。したがって、これらは**再現性・比較統計のレイヤー**では非常に強い先行だが、あなたの event-conditioned success decomposition を直接は代替しない。 52

同様に、Open RL Benchmark は raw runs と reproducible tracking、図表生成、rliable 連携を提供するが、公開説明では metric layer は既存の tracked data と rliable integration に寄っており、first-success / post-success consolidation のような新規 event metrics は前面に出ていない。したがって、**あなたの contribution は Open RL Benchmark の代替ではなく、その上に載せられる新 metric family**として位置づけるのが賢い。 53

診断指標

既存 diagnostic metrics と、どこが足りないか

ここでは **diagnostic metrics** を分離する。これらは多くの場合、episode end の success / failure ではなく、**critic ・ value ・ state-space** の内部状態を見にいく。

指標 / ツール	何を測るか	初 回 成 功	再 成 功	失 敗 経 由 成 功	価値伝 播	FrozenLake / MiniGrid ログ から算出	脅威	残るギャッ プ	出 典
Bellman residual / Bellman error	Bellman 方程式の残 差	×	×	×	△	Partial (critic/ Q snapshot が 必要)	Medium	value propagation を goal- distance と 結びつけな い	38
TD error	逐次的な value update の 局所誤差	×	×	×	△	Partial (step- level TD logs 必須)	Low- Medium	state-space 全体の success geometry は 見えない	54
value error	真値との差	×	×	×	Yes (一 部)	FrozenLake で は Yes 、 MiniGrid では model があれ ば Partial	Medium	“いつ成功し たか”と結び つかない	38
Q-value propagation rate	reward 情 報が Q に どれだけ速 く広がるか	×	×	×	Yes	Partial (Q snapshot 系ロ グが必要)	Medium	実際の success event と対 応づけない	55
distance- binned value curves / heatmaps	goal 距離 ごとの value landscape	×	×	×	Yes	Yes (grid / tabular なら容 易)	Low- Medium	既存文献で は標準 metric に なっていない	56
Interestingness Elements for XRL	重要 interaction moments と能力 / 限 界の視覚要 約	×	△	△	△	Partial (rich trajectory logs が必要)	Low- Medium	成功分解の 定量 metric ではない	57
RLInspect	training 中 の挙動分析 の interactive visual tool	×	△	△	△	Partial (state/ action/reward/ architecture logs が必要)	Low- Medium	benchmark- ready metric family では ない	58

この領域の重要ポイントは、**既存の diagnostic 指標は success decomposition の代替というより、value / policy の内部状態の補助診断**だということだ。とくに Bellman error 系については、「それを見れば価値伝播は分かる」という objection が出やすいが、Fujimoto らはむしろ **Bellman error は value error の良い proxy ではない**と主張している。したがって、あなたの proposed value-propagation axis は、Bellman

residual ではなく、**goal-distance conditioned value landscape** や **post-first-success** と **value spread** の相関に置くほうが差別化しやすい。 38

実務的には、FrozenLake / MiniGrid のような小規模環境では、この軸はかなり実装しやすい。環境遷移が有限で、goal までの shortest-path distance が明示でき、tabular Q/V を可視化できるからだ。つまり、この軸は「既存に完全にはない」わけではないが、**既存の主要評価文献では標準化されていない**し、**first-success / re-success の時間相と結んだ診断指標**としては未整理である。ここは publishable な差分になる。 59

ベンチマーク環境

benchmark environments の整理

ここでは **benchmark environments** を分離する。重要なのは、ベンチマークは novelty を直接潰すというより、**どの現象が既に benchmarked されているか**を通じて、「新しい metric が本当に必要か」を問うてくる点である。

環境 / benchmark	関連特性	既存でよく使われる評価	あなたの軸をログから計算できるか	直接的な novelty threat	コメント	出典
FrozenLake	sparse reward、slippery による stochastic transitions、hole で episode 終了	success / return / solved criterion	Yes 。最も実装しやすい	Low-Medium	環境自体は古典的だが、新 metric の proof-of-concept には最適	60
MiniGrid / MiniWorld	goal-oriented gridworld / 3D、customizable、研究特化環境の作成が容易	success rate、episode length、sample efficiency	Yes	Medium	goal-conditioned gridworld と maze 系実験の主戦場	61
MiniHack	procedural、rich dynamics、拡張しやすい sandbox、難探索	score / success / sample efficiency	Yes だが richer logging が必要	Medium	dead-end / deceptive exploration を設計しやすい	62
BabyAI	MiniGrid ベース、sample efficiency と grounded language learning	success / demos / sample efficiency	Yes (instruction 条件付き)	Medium	success threshold / sample efficiency objection の根拠になりうる	63

環境 / benchmark	関連特性	既存でよく使われる評価	あなたの軸をログから計算できるか	直接的な novelty threat	コメント	出典
Procgen	procedural generalization、sample efficiency	aggregate score、generalization、sample efficiency	Partial	Medium	first-success は取れるが failure dependence は task 次第	64
Habitat	embodied navigation、photorealistic 3D、PointNav / ObjectNav	SPL、SoftSPL、distance-to-goal、steps	Partial-Yes	High	path-efficiency objection の主要根拠	65
ALE / Atari hard-exploration tasks	多数ゲーム、Montezuma / Pitfall など sparse / deceptive reward	game score、sample efficiency、exploration	Partial	Medium	hard exploration benchmark として重要だが success decomposition は標準化されていない	66

この整理から見えるのは、ベンチマークは既に十分存在するが、あなたの **metric family** は **benchmark** ではなく **“lens”** の提案として立てるべきだということだ。つまり、「新しい環境を作る」ことを主張するより、既存 **benchmark** 上で既存 **metrics** では **distinguish** できない **agent difference** を見せるほうが、論文化としては筋が良い。とくに FrozenLake / MiniGrid / MiniHack / Habitat / ALE を横断して同じ evaluation language を通せるなら、枠組みの説得力が上がる。 67

指標ではない先行手法と査読対策

algorithmic methods であって metrics ではないもの

以下は、**algorithmic methods that are not themselves metrics** である。査読ではしばしば「それは training method / reward shaping / safe RL で解くべきで、metric の話ではない」と返ってくるので、先に切り分けておくべき対象だ。

手法 / 論文	何をする手法か	あなたの方向に近い点	なぜ metric の代替ではないか	FrozenLake / MiniGrid ログからの関係	脅威	出典
potential-based reward shaping / policy invariance	reward を shaping して学習を速くする、optimal policy の不変性を理論保証	distance-to-goal shaping が初回成功を速めうる	これは 評価指標 ではなく 学習介入 。成功の分解はしない	shaping の有無で proposed metrics を比較する対照群に使える	Medium	68

手法 / 論文	何をする手法か	あなたの方向に近い点	なぜ metric の代替ではないか	FrozenLake / MiniGrid ログからの関係	脅威	出典
Go-Explore / reset-based exploration	hard exploration で “return then explore” を使う	初回到達 difficulty を強く意識	これは success を早く見つける 方法 で、見つけた後の再成功や定着を測らない	proposed first-success / re-success axis の比較対象に最適	Medium	69
Learning to Generalize from Sparse and Underspecified Rewards	accidental / spurious success を抑える auxiliary reward 学習	“見せかけの成功”問題を扱う	failure-assisted success を 評価 する explicit metric ではない	failure dependence 軸の関連先行として有効	Medium	36
reversibility-aware RL	不可逆行動を避ける policy を学ぶ	irreversible failure 問題設定に近い	不可逆失敗を減らす 手法 であって、どれだけ failure dependence があつたかの指標ではない	irreversible benchmarks 上の baseline として使える	Medium	37
safe learning under irreversible dynamics / asking for help	不可逆 dynamics 下で help を要請して安全学習	dead-end / irreversible failures を直接扱う	安全学習法であり、success decomposition metric ではない	irreversible setting を定義する際の強い関連先行	Medium	
Leave No Trace	reset policy を学び、unsafe / unrecoverable states を避ける	failure recovery / reset 問題に近い	reset learning は metric ではない	“failure-recovery dependence” の比較対象に使える	Low-Medium	70

この切り分けは重要で、**あなたの貢献は「より良い学習 algorithm」を出すことではなく、「既存 algorithm をどう診断・比較するか」を出すこと**である。したがって、これら algorithmic papers がどれだけ近く見えても、査読返しでは「それらは intervention、こちらは measurement」という構図を明示したほうがよい。Chan / Agarwal / Jordan / Patterson の evaluation 系論文が、algorithm invention ではなく measurement design で成立しているのと同じ線で戦うべきである。 71

reviewer-rebuttal matrix

ありうる査読コメント	背後にある既存指標 / 論文	objection が妥当な理由	それでも完全代替にならない理由	あなたの残る貢献	必要な防御実験
「初回成功は hitting time / time-to-threshold で測れる」	first-passage / hitting-time 系、threshold 系 ⁷²	初回到達 difficulty だけならその通り	それらは 再成功・定着・failure dependence を持たない	success を phase-split する評価	同じ first-success でも post-success gap が違う agent を見せる
「再現性は reliability metrics と CVaR で十分」	Chan 2020、A2Perf、reliable ⁷³	seed 間ばらつき・tail risk は既に強い	それらは first success 以後 を条件化していない	post-discovery robustness / consolidation の導入	同じ IQR / CVaR でも post-first-success success rate が異なる例を示す
「経路効率 は SPL / SoftSPL / SCT で十分」	Anderson 2018、Yokoyama 2021 ⁷⁴	1 episode の path efficiency は既に測れる	それらは training-progress や failure-assisted success を見ない	success path efficiency を learning dynamics と接続	同じ SPL でも初回成功までの episode 数や failure dependence が違う例を示す
「失敗依存成功は単に failure rate を見ればよい」	failure / catastrophe / collision 系 ⁵⁰	failure frequency は測れる	“失敗が多い”ことと“成功が failure / respawn に依存”することは別	success-conditioned failure dependence 指標	同じ failure rate でも success の多くが respawn 後のみ起こる agent を示す
「価値伝播 は Bellman error / value error で見ればよい」	Fujimoto 2022、TD / Bellman 系 ⁷⁵	critic diagnostics としては妥当	Bellman error 自体が value error の良い proxy ではなく、goal-distance geometry も持たない	distance-binned value propagation	同じ Bellman error でも goal 周辺からの value spread が異なる例を示す

ありうる査読コメント	背後にある既存指標 / 論文	objection が妥当な理由	それでも完全代替にならない理由	あなたの残る貢献	必要な防御実験
「既存 benchmark で十分だから新 framework は不要」	FrozenLake, MiniGrid, MiniHack, Habitat, ALE 67	benchmark 自体は豊富	問題は環境不足ではなく 解析の lens 不足	benchmark-agnostic metric family	同じ既存 benchmark 上で、既存 metrics と提案 metrics の ranking reversal を示す
「rlable / Open RL Benchmark を使えばもう十分」	rlable, Open RL Benchmark 76	aggregate evaluation と reproducibility は非常に強い	first-success / re-success / consolidation / failure dependence を持たない	event-conditioned layer を追加	rlable と提案 metrics を併用し、両者が補完的であることを示す

総合評価と、論文化するための設計

最終判断として、**このテーマは論文になる**。ただし、強い論文にするには「新しい metric をいくつか提案しました」では弱い。必要なのは、**evaluation framework** としての form を与えることである。具体的には、

1. success を phase 分解する明確な taxonomy を定義し、
2. 各指標の formal definition と log requirements を与え、
3. 既存 metrics との inclusion / exclusion relationship を整理し、
4. 既存 metrics では同順位でも提案 metrics では大きく差が出る concrete cases を示し、
5. 既存 benchmark 群の上で algorithm-agnostic に再現する、

という構造が必要になる。これは measurement paper としてかなり筋が良い。 71

最も有望な framing は次の通りである。

「疎報酬・確率遷移・不可逆失敗環境において、既存 RL 指標は‘成功’を単一数値に潰しすぎる。われわれは **success を discovery, reproducibility, consolidation, efficiency, failure dependence, value propagation に分解する診断的評価フレームワークを提案し、既存ベンチマーク上で ranking reversal と failure mode attribution を示す**」。この framing なら、先行研究との関係は明確で、しかも novelty も十分に立つ。 77

限界としては、今回の調査は主要一次情報をかなり広く押さえている一方で、国内研究会や niche workshop の未整理 PDF 群までは完全網羅ではない。また、「post-discovery robustness」「policy stability after first success」のような語は、少なくとも主要公開文献では標準的定着語ではなく、**あなたが命名を与えうる余地**が残っている。逆に言えば、題名・定義・実験プロトコルを丁寧に整えれば、論文としての identity を作りやすい。 78

1 7 10 14 15 32 51 74 77 <https://arxiv.org/abs/1807.06757>
<https://arxiv.org/abs/1807.06757>

- 2 44 <https://www.semanticscholar.org/paper/Visual-Reinforcement-Learning-with-Imagined-Goals-Nair-Pong/3aadab924520c58be81781aafd51e6807e9c4576>
<https://www.semanticscholar.org/paper/Visual-Reinforcement-Learning-with-Imagined-Goals-Nair-Pong/3aadab924520c58be81781aafd51e6807e9c4576>
- 3 5 30 38 75 <https://arxiv.org/abs/2201.12417>
<https://arxiv.org/abs/2201.12417>
- 4 39 40 <https://openreview.net/forum?id=rQYyXqHPgZR>
<https://openreview.net/forum?id=rQYyXqHPgZR>
- 6 18 33 71 <https://openreview.net/forum?id=SJlpYJBKvH>
<https://openreview.net/forum?id=SJlpYJBKvH>
- 8 11 19 45 73 <https://arxiv.org/abs/1912.05663>
<https://arxiv.org/abs/1912.05663>
- 9 59 60 67 https://gymnasium.farama.org/environments/toy_text/frozen_lake/
https://gymnasium.farama.org/environments/toy_text/frozen_lake/
- 12 43 72 <https://proceedings.mlr.press/v202/wang23av/wang23av.pdf>
<https://proceedings.mlr.press/v202/wang23av/wang23av.pdf>
- 13 24 78 <https://jmlr.org/papers/v25/23-0183.html>
<https://jmlr.org/papers/v25/23-0183.html>
- 16 <https://vladlen.info/papers/navigation-evaluation.pdf>
<https://vladlen.info/papers/navigation-evaluation.pdf>
- 17 <https://arxiv.org/abs/2103.08022>
<https://arxiv.org/abs/2103.08022>
- 20 34 Deep Reinforcement Learning at the Edge of the Statistical Precipice
https://arxiv.org/abs/2108.13264?utm_source=chatgpt.com
- 21 Deep Reinforcement Learning at the Edge of the Statistical ...
https://proceedings.neurips.cc/paper_files/paper/2021/file/f514cec81cb148559cf475e7426eed5e-Paper.pdf?utm_source=chatgpt.com
- 22 35 Evaluating the Performance of Reinforcement Learning Algorithms
https://arxiv.org/abs/2006.16958?utm_source=chatgpt.com
- 23 Evaluating the Performance of Reinforcement Learning ...
https://proceedings.mlr.press/v119/jordan20a/jordan20a.pdf?utm_source=chatgpt.com
- 25 36 <https://arxiv.org/abs/1902.07198>
<https://arxiv.org/abs/1902.07198>
- 26 <https://proceedings.mlr.press/v97/agarwal19e/agarwal19e.pdf>
<https://proceedings.mlr.press/v97/agarwal19e/agarwal19e.pdf>
- 27 69 <https://arxiv.org/abs/1901.10995>
<https://arxiv.org/abs/1901.10995>
- 28 37 <https://openreview.net/forum?id=3X65eaS4PtP>
<https://openreview.net/forum?id=3X65eaS4PtP>
- 29 https://hal.science/hal-03454640v1/file/Reversibility_Aware_Reinforcement_Learning__NeurIPS_.pdf
https://hal.science/hal-03454640v1/file/Reversibility_Aware_Reinforcement_Learning__NeurIPS_.pdf

- 31 <https://proceedings.mlr.press/v162/fujimoto22a/fujimoto22a.pdf>
<https://proceedings.mlr.press/v162/fujimoto22a/fujimoto22a.pdf>
- 41 47 52 76 <https://github.com/google-research/rliable>
<https://github.com/google-research/rliable>
- 42 <https://www.cs.utexas.edu/~ml/papers/cohen.corl22langrob.pdf>
<https://www.cs.utexas.edu/~ml/papers/cohen.corl22langrob.pdf>
- 46 <https://jmlr.org/papers/v18/15-636.html>
<https://jmlr.org/papers/v18/15-636.html>
- 48 https://www.researchgate.net/publication/358143418_PONI_Potential_Functions_for_ObjectGoal_Navigation_with_Interaction-free_Learning
https://www.researchgate.net/publication/358143418_PONI_Potential_Functions_for_ObjectGoal_Navigation_with_Interaction-free_Learning
- 49 <https://openreview.net/pdf/18978bb6491b27dec40fbd4bf99698b011213514.pdf>
<https://openreview.net/pdf/18978bb6491b27dec40fbd4bf99698b011213514.pdf>
- 50 <https://www.nature.com/articles/s41598-025-17740-5>
<https://www.nature.com/articles/s41598-025-17740-5>
- 53 <https://arxiv.org/html/2402.03046v1>
<https://arxiv.org/html/2402.03046v1>
- 54 <https://arxiv.org/html/2310.08091v2>
<https://arxiv.org/html/2310.08091v2>
- 55 <https://proceedings.mlr.press/v205/burns23a.html>
<https://proceedings.mlr.press/v205/burns23a.html>
- 56 <https://arxiv.org/pdf/2011.02073>
<https://arxiv.org/pdf/2011.02073>
- 57 <https://arxiv.org/abs/1912.09007>
<https://arxiv.org/abs/1912.09007>
- 58 <https://arxiv.org/html/2411.08392v1>
<https://arxiv.org/html/2411.08392v1>
- 61 <https://arxiv.org/abs/2306.13831>
<https://arxiv.org/abs/2306.13831>
- 62 <https://arxiv.org/abs/2109.13202>
<https://arxiv.org/abs/2109.13202>
- 63 <https://arxiv.org/abs/1810.08272>
<https://arxiv.org/abs/1810.08272>
- 64 <https://proceedings.mlr.press/v119/cobbe20a/cobbe20a.pdf>
<https://proceedings.mlr.press/v119/cobbe20a/cobbe20a.pdf>
- 65 <https://arxiv.org/abs/1904.01201>
<https://arxiv.org/abs/1904.01201>
- 66 <https://arxiv.org/abs/1207.4708>
<https://arxiv.org/abs/1207.4708>

⁶⁸ <https://people.eecs.berkeley.edu/~pabbeel/cs287-fa09/readings/NgHaradaRussell-shaping-ICML1999.pdf>

<https://people.eecs.berkeley.edu/~pabbeel/cs287-fa09/readings/NgHaradaRussell-shaping-ICML1999.pdf>

⁷⁰ Shixiang Gu

https://dblp.org/pid/121/0550?utm_source=chatgpt.com