

疎報酬と不可逆失敗を軸にした強化学習の必読文献地図

エグゼクティブサマリー

あなたが見ている問題は、文献上では単なる「疎報酬」の一語では片づきません。実際には、**価値がどの速度で伝播するか、最初の成功をどう発見するか、成功後にそれを再現・安定化できるか、失敗が可逆か不可逆か、そして遷移の確率性が探索と学習をどの程度ゆがめるか**、という複数の軸に分解して読むのが最も生産的です。標準教科書・古典理論・探索論文・安全／可逆性論文を束ねると、この分解が最も自然です。 ¹

最短で軸を作るなら、最初に見るべき核は次の並びです。まず **TD learning** と **Q-learning** で価値伝播の骨格をつかみ、次に **potential-based reward shaping** で「報酬をどう濃くしても最適方策を壊さないか」を理解し、その上で **R-MAX** と **Robust Dynamic Programming** で「探索」と「遷移不確実性」を理論側から読む。そこから **HER**、**Leave No Trace**、**First return, then explore** に進むと、「最初の成功」「成功後の再現」「リセット可能性」の差が一気につながります。最後に **Exploration in Deep Reinforcement Learning: A Survey** で全体地図を閉じるのが、いちばん失速しにくい順番です。 ²

重要なのは、「最初の成功」と「成功の再現」は同じ問題ではないという点です。文献は前者については exploration と intrinsic motivation でかなり厚く積み上がっていますが、後者は HER、Go-Explore、reset policy、reversibility-aware RL のように別系統の論文に分散しています。したがって、あなたの研究軸を「first success」と「post-success stability」に分ける見方は、文献整理としてかなり筋が良いです。これは既存文献の配置からの推論です。 ³

Frozen Lake 型の問題設定、つまり「疎報酬・確率遷移・穴への落下のような事実上の不可逆失敗」が絡む環境では、単純な exploration bonus を増やすだけでは不十分で、**価値伝播**、**optimism under uncertainty**、**goal relabeling**、**resetability / reversibility**、**robustness to transition ambiguity** を順に読む必要があります。特に、確率滑りが本質なら curiosity 系より robust / optimistic 系の比重が上がり、失敗不可逆性が本質なら reset / reversibility 系の比重が上がります。これも文献横断からの推論です。 ⁴

選定方針

このリストは、**高被引用・古典性・現在でも参照される標準性**を優先しつつ、あなたの六つの軸に直接つながるものだけを残した「コア文献」中心の選定です。引用数は Springer / JMLR / OpenReview / Nature / Google Scholar / ADS など表示元で差が出るため、**桁感を見るための概数**として扱っています。 ⁵

日本語での入口として最も価値が高いのは、Reinforcement Learning: An Introduction ⁶ の日本語版『強化学習（第2版）』です。これは単なる入門書ではなく、今回の六軸を読むための共通言語を与える基礎書です。MIT Press ⁷ 版は 2018 年、日本語版は 2022 年に刊行されています。 ⁸

逆に、**成功再現性**や **failure semantics / resetability** を、あなたの言葉どおりの名前で体系化した「古典大サーベイ」はまだ薄いです。そこで本レポートでは、その穴を **safe RL**、**reset-based RL**、**reversibility-aware RL**、**hard-exploration** の代表文献を束ねる形で埋めています。これはこのテーマの現在地そのものです。 ⁹

比較表

以下の表で、まず全体像を一望できるようにしました。

凡例は、疎 = 疎報酬、確 = 確率遷移・遷移不確実性、不 = 不可逆失敗・resetability、発 = 成功発見、再 = 成功再現、値 = 価値伝播 です。◎は中核、○は強い関連、△は間接関連を表します。なお、この軸付け自体は論文の著者ラベルではなく、本レポートの統合的読解です。

文献	位置づけ	軸	理/ 実	環境	主概念	主な持ち帰り
Sutton & Barto 2018 10	基礎書	疎 ○ 確 ○ 不 △ 発 △ 再 △ 値 ◎	理論 +教 科書	tabular中心 + 発展話題	MDP, TD, MC, control	六軸を同じ言語 で読むための土 台。
TD learning 1988 11	古典理論	疎 △ 確 ○ 不 一 発 一 再 △ 値 ◎	理論	予測課題 / toy	temporal- difference	価値伝播の最小 単位。
Q-learning 1992 12	古典理論	疎 △ 確 ◎ 不 一 発 △ 再 △ 値 ◎	理論	tabular MDP	off-policy control	確率遷移下での 制御学習の骨 格。

文献	位置づけ	軸	理/ 実	環境	主概念	主な持ち帰り
Reward shaping 1999 ¹³	古典理論	疎 ◎ 確 △ 不 一 発 △ 再 ◎ 値 ◎	理論 +設計	一般MDP	potential-based shaping	価値伝播を速めつつ最適方策を壊さない条件。
R-MAX 2002 ¹⁴	探索理論	疎 ◎ 確 ○ 不 一 発 ◎ 再 △ 値 ○	理論	tabular MDP / stochastic game	optimism under uncertainty	first success を理論的に扱う古典。
Robust DP 2005 ¹⁵	ロバスト理論	疎 一 確 ◎ 不 △ 発 一 再 ◎ 値 ○	理論	一般MDP	ambiguity set, rectangularity	遷移曖昧性が本質なら最重要。

文献	位置づけ	軸	理/ 実	環境	主概念	主な持ち帰り
Safe RL survey 2015 16	標準サーベ イ	疎 — 確 △ 不 ◎ 発 △ 再 ◎ 値 —	サー ベ イ	既存文献横断	safety factor, safe exploration	不可逆失敗を 「探索過程の問題」として読む 入口。
Pseudo- counts 2016 17	探索基盤	疎 ◎ 確 △ 不 — 発 ◎ 再 — 値 △	理論 +実 験	non-tabular / Atari系	density model, pseudo-count	count-based exploration を deep RL に拡 張。
Curiosity 2017 18	探索基盤	疎 ◎ 確 △ 不 — 発 ◎ 再 △ 値 △	実験 中心	VizDoom, Super Mario Bros	intrinsic reward, inverse dynamics	外部報酬がほぼ 無いときの標準 解法。

文献	位置づけ	軸	理/ 実	環境	主概念	主な持ち帰り
HER 2017 19	疎報酬の標準	疎 ◎ 確 △ 不 一 発 ◎ 再 ◎ 値 ○	実験 中心	robot manipulation	goal relabeling	「失敗を別目標の成功に変換」して学習密度を上げる。
Leave No Trace 2018 20	resetability	疎 △ 確 △ 不 ◎ 発 △ 再 ◎ 値 △	実験 中心	robotics tasks	forward/reset policy	成功学習の前提である「再試行可能性」を学習する。
First return, then explore 2021 21	hard exploration	疎 ◎ 確 △ 不 △ 発 ◎ 再 ◎ 値 △	実験 中心	Montezuma, Pitfall	archive, return-then-explore, robustify	first success と post-success robustification を分離。

文献	位置づけ	軸	理/ 実	環境	主概念	主な持ち帰り
There Is No Turning Back 2021 22	reversibility	疎 △ 確 △ 不 ◎ 発 △ 再 ◎ 値 —	理論 +実 験	synthetic tasks, Sokoban	temporal order, reversibility	不可逆性そのものを自己教師ありで測る。
Exploration survey 2022 23	標準サーベイ	疎 ◎ 確 △ 不 △ 発 ◎ 再 △ 値 △	サー ベ イ	既存文献横断	count, curiosity, goal-based, memory	現代探索法の地図として最も使いやすい。

厳選文献詳解

1. Richard S. Sutton ²⁴ と Andrew G. Barto ²⁵ の Reinforcement Learning: An Introduction (2018, MIT Press, ISBN 9780262039246, 日本語版あり)

読む理由は、いまの六軸を別々の流派ではなく「同一の MDP / value function / return / exploration language」で再記述できるからです。特に、TD、MC、control、eligibility traces、planning を同じ地盤で比較できるので、後で exploration 論文や reversibility 論文を読んでも、問題のどこをいじっているかが見失いませぬ。書誌統合ベースで引用数は約 9 万超と桁違いで、日本語版も手に入るため、最初の一冊としての費用対効果が圧倒的です。接続先は TD、Q-learning、reward shaping、HER、safe RL のすべてです。 ¹⁰

2. Sutton の “Learning to Predict by the Methods of Temporal Differences” (1988, Machine Learning, DOI: 10.1007/BF00115009)

これは価値伝播の原点です。この論文は、従来が「予測値と最終結果の差」で credit assignment していたのに対し、「時間的に隣接する予測の差」で credit assignment する方法を導入しました。疎報酬で苦しいとき、最終的には「報酬が遠いから悪い」のではなく「価値が途中状態へ届くのが遅い」ことが本質なので、その意味でこの論文は今でも中核です。引用数は少なくとも約 4 千規模で、索引によってはさらに高く計上されます。Q-learning、eligibility traces、reward shaping を読む前提として必読です。 ¹¹

3. Christopher J.C.H. Watkins ²⁶ と Peter Dayan ²⁷ の “Q-learning” (1992, Machine Learning, DOI: 10.1007/BF00992698)

これは「遷移が確率的で未知でも、action value を直接学んで最適制御へ行く」古典です。抽象だけ見ると当たり前に見えますが、実際には off-policy 制御と収束保証を組み合わせたことで、その後の膨大な value-based RL の土台になりました。あなたの軸では特に **確率遷移** と **価値伝播** の接点を押さえるために重要で、成功再現性を語るときも、何を安定化したいのかは結局 Q の学習対象として定義されます。引用数は約 2.1 万です。HER や多くの off-policy 系は、この系譜の上にあります。 ¹²

4. Andrew Y. Ng ²⁸、Daishi Harada ²⁹、Stuart Russell ³⁰ の“Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping” (1999, ICML, DOI未確認・公式ページあり)

「報酬を濃くしたいが、最適方策を壊したくない」という問題に対する古典的解答です。この論文が示したのは、potential-based shaping なら policy invariance を保てるということでした。疎報酬問題で reward shaping はすぐ思いつきますが、雑にやると別問題になります。この論文を読むと、

「価値伝播を速くする」と「問題設定を捻じ曲げる」を切り分ける軸が立ちます。引用数は約 3 千規模です。HER や RUDDER 的発想と比べると、人手設計の potential を要求するかわりに理論の見通しが良い、という位置づけです。 ¹³

5. Ronen I. Brafman ³¹ と Moshe Tennenholtz ³² の“R-MAX” (2002, JMLR 3:213–231, 公式ページあり)

first success の理論側を読むなら、これは極めて重要です。R-MAX は未知領域を楽観的に初期化し、探索と活用のジレンマを「optimism under uncertainty」に吸収します。要するに、「まだ知らないところは良いかもしれない」とみなして、理論保証つきで成功発見へ進む設計です。疎報酬・希少成功・サンプル効率という問題を、deep 以前にどう定式化したかを学ぶには最適です。引用数は約 1.7 千です。Bellemare の pseudo-count や後の探索ボーナス群は、実用面では別方向へ伸びましたが、思想的な祖先はここにあります。 ¹⁴

6. Garud N. Iyengar ³³ の“Robust Dynamic Programming” (2005, Mathematics of Operations Research, DOI: 10.1287/moor.1040.0129)

Frozen Lake 型の「滑る」「遷移がぶれる」「モデルがずれる」を真正面から読むなら、この論文は外せません。Iyengar は、遷移確率に ambiguity set を置いた robust DP を定式化し、**rectangularity** 条件のもとで有限・無限 horizon DP の結果が robust counterpart に拡張されること、さらに robust DP が完全情報ゼロ和ゲームに等価であることを示しました。これは exploration 論文ではなく、**確率遷移の信頼できなさそのもの**を主題化した理論です。引用数は約 1 千です。探索ボーナスで解くべき問題と、ロバスト化で解くべき問題を見分ける軸を与えます。 ³⁴

7. Javier García ³⁵ と Fernando Fernández ³⁶ の“A Comprehensive Survey on Safe Reinforcement Learning” (2015, JMLR 16:1437–1480, 公式ページあり)

このサーベイの価値は、「失敗不可逆性」を単なる性能低下ではなく、**探索過程の安全性問題**として整理しているところです。論文は safe RL を、最適化目的そのものに safety factor を入れる方向と、探索過程を外部的知識やリスク指標で制約する方向に大別します。あなたの問題設定では、穴に落ちる・戻れない・再試行コストが高い、という性質をどう読むかのメタ枠として非常に有用です。引用数は約 2 千超で、この領域の標準入口です。日本語メタデータも CiNii で引けます。 ¹⁶

8. Marc Bellemare ³⁷ ほかの“Unifying Count-Based Exploration and Intrinsic Motivation” (2016, NeurIPS 29, 公式ページあり)

これは、count-based exploration を非 tabular 領域へ持ち込む要の論文です。密度モデルから **pseudo-count** を作り、「訪問回数」を直接数えられない状況でも count-based bonus の考え方を使えるようにしました。疎報酬で first success を掘り当てて、理論的にも実装的にもつなぐ橋です。引用数は約 2.1 千です。Pathak の curiosity や RND と並ぶ modern exploration の核であり、R-MAX 的な optimism を deep RL の文脈へ翻訳したものとして読むと理解しやすいです。 ¹⁷

9. Deepak Pathak ³⁸ ほかの “Curiosity-driven Exploration by Self-supervised Prediction” (2017, ICML / PMLR 70, 公式ページあり)

curiosity 系の定番です。外部報酬が極端に疎、あるいは無いときに、行動結果の予測誤差そのものを内発的報酬にします。重要なのは、画像のピクセル予測ではなく、inverse dynamics で学んだ feature space 上で予測誤差をとることで、高次元観測にもスケールさせた点です。論文は sparse extrinsic reward、reward-free exploration、unseen scenarios への generalization の三設定を実験しており、VizDoom と Super Mario Bros で効果を示しました。引用数は約 3.8 千です。Bellemare が数え上げる系、Pathak が自己教師あり予測系、という整理で読むと、その後の survey が格段に見やすくなります。 ¹⁸

10. Marcin Andrychowicz ³⁹ ほかの “Hindsight Experience Replay” (2017, NeurIPS 30, arXiv: 1707.01495)

これは、疎報酬・goal-conditioned RL の標準です。アイデアは非常に強く、**失敗エピソードを、達成してしまった別目標に対する成功エピソードとして再ラベルし直すことで、希少な成功信号を人工的に増やします**。論文自身も「implicit curriculum」と表現しており、あなたの言葉で言えば「最初の成功を見つけたあと、その周辺で再成功可能性を増やす」装置です。ロボットマニピュレーションでサンプル効率を改善し、引用数は約 3.8 千です。reward shaping が人手で potential を入れるのに対し、HER は目標表現側で学習密度を上げると理解するとよいです。 ¹⁹

11. Benjamin Eysenbach ⁴⁰ ほかの “Leave no Trace: Learning to Reset for Safe and Autonomous Reinforcement Learning” (2018, ICLR, arXiv:1711.06782)

これは resetability を主題化した代表論文です。forward policy だけでなく **reset policy** を同時に学習し、さらに reset policy の value function を使って「このまま進むと非可逆状態に入りそうか」を検知して safety abort します。外から見ると探索手法ですが、より本質的には「研究者や人間が毎回リセットしてやる」前提を崩す論文です。成功発見そのものより、再試行可能性をどう確保するか、失敗をどう安く抑えるか、という観点で読むべきです。引用数は約 200 です。Go-Explore の robustify とも、There Is No Turning Back の reversibility 推定とも自然につながります。 ²⁰

12. Adrien Ecoffet ⁴¹ ほかの “First return, then explore” (2021, Nature, DOI: 10.1038/s41586-020-03157-9)

あなたの「成功発見」と「成功再現」を最も明確に切り分けた必読論文は、実質これです。Go-Explore は、**promising state を保存し、まずそこへ確実に戻ってから探索し、最後に robustify する**という原理で hard exploration を解きます。ここで重要なのは、first success と robust execution を同時にやらないことです。最初に“見つける”局面と、その後“再現可能にする”局面を分離したからこそ、Montezuma’s Revenge や Pitfall で劇的に前進しました。引用数は索引差があるものの概ね 400–600 規模です。あなたの研究軸に最も近い、実質的な基準点です。 ²¹

13. Nathan Grinsztajn ⁴² ほかの “There Is No Turning Back: A Self-Supervised Approach for Reversibility-Aware Reinforcement Learning” (2021, NeurIPS 34, 公式ページあり)

この論文の新規性は、**可逆性 / 不可逆性それ自体を自己教師ありで測る点**にあります。具体的には、trajectory 上の観測ペアについて時間順序を当てる surrogate task を学び、その temporal order から reversibility を近似します。論文は exploration 用の RAE と control 用の RAC を提案し、Sokoban を含む環境で、失敗や side effect を減らし、場合によっては reward function を使わずに safer behavior が出ることを示しました。引用数はまだ約 30 と新しいですが、failure semantics / reversibility 軸では代表的です。Leave No Trace が「戻す policy」を学ぶのに対し、こちらは「戻せるかどうかの性質」を学ぶ論文です。 ²²

14. Pawel Ladosz ⁴³ ほかの “Exploration in Deep Reinforcement Learning: A Survey” (2022, Information Fusion, DOI: 10.1016/j.inffus.2022.03.003)

いま探索の地図を一枚で持つなら、このサーベイが最も実用的です。論文は、疎報酬で reward が稀

なために action-reward association が難しくなり、より洗練された exploration が必要になると明示し、count-based, intrinsic motivation, memory / archive, goal-based などの流れを整理しています。引用数は約 800 です。古典理論の代わりにはなりません、あなたがこれから論文の波に飲まれないための“索引”として極めて有効です。Bellemare、Pathak、HER、Go-Explore をどこに置けばいいかが、この一冊でかなり整います。 23

論文間の関係と年表

ここまでの関係を一言でまとめると、**Sutton の credit assignment が Watkins の control に伸び、Ng が shaping の安全条件を与え、R-MAX が first success を理論化し、Bellemare / Pathak / HER が sparse reward の現代解法を作り、Eysenbach / Ecoffet / Grinsztajn が resetability • robustification • reversibility を前景化した**、という流れです。Ladosz のサーベイはその現代探索地図、Iyengar と García はそれぞれ stochasticity と failure semantics を理論側から支える位置にあります。 44

flowchart LR

```
SB["Sutton & Barto"] --> TD["TD learning"]
TD --> Q["Q-learning"]
TD --> RS["Reward shaping"]
Q --> RMAX["R-MAX"]
RMAX --> PC["Pseudo-counts"]
PC --> CUR["Curiosity"]
PC --> GO["First return, then explore"]
CUR --> SURV["Exploration survey"]
PC --> SURV
GO --> SURV
RS --> HER["HER"]
Q --> HER
HER --> GO
RDP["Robust DP"] --> SAFE["Safe RL survey"]
SAFE --> LNT["Leave No Trace"]
LNT --> TNB["There Is No Turning Back"]
GO --> TNB
```

出版年の流れは次のように読むと見通しが立ちます。最初は value propagation と control の骨格、その次に shaping と sample-efficient discovery、その後に safe / robust / deep exploration / resetability / reversibility が乗ってきます。 45

timeline

```
title 主要文献の年表
1988 : TD learning
1992 : Q-learning
1999 : Reward shaping
2002 : R-MAX
2005 : Robust Dynamic Programming
2015 : Safe RL survey
2016 : Pseudo-counts
2017 : Curiosity
      : HER
2018 : Leave No Trace
```

2021 : First return, then explore
: There Is No Turning Back
2022 : Exploration survey

この年表から見てくるのは、“成功発見”の文献は厚いが、“成功再現性”は reset / robustify / reversibility に散在しているという非対称性です。したがって、研究テーマを立てるときは「探索の改良」一本に寄せるより、探索と再現を分けた problem formulation にした方が新規性を考えやすい、というのが自然な読みです。これは文献配置からの推論です。 3

読書順

いちばん無難なのは、理論の骨格 → 疎報酬の現代解法 → 不可逆失敗と再試行性という順です。まず教科書で chapter-wise に MDP, TD, control を押さえ、そのあと TD 論文と Q-learning 論文へ戻る。そこで value propagation の骨格が入ったら reward shaping を挟み、R-MAX と Robust DP を読む。この時点で「希少成功の発見」と「滑る環境での遷移不確実性」を理論的に分けて見られるようになります。そこから HER と Go-Explore を読むと、success discovery と success reproducibility の差が実感に変わります。最後に Leave No Trace と There Is No Turning Back を読むと、失敗不可逆性を exploration の副作用ではなく、独立した意味論として捉えられます。 46

もし時間が限られているなら、最小コアは次の八本です。

① Sutton & Barto、② TD learning、③ Q-learning、④ reward shaping、⑤ R-MAX、⑥ HER、⑦ Leave No Trace、⑧ First return, then explore。

この八本で、価値伝播、成功発見、成功再現、不可逆失敗というあなたの主軸はほぼ一周できます。Ladosz の survey はそのあとで「抜けている探索系統」を埋める索引として読むのが効率的です。 47

反対に、最初から survey を大量に読むのは、今の段階では必ずしも得策ではありません。探索 survey は便利ですが、軸がないまま入ると count-based ・ curiosity ・ goal-based ・ model-based ・ memory-based を同列に眺めて終わりやすいからです。いまのあなたの状況なら、すでに自分の実験から軸が出ているので、survey は最初ではなく「骨格を作った後の圧縮装置」として使う方が強いです。これは文献の役割差からの実践的判断です。 48

学習計画

下の計画は、二週間で「軸を持って論文海へ入る」ための最低限のロードマップとして組んでいます。各ブロックで「読んだ事実」だけでなく、「自分の問題に引きつけたメモ」を必ず一枚残す想定です。

期間	目的	読むもの	その日の到達目標
初日から二日目	共通言語の確立	Sutton & Barto の MDP / TD / control 関連章 8	疎報酬・確率遷移・不可逆失敗を MDP の語彙で言い換える。
三日目	価値伝播の骨格	TD learning、Q-learning 49	「報酬が遠い」と「価値が届かない」を区別して説明できる。
四日目	報酬設計の軸	Reward shaping 50	shaping が問題変形になる条件と、ならない条件を整理する。

期間	目的	読むもの	その日の到達目標
五日目 から六 日目	first success の 理論	R-MAX、Robust DP ⁵¹	optimism と robustness を混同せずに説明できる。
七日目 から八 日目	sparse reward の 現代探索	Pseudo-counts、 Curiosity、Exploration survey の該当箇所 ⁵²	count-based と curiosity-based の違いを表にする。
九日目	失敗から学 ぶ	HER ⁵³	「失敗の再ラベル」が value propagation をどう補うかを書く。
十日目 から十 一日目	再試行可能 性と成功再 現	Leave No Trace、First return, then explore ⁵⁴	first success と post-success stability を別タスクとして定義する。
十二日 目	不可逆失敗 の意味論	Safe RL survey、There Is No Turning Back ⁵⁵	failure semantics / resetability / reversibility の語彙を固定する。
十三日 目から 十四日 目	研究テーマ 化	上のノートを統合し、必 要なら Exploration survey を戻り読み ⁵⁶	研究仮説を三本に絞る。例: 「成功発見と成功再現を分離した評価系」「stochastic slippage 下の value propagation」「reset cost を含む sparse-reward MDP」。

この計画のポイントは、毎日「**自分の問題にどう移植されるか**」を一枚に要約することです。特に最後の二日では、論文要約ではなく、**自分の問題定義**を更新することが重要です。文献を読む前より、状態・失敗・成功・再現・リセットの定義が精密になっていれば成功です。 ⁵⁷

限界と注意点

このリストは「今すぐ研究軸を立てる」ことを優先したため、**補助必読**としてはまだ二つ残っています。ひとつは Kearns と Singh の **E³** で、R-MAX と並ぶ理論的探索古典です。もうひとつは 2019 年の **Safety Gym** で、不可逆失敗を benchmark としてどう測るかを見るには価値があります。今回のコアに入れなかったのは、軸を立てる最短経路では R-MAX と García / Leave No Trace / reversibility 論文の方が先に効くと判断したからです。 ⁵⁸

もうひとつの注意は、**引用数の多さと、あなたの問題への適合性は一致しない**ことです。たとえば curiosity 系は高被引用ですが、環境ノイズや controllability の低さが本質だと、必ずしも第一選択ではありません。逆に、引用数が低めでも Leave No Trace や There Is No Turning Back は、あなたの「失敗不可逆性」「成功再現性」の軸にはかなり直接的です。したがって、文献の読む順番は「引用数降順」ではなく、「自分の問題分解との一致度順」で決めるのが正解です。これは本レポート全体の中心的な結論です。 ⁵⁹

¹ ⁶ ⁸ ¹⁰ ²⁷ ²⁸ ²⁹ ⁴⁶ ⁴⁷ ⁵⁷ <https://mitpress.ubli.sh.com/book/reinforcement-learning-an-introduction-2>

<https://mitpress.ubli.sh.com/book/reinforcement-learning-an-introduction-2>

² ¹¹ ²⁴ ⁴⁰ ⁴¹ ⁴⁴ ⁴⁵ ⁴⁹ <https://link.springer.com/article/10.1007/BF00115009>

<https://link.springer.com/article/10.1007/BF00115009>

- 3 17 52 <https://proceedings.neurips.cc/paper/2016/hash/afda332245e2af431fb7b672a68b659d-Abstract.html>
<https://proceedings.neurips.cc/paper/2016/hash/afda332245e2af431fb7b672a68b659d-Abstract.html>
- 4 14 37 39 42 51 <https://www.jmlr.org/papers/v3/brafman02a.html>
<https://www.jmlr.org/papers/v3/brafman02a.html>
- 5 <https://scholar.google.com/citations?hl=en&user=6m4wv6gAAAAJ>
<https://scholar.google.com/citations?hl=en&user=6m4wv6gAAAAJ>
- 7 23 30 31 48 56 <https://www.sciencedirect.com/science/article/abs/pii/S1566253522000288>
<https://www.sciencedirect.com/science/article/abs/pii/S1566253522000288>
- 9 16 25 35 38 43 55 <https://jmlr.org/papers/v16/garcia15a.html>
<https://jmlr.org/papers/v16/garcia15a.html>
- 12 26 33 <https://www.gatsby.ucl.ac.uk/~dayan/papers/wd92.html>
<https://www.gatsby.ucl.ac.uk/~dayan/papers/wd92.html>
- 13 <https://robotics.stanford.edu/~ang/papers.php>
<https://robotics.stanford.edu/~ang/papers.php>
- 15 34 <https://pubsonline.informs.org/doi/10.1287/moor.1040.0129>
<https://pubsonline.informs.org/doi/10.1287/moor.1040.0129>
- 18 59 <https://proceedings.mlr.press/v70/pathak17a.html>
<https://proceedings.mlr.press/v70/pathak17a.html>
- 19 36 53 <https://arxiv.org/abs/1707.01495>
<https://arxiv.org/abs/1707.01495>
- 20 54 <https://openreview.net/forum?id=S1vuO-bCW>
<https://openreview.net/forum?id=S1vuO-bCW>
- 21 <https://www.nature.com/articles/s41586-020-03157-9>
<https://www.nature.com/articles/s41586-020-03157-9>
- 22 https://proceedings.neurips.cc/paper_files/paper/2021/file/0e98aeeb54acf612b9eb4e48a269814c-Paper.pdf
https://proceedings.neurips.cc/paper_files/paper/2021/file/0e98aeeb54acf612b9eb4e48a269814c-Paper.pdf
- 32 50 <https://robotics.stanford.edu/~ang/papers/shaping-icml99.ps>
<https://robotics.stanford.edu/~ang/papers/shaping-icml99.ps>
- 58 <https://link.springer.com/article/10.1023/A%3A1017984413808>
<https://link.springer.com/article/10.1023/A%3A1017984413808>