

研究説明

藤田研卒 藤井 和希

勉強の進捗

- 勉強の進捗


- 強化学習: ハイパラを変えてひたすら試行錯誤する経験は少し積んだ。アルゴリズム (PPOなど) はまだ理解できていないので、勉強中。現在は REINFORCE の理解に取り組む中。
- ニューラルネット: 実装するだけなら少しはできる。Transformer などは実装例をそのまま移植するだけならできる。



<https://qiita.com/key353/items/79a6f7b674dd1ce515cc>

<https://www.youtube.com/watch?v=vQYNYtJH7k>


強化学習とは？




具体例

迷路の問題。
AIは左上のスタートから
右下のゴールへ向かう。

エージェント



AIは、どのマスの時にどう
動けばゴールに辿り着け
るかを学習する。



仕事の問題意識

- **仕事の概要**

- 仕事の目的は、シミュレータ上で、より良い学習済みモデルを作れるような設定値を探していくこと。
- 普段の作業としては、ハイパラなどの設定を色々いじって、結果を見て振り返りして、また設定をいじる、というのを日々繰り返している。

- **感じた課題**

- 課題1: 計算機のリソースに限りがあり、全ての設定値を網羅的に試すことができない。
- 課題2: 強化学習は学習結果が大変ぶれやすく、全く同じ設定でやっても結果が大きく変わる時がある。

- **強化学習特有？の意識**

- あくまで「他の設定値よりも良い設定値を見つけ出していく」ことが目的であって、他の設定に対して相対優位であることが必要。特定のノルマ基準を最短で超える、ような意識はない。

- **以上のことから考えた、研究の方向性**

- 「少ない計算リソースの中でも、他よりも相対優位な設定値を見つけていく方法」

強化学習で、ある設定が良いとどうやったら分かるのか？

- 設定値の性能評価に関わる要因 = 環境 × アルゴリズム × 予算

- 環境 = 環境ファミリー × 環境因子
- アルゴリズム = 手法 × ハイパラ
- 予算 = seed × episode

- 環境ファミリー: どのような問題設定の環境か
- 環境因子: 環境の持つ要素は何か
- 手法: PPOか、Q学習か
- ハイパラ: バッチサイズや学習率はどれだけか
- seed: 乱数条件を変えて、何回独立に学習・評価させるか
- episode: 1seedあたり、何episode分学習させるか

手順としては、

- ①与えられた環境のなかで、
 - ②アルゴリズムを選択して、
 - ③限られた計算予算で学習と評価を行う。
- という大きく3ステップがある。


②で、良い設定値を見つけていく。

③で、その設定値が本当に良いのか/悪いのかを判断する。


強化学習で、ある設定が良いとどうやったら分かるのか？

- 設定値の性能評価に関わる要因 = 環境 × アルゴリズム × 予算
 - 環境 = 環境ファミリー × 環境因子
 - アルゴリズム = 手法 × ハイパラ
 - 予算 = seed × episode


- 迷路
- ・ ベース環境




- 迷路
- ・ 失敗終端(穴)がある場合
- ・ 確率遷移(滑る)場合



- 迷路
- ・ 複合タスク(鍵を拾ってドアを開けて進む)




- カートポール
- ・ 環境因子は特になし




強化学習で、ある設定が良いとどうやったら分かるのか？

- 設定値の性能評価に関わる要因 = 環境 × アルゴリズム × 予算
 - 環境 = 環境ファミリー × **環境因子**
 - アルゴリズム = 手法 × ハイパラ
 - 予算 = seed × episode


- 迷路
- ・ベース環境



- 迷路
- ・失敗終端(穴)がある場合
- ・確率遷移(滑る)場合



- 迷路
- ・複合タスク(鍵を拾ってドアを開けて進む)



・同じ環境ファミリー(迷路)でも、環境因子によって、アルゴリズムの「学びやすさ」「学習の不安定さ」は大きく変わる。

・「少ない計算リソースの中でも、他よりも相対優位な設定値を見つけていく」上で、環境因子がどう作用してくるのかを調べたい。

・上記のことが分かると、例えば「今回の環境は○○の環境因子があるから、episodeは少なくてもいいけどseedは多い方が良いな」などの判断に繋がる。

既存研究

- 設定値の性能評価に関わる要因 = 環境 × アルゴリズム × 予算
 - 環境 = 環境ファミリー × 環境因子
 - アルゴリズム = 手法 × ハイパラ
 - 予算 = seed × episode

- Henderson et al.
 - RL実験では、seed、環境の確率性、実装、評価手順によって結果が揺れやすい
- Agawal et al.
 - 特にDeep RLでは、少数runの点推定だけに基づく比較が不安定な結果を生みうる
- Andrychowicz et al.
 - オンポリシーRLの実装には多数の設計選択があり、それらが性能に強く影響する。アルゴリズムだけでなく、実装上の設計やハイパラ、環境因子といったものに強く左右される。
- Adkins et al.
 - RL性能がハイパラに強く依存し、環境ごとに異なる設定が必要になる
- Patterson et al.
 - CHS
- Jamieson & Talwalkar
 - ハイパラ最適化を non-stochastic best-arm identificationとして定式化し、限られたリソースで最良候補を同定する問題を扱っている。
- bsuite
 - RL agentの中核的能力や失敗要因を調べるための、慎重に設計された小規模実験群

聞きたいこと

○この研究について

- ・今の段階で、研究テーマとしてどこが一番弱く見えますか

○研究一般について

- ・論文の主張は、どこまで弱めても大丈夫なのか。(弱めすぎると貢献が弱くなり論文として認められなそう)

○提出先について

- ・この研究は論文誌に投稿するレベルには至らなそうなので、小さいワークショップや研究会などに出すなら、どういう出し方が良いか。(そもそもワークショップや研究会とはどういうものか)

研究テーマのイメージ

- 強化学習の理解がまだ初歩段階であり、NNも理論面は全く理解できていない。
 - →新アルゴリズムの提案、などの研究はまだ難しい。
- しかし、強化学習の試行は仕事でやっているので、そこに近いテーマならできるかもしれない。
 - →どういう問題設定の時に、強化学習の精度が落ちるのか？
 - →少ない試行回数で、良いハイパラの組み合わせを見つける方法は何か？
 - →どちらかと言えば、評価系の論文の方が取組みやすそう。

研究テーマ

- 少ない実験回数でAIのハイパラ設定を選ぶ時、どんな問題では判断を間違えやすいのか？
- 強化学習の実務では、複数のハイパーパラメータ設定を試して、良さそうな設定を選ぶことがあります。
- ただし、シミュレータが重いと、全ての候補を十分な seed数・十分な学習時間で評価できません。
- そのため、少ない予算で候補を絞るのですが、このとき本当に良い設定ではなく、たまたま序盤に良く見えた設定を選んでしまう可能性があります。
- 私の研究では、この選択ミスが、どのような環境条件で起こりやすいかを調べています。

モチベーション


- 動機

- 強化学習の仕事で、ハイパラ等を弄って AI を強くする、ということをやっている。
- 扱っているシミュレータの計算が重く、全ての候補を十分に計算させると時間がかかりすぎる。
- そのため、少ない seed や短い学習期間で、「この設定が良さそう」と判断して設定を絞り込みたい。

- 問題

- しかし、その判断が信頼できるのかは、環境によって違うはず。
- 既存研究では、「RL は学習が不安定になりやすく、seed や学習結果を減らすと結果が非常にブレやすくなる」ということまでは報告されている。
- しかし、そのブレが、どういう環境の性質を元に起こりやすくなるのかについては、明らかにされていない。


強化学習とは？




具体例

迷路の問題。
AIは左上のスタートから
右下のゴールへ向かう。

エージェント




AIは、どのマスの時にどう
動けばゴールに辿り着け
るかを学習する。



具体例

- ・ハイパラの設定の仕方によって、AIの学習性能に大きな違いが出る。
- ・最終的には設定Aも設定Bもゴールするようになるのだが、報酬の獲得量に差がある。
- ・この場合は設定Bが序盤は弱い、最終的には高いスコアを出す。


(例)2種類の設定で学習させた場合の結果



具体例

- ・設定によっては、「学習初期では強いものの、学習後半では相対的に弱くなるもの」や「学習初期は性能が低い、後半で強いもの」などがある。
- ・そのため、学習初期と後期で、強い設定のランキングが変動する。


(例)4種類の設定で学習させた場合の結果



具体例

・研究の大まかな方向性としては、「上記の点線で囲ったような、学習初期の結果」から「最終的にどの設定がwinnerになるか」を選びたい、というもの。


(例)4種類の設定で学習させた場合の結果



具体例

- ・しかし、環境には「AIが学びやすいもの」と「AIが学びにくいもの」がある。
- ・環境によっては、「学習初期の優劣」と「最終的な結果の優劣」に違いが生まれたり、そもそも結果の分散が大きくなったりしてしまう。研究内容としては、これらの現象が、どのような環境の持つ性質の下で起こりやすくなるのかを調べる。


(例)4種類の設定で学習させた場合の結果




具体例

- ・しかし、環境には「AIが学びやすいもの」と「AIが学びにくいもの」がある。
- ・環境によっては、「学習初期の優劣」と「最終的な結果の優劣」に違いが生まれたり、結果の分散が大きくなってしまう。研究内容としては、これらの現象が、どのような環境の持つ性質の下で起こりやすくなるのかを調べる。


(例)4種類の設定で学習させた場合の結果



- ・穴がある場合
- ・滑る場合



- ・鍵を拾ってドアを開けないと進めない場合



RLの性能を決める主要素

- ・RLの性能＝環境 × アルゴリズム × 予算
 - ・環境＝環境ファミリー × 環境因子
 - ・アルゴリズム＝手法 × ハイパラ
 - ・予算＝seed × episode

RLの性能を決める主要要素

・RLの性能＝環境 × アルゴリズム × ハイパラ × 予算

・環境＝環境ファミリー × 環境因子

・アルゴリズム

・ハイパラ

・予算＝seed × episode

問題：少数seed・少数episodeで勝者を選ぶ危険

既存研究との差分

- 既存研究は、RLの不安定さそのものについて調査した論文が多い。
- どの環境要因の時に、winner selection failureが生まれやすいかは明らかになっていない。

実験設計

- 8環境、Q-learning候補、reference vs low-budget

指標: practical misselection, regret

主結果:どの環境で誤選択が起こりやすいか

失敗パターン: late-bloomer elimination

現時点での弱点・迷い

聞きたいこと。

- ・研究テーマの思いつき方
- ・ワークショップとはどういうもの？出し方は？