

問題の整理

問題の構造を整理するときの方針

- 全ての問題を網羅することはない。
- まずは「試行のため」に必要な、最低限の浅い問題だけを整理する。
- 問題の構造を整理するとは
 - 原因と結果を切り分けること。その要素は原因か結果か。原因であれば、その原因から生まれる結果を、結果であればその結果を生む原因を考える。
 - 要素同士を関連づけること。

目的、目標

- 目的:

- 強化学習で特に興味深いのは、最適な解き方が「問題の持つ性質」に強く依存すること。
- 強化学習を実際に現実問題に適用していくためには、今取り組んでいる問題がどういう問題なのかを見極め、問題の持つ性質に応じて使うアルゴリズムや手法を選択する必要がある。
- そのため、手法やアルゴリズムだけでなく、問題の性質について学んでいく必要がある。
- 強化学習を現実問題に適用できるようにするために、問題の性質について学び、知識をまとめた。

- 目標:

- 抽象化した簡単な問題について、その1つ1つについて性質を探る。
- 問題同士の関係性を考察する。
- 遅延報酬や学習データの多様性などの問題について、問題に紐付けて理解する。
 - ex)遅延報酬は、それ自体で問題にはならない。別の性質と結びつくことで凶悪な問題になる。

問題意識

- 強化学習を適用させるためには、問題の性質を見極めないといけない。しかし、既存の本ではアルゴリズムのカatalog的な整理が中心であり、問題についての性質や類型についてはほとんど触れていない。
- 強化学習を適用できる問題自体はそれこそ無限にあるため全てを整理することは難しい。しかし、代表的な性質に絞って類型化・構造化することはできるはず。
- 強化学習という問題の解き方の言語については整理されている一方で、問題の型を記述する言語については十分整備されていない。

アウトプット・イメージ

- ある問題の難しいポイントが分かるようになる。
- ある問題に対して、構造を理解して、それに応じた手法を自分で考え出せる/見つけ出せるようになる。
- どういう構造を持つ問題が破綻しやすいのかが分かる。

用語メモ

- 日-英の対応は間違っている部分あり。
- 遅延報酬(delayed reward)
- 疎報酬(sparse reward)
- 複合的タスク(long-horizon compositional task)
- 時間軸の信用割り当て(multi-stage credit assignment)
-
- 疎報酬
- 遅延報酬
- 確率遷移
- 長期依存
- 部分観測
- 多峰性
- 協調/競争
- 非定常
- 安全制約
- 探索のボトルネック
- 状態表現の難しさ
-
-

疎報酬と遅延報酬

- 疎報酬: 報酬が発生する頻度や範囲が小さいこと。
 - 問題の中心は探索と情報不足。
- 遅延報酬: 報酬が帰ってくる時点が遅いこと。
 - 問題の中心は時間的な信用割り当て。
 - 行動と報酬が同時でない問題は、程度の差はあれ遅延報酬になる。
- 問題のケース
 - 疎報酬かつ遅延報酬なケース: MDPかつゴールした時のみ報酬が入るような問題は大体これ。問題によって違うのは、程度の深刻さ度合い。
 - 疎報酬だが遅延報酬でないケース: 1000本腕のうち1本しか当たりのないバンディットなど。当たりはまれだが、報酬がそのばで帰ってくるので信用割り当ては簡単。
 - 疎報酬ではないが遅延報酬なケース: 広告配信など。今日の施策の結果が 1週間後に売上として出る。でも売上シグナル自体は継続的に観測される。施策と成果に時間的ラグがあるが、報酬自体はゼロばかりでなく、観測はそこそこある。

疎報酬と遅延報酬(考察)

- 局所評価不可能性→遅延報酬

- 問題なのは「報酬が遅いこと」自体ではなく、行動の良し悪しが、その場で局所的に判断できないこと。(局所評価不可能性)
- 事例
 - 簡単な遅延報酬(固定迷路): 特に価値ベースの場合、ゴールは遠くても正しい経路に乗れば価値が逆流する。遅延はあるが局所評価可能に変換しやすい。
 - 難しい遅延報酬(ゲームAI): 「位置どり→射撃→誘導→命中」など、成功まで複数の条件が必要で途中状態の良さが局所的にわかりにくい場合。遅延だけでなく、因果の把握が難しい。
- 本当の問題は遅延報酬だけではなく、「delay」「sparsity」「multi-step dependency」「credit assignment difficulty」の組み合わせ。
- 遅延報酬の問題とは、「報酬が遅いこと」そのものではなく、「未来の成果に対する現在の行動の寄与を、中間状態の価値として局所的に回収しにくい」という問題。

疎報酬と遅延報酬(考察)

- 軸1. 成果までの時間差: 何ステップ先で成果が出るか。
 - 軸2. 成果に対する寄与の分解可能性: どの行動が効いたか分かるか
 - 軸3. 中間状態に局所的な良し悪しを定義できるか: 価値の染み出しが可能か
 - 軸4. 成功手順の安定性: 毎回似た道筋で良いか、それとも文脈によって全く違うか。
-
- 迷路が遅延報酬にも関わらず上手いくのは、価値の染み出しによって局所評価可能な問題に変換できるため。遅延した成果を、中間状態の価値として局所化できるため。
 - 価値ベースは局所化可能であるが、REINFORCEなど純粋な方策ベースではそれが弱い。

長期依存タスクと複合タスク

- 長期依存複合タスク: 報酬や結果が決まるまでに長い手順を要し、かつ複数の手順を並列でクリアする必要のあるタスク
 - 問題①: 最後に成功しても、どの行動が効いたのかわかりにくい。信用割り当てが難しい。
 - 問題②: 成功までに必要な段階が多いほど、途中で失敗しやすい。一度失敗したら最初からやり直しになるタスクは特に。
 - 問題③: 成功までの正しい列を偶然踏むのが難しい。成功体験を得づらい。探索が大変。
 - 1~2手で結果が決まる→short-horizon。結果を得るまでに10~100手以上が必要→long-horizon
- 長期依存タスク: 欲しい結果を得るために、長い手順を要するタスク。
- 複合タスク: 欲しい結果を得るために、複数の手順を並列でクリアする必要のあるタスク

局所解と過学習

- 局所解: 密な報酬/罰則がある場合に起こる可能性がある。エージェントが本来されるべき最終目標を達成せず、補助のために用意した報酬や罰則を最優先にした行動に陥ってしまうこと。
 - 設計者側が意図したゲームと、エージェントの想定したゲームに違いが生まれること。
- 過学習: 学習時の環境に最適化されすぎてしまい、別の環境で上手く行動できなくなること。

確率遷移とは何か

- 確率遷移下では、エージェントが学ぶのは「この行動を取れば必ずこうなる」という因果ではなく、「この行動を取ると、平均的にはこうなりやすい」という傾向になる。
- 最適行動は可能か: 確率遷移環境では、最適方策を学んでも最短での成功は保証されない。ただし、期待収益の面では最適性を達成しうる (穴のないFrozenLakeなど)
- 2つの問題があるとして、その期待値は同じでも、分散の大きいものの方が期待値の推定が難しくなる。同様に、エージェントが得る経験サンプルの分散が大きいと、正しい期待値推定のために必要なサンプル数が多くなる。期待値の推定誤差が大きくなりやすい。そのため、確率遷移は学習が難しくなる。
- 要約すれば、確率遷移は、価値推定に高分散ノイズを導入し、行動間の真の優劣の識別を難しくする。
- 探索と活用のトレードオフは確定遷移でも存在する。しかし確率遷移では、同じ行動の結果がブレるため、行動価値の推定誤差が大きくなり、探索を打ち切るべきか継続すべきかの判断がより一層難しくなる。
- また、確定環境の元では、確率遷移の下では、最適軌跡でも成功 / 失敗する場合があるし、同様に非最適軌跡でも成功 / 失敗が混在する。観測された結果だけでは、行動系列の質を素直に判定しづらくなる。

確率遷移とは何か2

- 確率遷移の結果として生まれる問題
 - 経験のばらつきが大きく、推定誤差が大きくなる。
 - また、一度の成功/失敗を見ても、その軌跡の良し悪しを判断することが難しい。
- 確率遷移の結果生まれる問題が起こる原因
 - 同じ状態と行動でも、次状態や報酬が変化する。
 - 確定遷移とは違い、学ぶべきものが期待值的な傾向になる。
- 確率遷移によって生まれる課題
 - 推定誤差が大きくなるので、確率推定に多くのサンプルが必要。
 - 行動間の真の優劣が見えにくくなる。
 - 探索の打ち止めタイミングの判断が難しい。
- 他要素との掛け算
 - 疎報酬、遅延報酬、long-horizon、部分観測、非定常性と組み合わせると、難易度は足し算的ではなく掛け算的に増していく。

確率遷移とは何か3

- Flozen Lakeの難しさ
 - Flozen Lakeでは保守的な行動が好まれやすい。
 - それは、確率遷移なので分散が大きいからというよりも、「1回のミスが致命的」「失敗状態が吸収的」「回復不能」だからでもある。
 - Flozen Lakeの難しさは、確率遷移単体によるものというよりも「確率遷移 ×失敗の不可逆性×疎報酬」の掛け合わせが難しさの要因になっている。
- これもやはり、確率遷移単体の難しさもそうだが、他の「失敗の不可逆性」や「遅延報酬」とかけ合わさった時に生まれる新しい課題としてどんなものがあるかについて考えたい。


部分観測とは何か

環境の非定常性とは何か。

- 環境の非定常性とは、環境の遷移則や報酬則が時間と共に変わること。
- ただし、その変化が状態として観測できるなら、拡張状態を導入して定常問題として扱える。
 - 観測可能な変化: 観測に組み込めば、定常 MDPに戻せる。
 - 観測不能な変化: エージェントから見ると非定常になる。
- 具体ケース
 - ケースA(定常MDP): 毎回ゴールが変わるが、状態を「自分位置」「ゴール位置」として見れる。
 - ケースB(非定常): 毎回ゴールが変わるが、エージェントに知らされない。
- ただし、上記のケースBは部分観測の問題を含んでいる。最初の定義に従うのであれば、非定常性と部分観測は関連した概念になるはず。追加で考えたい。


問題の構造

- 要因1. タスク構造
 - 1-1. 成功まで長い行動列が必要
 - 1-2. 成功条件がAND的
 - 1-3. 状態空間が広い
 - 1-4. 部分観測
 - 1-5. 相手も移動する。
- 要因2. 報酬設計
 - 2. ゴール時のみ、中間報酬なし。
- 結果. タスク構造と報酬設計の結果として観測される現象
 - 報酬が遅い(遅延報酬)
 - 報酬が稀(疎報酬)
 - 成功体験が集まらない(探索困難)
 - 成功してもどの要因が効いたのか分からない(信用割り当て)



密な報酬

- ウロウロしにくい。探索コストが小さい。
- 各時刻で行った意思決定について、どれが報酬獲得に寄与したのかがわかりやすい。
- 報酬を最大化するための手がかりが多い。




疎な報酬


- ウロウロしやすく、成功体験を得にくい。初期の探索コストが大きい。
- 各時刻で行った意思決定について、どれが報酬獲得に寄与したのか、信用の重みづけができない。(左のようなルートで通ったとして、どの時刻の何の行動が効いたのか分からない。)
- 各時刻で意思決定しているから、より大局的な目線での「大体こっち行けばOK」みたいなのが学びにくくなるのではないかな？

タスクの分類1

迷路タスク




ANDタスク




行動空間 $\in$ {移動,色}として、色も移動先に合わせないとGがゴールにならない。

AND複合タスク




順序制限付き ANDタスク



行動空間 $\in$ {移動,色}として、色も移動先に合わせ、順番も守らないとGがゴールにならない。


順序制限付き AND複合タスク



タスクの分類2


ゴールの場所が毎エピソード変わる

ゴール変動 タスク




ゴールが毎ステップ移動する
(Pursuit-evasion)

追いかकेタスク



ゴールが毎ステップ意思決定して逃げる
(Pursuit-evasion/Simple Tag)


追いかケタスク (MARL)



迷路タスク


- 通常の迷路タスク。

迷路タスク



ANDタスク

- 白丸は必ず通らなければ行けない
- taxiなど。




順序制限付き ANDタスク

- 白丸を数字の順番の通りに通らなければ行けない。
-

白丸を数字の順番
の通りに通らなけれ
ば行けない

順序制限付き ANDタスク




AND複合タスク

- 行動空間 $\in$ {移動,色}として、色も移動先に合わせないとGがゴールにならない。
- 単なる移動だけでなく、「色の選択」という別の種類のタスクが割り込むため、問題としての次元が上がる。

行動空間 $\in$ {移動,色}として、色も移動先に合わせないとGがゴールにならない。

AND複合タスク




順序制限付き AND複合タスク

- 行動空間 $\in$ {移動,色}として、色も移動先に合わせ、順番も守らないとGがゴールにならない。
-

行動空間 $\in$ {移動,色}として、色も移動先に合わせ、順番も守らないとGがゴールにならない。

順序制限付き AND複合タスク




ゴール変動タスク

- ゴールの場所がエピソード毎に変わる。
- ゴールが変わる全てのパターンについて、エージェントは学ばないと行けない。

ゴールの場所が毎
エピソード変わる

ゴール変動タスク




タスクの分類


時間軸の信用割り当ての難易度の度合い

疎報酬の度合い

迷路タスク




ANDタスク




白丸は必ず通らなければ行けない

順序制限付き ANDタスク




白丸を数字の順番の通りに通らなければ行けない

AND複合タスク



行動空間 $\in$ {移動, 色} として、色も移動先に合わせないと G がゴールにならない。

順序制限付き AND複合タスク



行動空間 $\in$ {移動, 色} として、色も移動先に合わせ、順番も守らないと G がゴールにならない。