


行動分布の考察

目的

- ・強化学習エージェントの行動分布が、探索にどう影響するのかを調べたい。
- ・PPOのアクションサンプリング(ガウス分布)にある問題を調べたい。
- ・以上の問題を、簡単なランダムウォークを使って示したい。

問題設定


- 2次元空間で、ある行動分布にしたがって1000ステップランダムに移動する。これを1エピソードとして、100エピソード分やった時に軌跡の分布がどうなるかを見たい。




←を1000ステップ1エピソードとして100回繰り返し、軌跡の分布を見る。

問題設定


- 2次元空間で、ある行動分布にしたがって1000ステップランダムに移動する。これを1エピソードとして、100エピソード分やった時に軌跡の分布がどうなるかを見たい。
- パターン1: 確率50%でそれぞれ右か左に 10° 進む。
- パターン2: $-10^\circ \sim 10^\circ$ までを10分割して、それぞれ10%で選ばれる。(一様分布)
- パターン3: 正規分布。




パターン1



パターン2




パターン3




←を100ステップ1エピソードとして1000回繰り返し、軌跡の分布を見る。


Pattern 1 trajectories: $\pm 10^\circ$ with 50% each, initial heading up




パターン1




Pattern 2 trajectories: 10 equally spaced angles from -10° to 10° , initial heading up




パターン2









Pattern 3 trajectories: Gaussian-shaped action probabilities, initial heading up



パターン3






定量的比較(の、つもり)

- パターンによって、どのくらい状態分布にバラツキがあるだろうか？
 - 状態占有エントロピー
 - 状態空間(x,y,θ)を小さなセルに分解した時に、各セルを状態領域iとして、「 $p_i = (\text{セルを訪問した回数}) / \text{全状態数}$ 」を計算する。その上で $H = -\sum p_i \times \log p_i$ を計算する。Hが大きいほど、多くの状態領域を比較的広く訪問している。
 - 実効状態セル数
 - 実質的に、何個の状態セルを均等に探索したのと同じくらい状態分布が多様だったか。


パターン	訪問セル数	状態エントロピー (指数なので違いが見えにくい)	実効状態セル数
パターン1	21,357	9.559	14,175
パターン2	18,388	9.395	12,024
パターン3	13,195	9.026	8,313

行動分布が正規分布の時に生まれる問題。

- PPOは毎ステップでアクションサンプリングを行う。
- しかしこれには問題がある。
 - 毎ステップランダムにサンプリングするが、行動サンプリング周期の違いによって探索が悪化するのでは？
 - 時間的に独立 (i.i.d?)したホワイトノイズでは、「ある程度右にバイアスをかけ続ける」ような時間的に一貫性のある軌跡を作りにくいのでは？



Gaussian action sampling: effect of control frequency on random-walk behavior



←簡単なランダムウォークの例。正規分布からアクションサンプリング。

左は毎ステップ行動をサンプリングした場合。


右は10ステップに1回行動をサンプリングしてその値を保持した場合。

↑同じ「正規分布からのアクションサンプリング」でも、アクションを出す周期の細かさによって全然違う！

行動分布に時間的相関のある場合


正規分布からのサンプリングで、時間的相関のあるバイアスをかけた場合にどう軌跡が変化するかを調べる。

- パターン4: 毎ステップ独立に $N(0, 4^2)$ からサンプル(パターン3と同じ)
- パターン5: 8ステップごとに1回サンプルして、その値を8ステップ保持
- パターン6: 32ステップごとに1回サンプルして、その値を32ステップ保持
- パターン7: AR(1), $p=0.95$ 。前の値を引きずりながら徐々に変化するもの。10ステップ程度、行動の記憶を持つノイズ。




←行動分布自体は全て正規分布。

Trajectories: i.i.d. Gaussian turn noise (sigma = 4 deg), initial heading up




パターン4: 毎ステップ独立に
 $N(0, 4^2)$ からサンプル

Trajectories: 8-step hold Gaussian turn noise (sigma = 4 deg), initial heading up




パターン5: 8ステップごとに1
回サンプルして、その値を 8ス
テップ保持

Trajectories: 32-step hold Gaussian turn noise (sigma = 4 deg), initial heading up






パターン6: 32ステップごとに
1回サンプルして、その値を
32ステップ保持


Trajectories: AR(1) Gaussian turn noise (sigma = 4 deg, rho = 0.95), initial heading up



パターン7:AR(1),
p=0.95。



パターン	訪問セル数	状態エントロピー (指数なので違いが見えにくい)	実効状態セル数
パターン4	12,846	8.996	8070
パターン5	16,957	9.292	10,851
パターン6	13,175	8.897	8082
パターン7	12,049	8.897	7308



パターン	訪問セル数	状態エントロピー (指数なので違いが見えにくい)	実効状態セル数
パターン4	12,846	8.996	8070
パターン5	16,957	9.292	10,851
パターン6	13,175	8.897	8082
パターン7	12,049	8.897	7308

まとめ

- 「エントロピーを大きくすること(ガウス分布の周辺分散を広げること)」と、「探索に有効な行動列を生成すること」は別。
- アクションサンプリングで毎ステップ独立にガウス分布から行動をサンプリングすると時間的な一貫性が不足する可能性がある。
- その一方で、時間的な一貫性を強くしすぎると局所的な回転を継続してしまい、得られる状態空間が逆に狭まってしまう。
- 問題に応じた適切な時間相関のスケール調整が必要。

- ・以下、論文を少しだけ紹介。
- ・何年も前からこの話は問題として取り上げられていたことを示す。
- ・雰囲気だけ見るのを重視でかなりざっくりした理解で書く。

Autoregressive Policies for Continuous Control Deep Reinforcement Learning

・ガウス分布からのアクションサンプリングを「 $a_t = \text{mean}(s_t) + \text{std}(s_t)$ 」として分解している。この $\text{std}(s_t)$ がwhite gaussian noiseで、時間方向に独立していることを問題視している。特に学習初期では方策平均もほぼゼロ付近なので、探索が実質的にゼロ平均ホワイトノイズに依存し、速度やトルクのような低レベル制御では一貫した行動が生まれにくい。

・特に、行動サンプリング周期の違いによって探索が悪化しうることを、実験によって示している。このスライドの前のページでやった内容とほとんど同じ(論文を検索して、PDF6ページ右上の図を見せる)。つまり、意味のある探索を促すには、行動に対して時間的に独立したノイズを都度与えるのではなく、時間的に一貫したノイズを与えるべきでは？ という問題意識。

・この問題に対して、著者は、 $\text{std}(s_t)$ 部分にAR過程 X を追加して、 $\text{std}(s_t) \times X_t$ にすることで、ノイズの与え方をより連続的に一貫するような工夫をしている。ARとは自己回帰(Autoregressive)のことで、今の値が一個前の値をどのくらい引きずるかを表す時系列モデル。自分自身の過去の値を使って現在値を作るので自己回帰と言う。

・図5では、著者の提案手法とガウシアンポリシーの性能比較がされている。結果から見ると、必ずしも著者の提案手法が有効なわけではなく、問題によって手法の優劣が違ふ。問題に応じた適切な相関時間スケールが必要だと述べられている。

Colored Noise in PPO- Improved Exploration and Performance through Correlated Action Sampling

- ・問題意識としてはKorenkevych et al.(2019)とほぼ同じ。2ページ目の図1を参照。
- ・PPOを直接対象としている。
- ・この論文では時間的に相関のあるノイズの入れ方として、colored noiseを提案している。カラーノイズは時間構造を β で操作でき、ホワイトノイズ($\beta=0$)→ホワイトとピンクの中間($\beta=0.5$)→ピンクノイズ($\beta=1$)→レッドノイズ($\beta=2$)の順に時間相関が強い。非常にざっくりで言えば、前ページの「 $a_t = \text{mean}(s_t) + \text{std}(s_t)$ 」で、 $\text{std}(s_t)$ を少しいじってカラーノイズに変えました、という話。
- ・4ページの表1で、16のトイ環境で β を変えた時の評価を行っている。 $\beta=0.5$ が統計的に良かったそうだが、結局は環境によって最適な時間相関は異なる。
- ・また、ノイズの時間相関を強くすると、各エピソードで得られる経験が特定方向に偏りやすくなる。そのためtrain_batch_sizeを大きくして、バイアスを打ち消せと言っている。


Appendix: PPOでの行動分布の作られ方。

「使われる数式」

$$a_t \sim N(\mu_t, \sigma_t^2)$$

$$a_t = \mu_t + \epsilon_t \cdot \sigma_t$$

$$\epsilon_t \sim N(0, 1)$$



google slideでは、
macは「cmd と,」で下つき、
「cmd と.」で上つきで書ける。
Winでは「ctrlと,」「ctrlと.」で
書ける。

「作られる順序」

①まず $\epsilon_t \sim N(0, 1)$ からランダム値を1個取る。



②NNが U_t と σ_t を出す。

③ $a_t = \mu_t + \epsilon_t \cdot \sigma_t$ を計算する。

Appendix: PPOでの行動分布の作られ方。

実際は、 ϵ_t の正規分布からサンプリングしてから、そのサンプリングした値に σ^t をかける。

「直感的イメージ」



「 $\epsilon_t \cdot \sigma_t$ 」だけmeanからズラされる。

メモ

記号	読み方	意味
a_t	エー・サブ・ティー	時刻 t の行動
t	ティー	時刻、タイムステップ
$\sim$	チルダ	「～に従う」
$\mathcal{N}$	エヌ、正規分布	Normal distribution
μ	ミュー	平均
μ_t	ミュー・サブ・ティー	時刻 t における平均
σ	シグマ	標準偏差
σ_t	シグマ・サブ・ティー	時刻 t における標準偏差

Σ ←こいつも読み方は「シグマ」。混ざらないように注意。