


# 行動分布の考察

# 目的

- ・強化学習エージェントの行動分布が、探索にどう影響するのかを調べたい。
- ・PPOのアクションサンプリング(ガウス分布)にある問題を調べたい。
- ・以上の問題を、簡単なランダムウォークを使って示したい。

# 問題設定


- 2次元空間で、ある行動分布にしたがって1000ステップランダムに移動する。これを1エピソードとして、100エピソード分やった時に軌跡の分布がどうなるかを見たい。




←を100ステップ1エピソードとして1000回繰り返し、軌跡の分布を見る。

# 問題設定


- 2次元空間で、ある行動分布にしたがって1000ステップランダムに移動する。これを1エピソードとして、100エピソード分やった時に軌跡の分布がどうなるかを見たい。
- パターン1: 確率1/2で右に10度傾いて長さ1進む、逆であれば左に10度傾いて長さ1進む。
- パターン2:  $-10^{\circ}$ ~ $10^{\circ}$ までを10分割して、それぞれ10%で選ばれる。(一様分布)
- パターン3: 正規分布。




パターン1



パターン2




パターン3




←を100ステップ1エピソードとして1000回繰り返し、軌跡の分布を見る。


Pattern 1 trajectories:  $\pm 10^\circ$  with 50% each, initial heading up




# パターン1




Pattern 2 trajectories: 10 equally spaced angles from  $-10^\circ$  to  $10^\circ$ , initial heading up



## パターン2










Pattern 3 trajectories: Gaussian-shaped action probabilities, initial heading up



パターン3

Pattern 3: Gaussian-shaped action probabilities (sigma = 4 deg)







# 定量的比較(の、つもり)

- パターンによって、どのくらい状態分布にバラツキがあるだろうか？
  - 状態占有エントロピー
    - 状態空間(x,y,θ)を小さなセルに分解した時に、各セルを状態領域iとして、「 $p_i = (\text{セルを訪問した回数}) / \text{全状態数}$ 」を計算する。その上で $H = -\sum p_i \times \log p_i$ を計算する。Hが大きいほど、多くの状態領域を比較的広く訪問している。
  - 実効状態セル数
    - 実質的に、何個の状態セルを均等に探索したのと同じくらい状態分布が多様だったか。


| パターン  | 訪問セル数  | 状態エントロピー<br>(指数なので違いが見えにくい) | 実効状態セル数 |
|-------|--------|-----------------------------|---------|
| パターン1 | 21,357 | 9.559                       | 14,175  |
| パターン2 | 18,388 | 9.395                       | 12,024  |
| パターン3 | 13,195 | 9.026                       | 8,313   |

# 考察


- RLの文脈で言えばパターン1のような行動分布を持つと、挙動としては安定性が落ちる一方で、ある種の探索補助になっていることがわかった。
- エントロピー係数を上げて対策できるか？
  - パターン3について:これは、ハイパラのエントロピー係数を上げたとしても解決しない。PPOの`entropy_coef`はlossを計算するときに、`entropy_loss`にかけられる係数であり、NNが出すアクションが早い段階で決め打ちになりすぎないようにするためのものである。つまり、早い段階での収束を防ぐものではあっても、アクションの分散をより巨大にして、積極的に探索を促すようなものではない。探索が早期に消えるのを防ぐ、消極的？に探索補助をするもの。

# 正規分布でうまく探索させたい場合

- PPOは毎ステップでアクションサンプリングを行う。
- しかしこれには問題がある
  - 毎ステップランダムにサンプリングするが、制御周波数の違いによって探索が悪化するのでは？
  - 時間的に独立したホワイトノイズでは、「ある程度右にバイアスをかけ続ける」ような時間的に一貫性のある軌跡を作りにくいのでは？



Gaussian action sampling: effect of control frequency on random-walk behavior



←簡単なランダムウォークの例。正規分布からアクションサンプリング。

左は毎ステップ行動をサンプリングした場合。

右は10ステップに1回行動をサンプリングしてその値を保持した場合。


↑同じ「正規分布からのアクションサンプリング」でも、アクションを出す周期の細かさによって全然違う！

# 行動分布に時間的相関のあるバイアスをかけた場合

正規分布からのサンプリングで、時間的相関のあるバイアスをかけた場合にどう軌跡が変化するかを調べる。


- パターン4: 毎ステップ独立に $N(0, 4^2)$ からサンプル
- パターン5: 8ステップごとに1回サンプルして、その値を8ステップ保持
- パターン6: 32ステップごとに1回サンプルして、その値を32ステップ保持
- パターン7: AR(1),  $p=0.95$ 。前の値を引きずりながら徐々に変化するもの。10ステップ程度、行動の記憶を持つノイズ。

Trajectories: i.i.d. Gaussian turn noise (sigma = 4 deg), initial heading up




パターン4: 毎ステップ独立に  
 $N(0, 4^2)$ からサンプル

Trajectories: 8-step hold Gaussian turn noise (sigma = 4 deg), initial heading up




パターン5: 8ステップごとに1  
回サンプルして、その値を 8ス  
テップ保持

Trajectories: 32-step hold Gaussian turn noise (sigma = 4 deg), initial heading up






パターン6: 32ステップごとに  
1回サンプルして、その値を  
32ステップ保持

Trajectories: AR(1) Gaussian turn noise ( $\sigma = 4$  deg,  $\rho = 0.95$ ), initial heading up




パターン7:AR(1),  
 $p=0.95$ 。





| パターン  | 訪問セル数  | 状態エントロピー<br>(指数なので違いが見えにくい) | 実効状態セル数 |
|-------|--------|-----------------------------|---------|
| パターン4 | 12,846 | 8.996                       | 8070    |
| パターン5 | 16,957 | 9.292                       | 10,851  |
| パターン6 | 13,175 | 8.897                       | 8082    |
| パターン7 | 12,049 | 8.897                       | 7308    |



| パターン  | 訪問セル数  | 状態エントロピー<br>(指数なので違いが見えにくい) | 実効状態セル数 |
|-------|--------|-----------------------------|---------|
| パターン4 | 12,846 | 8.996                       | 8070    |
| パターン5 | 16,957 | 9.292                       | 10,851  |
| パターン6 | 13,175 | 8.897                       | 8082    |
| パターン7 | 12,049 | 8.897                       | 7308    |

## まとめ

- アクションサンプリングで毎ステップ独立にガウス分布から行動をサンプリングすると時間的な一貫性が不足する可能性がある。
- その一方で、時間的一貫性を強くしすぎると局所的な回転を継続してしまい、得られる状態空間が逆に狭まってしまう。
- 問題に応じた適切な時間相関スケールが必要。