

RL試行

藤井和希

試行① Frozen Lake

Frozen Lake



This environment is part of the Toy Text environments which contains general information about the environment.

1. 実験の比較対象

環境条件

マップ: FrozenLake 8×8

固定マップを使用 (4ケースで同一マップ)

遷移: 確定遷移 / 確率遷移

報酬: 疎報酬 / 密報酬

4ケース

- 1) 確定遷移 × 疎報酬
- 2) 確定遷移 × 密報酬
- 3) 確率遷移 × 疎報酬
- 4) 確率遷移 × 密報酬

2. 報酬設定

疎報酬

FrozenLake 標準そのまま

ゴール: +1.0

それ以外: 0.0

密報酬 (reward shaping)

方向ヒントを与える自作wrapperを使用

状態ポテンシャル $\Phi(s)$

goal: 0

hole: -1.5

other: $-d_{\text{safe}}(s,G) / d_{\text{max}}$

shaped reward: $r' = r + 0.2 (\gamma \Phi(s') - \Phi(s))$

$\gamma = 0.99$

3. 学習アルゴリズムと探索

学習アルゴリズム

tabular Q-learning で固定

更新式: $Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$

学習率 $\alpha = 0.1$

割引率 $\gamma = 0.99$

Qテーブル初期値: 全状態・全行動で0.0

探索設定 (ϵ -greedy)

初期 $\epsilon = 1.0$

最終 $\epsilon = 0.05$

0～18,000 episode: 線形減衰

18,001～30,000 episode: 0.05で固定

狙い: 前半で探索、後半で再現性と浸透を観察

4. 実行規模と公平性

実行規模

100 seeds

30,000 episodes / seed / case

1 episode の最大 step 数 = 200

hardest case (8×8 × 確率遷移 × 疎報酬) を想定した
設定

比較の公平性

4ケースすべてで以下を統一

同じ map

同じ seed list

同じ $\alpha, \gamma, \varepsilon$ 設定

同じ max_steps

同じ episode 数

差分は「遷移の確率性」と「報酬の密度」だけ

5. 記録ログと保存タイミング

毎 episode 記録

success / failure

episode length

episode return

episode index / seed / case

first success episode

first success までの累積 step 数

resuccess episode

初回成功後 50 / 100 episode 成功率

Q / V スナップショット

状態価値 : $V(s) = \max_a Q(s,a)$

固定時点 : 0, 100, 500, 1000, 3000, 10000, 30000

イベント時点 : 初回成功直後

イベント時点 : 初回成功 + 50 episode

イベント時点 : 初回成功 + 100 episode

6. 可視化と評価観点

可視化

- A. 学習曲線 (success rate の移動平均)
- B. 初回成功 episode の分布
- C. 再成功までの episode 数の分布
- D. ゴール距離ごとの平均状態価値の推移
- E. 状態価値ヒートマップ

評価観点

- ① 発見困難: 初回成功が遅い/ 未達率が高い
- ② 再現困難: 再成功までが長い/ 初回成功後成功率が低い
- ③ 浸透困難: 価値の立ち上がりが遅い/ ヒートマップの広がりが遅い

仮説: 確率遷移では、細い一本線より“広く薄い帯”が出やすい

学習前仮説↓

仮説(どうなるかの仮説と、仮説の検証から得られる知見まで考える。)

	ゴールの発見が困難		成功しても再現が困難		成功経路の学習困難(信用割り当て)	
シナリオ	初回ゴール到達までのエピソード数	初回ゴール到達までの総ステップ数	初回成功後の再成功までのエピソード数	初回成功後50/100エピソード成功率	ゴール距離ごとの平均状態価値の推移	ゴール近傍の状態価値の広がり方(画像で確認))
①確定遷移疎報酬	疎報酬なので、②より時間はかかるはず	疎報酬なので、②より時間はかかるはず	疎報酬なので、②より時間はかかるはず	疎報酬なので、②より時間はかかるはず	疎報酬なため、②よりは価値の伝播が遅そう。	疎報酬なため、②よりは価値の伝播が遅そう。
②確定遷移密報酬	密報酬かつ確定遷移なので少ないはず。	密報酬かつ確定遷移なので少ないはず。	確定遷移なので少ないはず。	確定遷移なので少ないはず。	確定遷移なので早く価値が推移するはず。	確定遷移なので早く価値が推移するはず。
③確率遷移疎報酬	探索の難易度が上がるため大きくなりそう。	探索の難易度が上がるため大きくなりそう。	確率遷移で軌跡を再現しにくいいため多そう。	確率遷移で軌跡を再現しにくいため少なそう。	確率遷移で価値が見積もりになるので遅そう。	確率遷移で価値が見積もりになるので遅そう。
④確率遷移密報酬	③よりは速そう。	③よりは速そう。	ヒント自体はあるため早くなりそう。	ヒント自体はあるため高くなりそう。	ヒント自体はあるため早くなりそう。	ヒント自体はあるため早くなりそう。

仮説(どうなるかの仮説と、仮説の検証から得られる知見まで考える。)

- どうなるかの仮説

- 確率遷移になると、確定遷移の時よりも探索が困難になるため、ゴールの発見の困難さが高まるはず。
- 同じ軌跡を再現しても確率で違う結果になるため、成功の再現に必要なエピソード数は伸びそう。
- 成功経路については、確率遷移だとゴールへの辿り着き方にバリエーションが生まれそうなので、価値のヒートマップの色のつき方は確定遷移よりもより広く薄く色がつくになりそう。


- 得られる知見の仮説

- 確率遷移と疎報酬が組み合わさると、特に最初の探索が難しくなる。
- ゴールに行くことに整合的な密報酬があれば探索が楽になり、その結果として、成功の再現がずっとしやすくなる。密報酬は探索だけでなく、成功後の価値伝播も助ける。
 - 初回成功の時から、ゴールまでの過程にも学習が進むため。
 - ゴールだけでなく途中の経路にも価値が付き、成功経路が強化されやすいため。
- 成功経路については、確定遷移の場合よりも、確率遷移の時はゴールまでの行き方がバラバラになることが予想されるため、価値のヒートマップもより広く薄く色がつくことになりそう。


学習後の検証↓

heatmap_ep0


det_dence




det_sparse



stoch_dence




stoch_sparse




heatmap_ep1000


det_dence




det_sparse



stoch_dence



stoch_sparse



heatmap_ep3000


ep3000の時点では、確率遷移はまだ価値が十分広
まっていない。

↓


可能性①: そもそも成功が少ない。

可能性②: 成功しているが価値の割り当てが進んでい
ない。


det_dence




det_sparse



stoch_dence




stoch_sparse




heatmap_ep10000


det_dence




det_sparse



stoch_dence




stoch_sparse




heatmap_ep30000


det_dence




det_sparse



stoch_dence




stoch_sparse




heatmap_first_success_plus_50


det_dence




det_sparse



stoch_dence




stoch_sparse




heatmap_first_success_plus_100


det_dence




det_sparse



stoch_dence







stoch_sparse



first_success_histograms



横軸＝初成功した時のエピソード数
縦軸＝その範囲に入ったseedの本数。

探索の難しさ、最初の成功発見のしやすさ、seed間の初成功までのばらつきを見る。





resuccess_gap_histograms

初めて成功した後、
次にもう一度成功する
までに何エピソード
かかったか。




密報酬のほうが、一
度成功した後再現で
きる可能性が高い。




横軸の幅に注意。
とはいえ、確率遷移
でも、密報酬のほう
が明らかに成功の再
現がしやすいそう。

success_rate_moving_average




average_episode_length




distance_value_event


det_dense: event-based value by distance to goal




det_sparse: event-based value by distance to goal







stoch_dense: event-based value by distance to goal



stoch_sparse: event-based value by distance to goal



distance_value_fixed



仮説(どうなるかの仮説と、仮説の検証から得られる知見まで考える。)

- どうなるかの仮説

- 確率遷移になると、確定遷移の時よりも探索が困難になるため、ゴールの発見の困難さが高まるはず。
 - →「first_success_histograms」により検証できた。平均的にも確率遷移のほうが時間がかかってそうで、初成功までに 3000 エピソード近くかかっているものも存在した。
- 同じ軌跡を再現しても確率で違う結果になるため、成功の再現に必要なエピソード数は伸びそう。
 - 「resuccess_gap_histograms」により検証できた。密報酬によって成功の再現率を高めることができることを学んだ。
- 成功経路については、確率遷移だとゴールへの辿り着き方にバリエーションが生まれそうなので、価値のヒートマップの色のつき方は確定遷移よりもより広く薄く色がつくになりそう。
 - 「heatmap」により検証できた。成功経路については確定遷移のほうが広く薄く色がついた。確率遷移では、特に上手く行くルートが他よりも際立って色がついていた。なので、仮説とはむしろ逆の結果になった。生き残りやすい経路だけが相対的に強く選別される結果となった。確率遷移では、確率で動いても大丈夫なロバストな通路への集中が起きているように見える。


仮説(どうなるかの仮説と、仮説の検証から得られる知見まで考える。)

- 得られる知見の仮説

- 確率遷移と疎報酬が組み合わさると、特に最初の探索が難しくなる。
 - 検証できた。
- ゴールに行くことに整合的な密報酬があれば探索が楽になり、その結果として、成功の再現がずっとしやすくなる。密報酬は探索だけでなく、成功後の価値伝播も助ける。
 - 初回成功の時から、ゴールまでの過程にも学習が進むため。
 - 「first_success_histograms」により検証できた。実際は、密報酬があっても初成功の間にはそこまで差がないように見える。ヒートマップを見る限り、確かにスタート地点付近の価値の立ち上がりは早いのだが、成功速度にはあまり影響しない？
 - ゴールだけでなく途中の経路にも価値が付き、成功経路が強化されやすいため。
 - 「heatmap」により検証できた。密報酬と疎報酬で成功経路についての価値の広がり方にはあまり差がないように見える。密報酬ではスタート地点付近の価値は確かに上昇している。これは単に報酬設計の結果生まれた現象に過ぎなそう。
- 成功経路については、確定遷移の場合よりも、確率遷移の時はゴールまでの行き方がバラバラになることが予想されるため、価値のヒートマップもより広く薄く色がつくことになりそう。
 - 検証できた。

学び


- 取り組み方についての学び
 - この問題は、最終的に獲得した報酬の量というよりも、「価値の立ち上がり」「初成功の速さ」「成功の再現率」「最終成功率」に分解して見たほうが学びが多い。
- Frozen Lakeの問題からの学び
 - 確率遷移は単にノイズが増えるだけでなく、探索の初動と成功の再現を両方悪化させる。
 - 密報酬は、初回発見よりも発見後の安定化・再現化に効いている可能性が高い。
 - 価値伝播の速さと初成功の速さは同じではない。
 - 確率遷移によって経路の多様化が起きるとは限らず、むしろロバストな経路への集中が怒ることがある。



まだ「見えている差」から「なぜそうなるか」の因果分解が少し甘い

試行② Taxi

Taxi



This environment is part of the Toy Text environments which contains general information about the environment.

