

RL試行

藤井和希

試行① Frozen Lake

1. 実験の比較対象

環境条件

マップ: FrozenLake 8×8

固定マップを使用 (4ケースで同一マップ)

遷移: 確定遷移 / 確率遷移

報酬: 疎報酬 / 密報酬

4ケース

- 1) 確定遷移 × 疎報酬
- 2) 確定遷移 × 密報酬
- 3) 確率遷移 × 疎報酬
- 4) 確率遷移 × 密報酬

2. 報酬設定

疎報酬

FrozenLake 標準そのまま

ゴール: +1.0

それ以外: 0.0

密報酬 (reward shaping)

方向ヒントを与える自作wrapperを使用

状態ポテンシャル $\Phi(s)$

goal: 0

hole: -1.5

other: $-d_{\text{safe}}(s,G) / d_{\text{max}}$

shaped reward: $r' = r + 0.2 (\gamma \Phi(s') - \Phi(s))$

$\gamma = 0.99$

3. 学習アルゴリズムと探索

学習アルゴリズム

tabular Q-learning で固定

更新式: $Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$

学習率 $\alpha = 0.1$

割引率 $\gamma = 0.99$

Qテーブル初期値: 全状態・全行動で0.0

探索設定 (ϵ -greedy)

初期 $\epsilon = 1.0$

最終 $\epsilon = 0.05$

0～18,000 episode: 線形減衰

18,001～30,000 episode: 0.05で固定

狙い: 前半で探索、後半で再現性と浸透を観察

4. 実行規模と公平性

実行規模

100 seeds

30,000 episodes / seed / case

1 episode の最大 step 数 = 200

hardest case (8×8 × 確率遷移 × 疎報酬) を想定した
設定

比較の公平性

4ケースすべてで以下を統一

同じ map

同じ seed list

同じ $\alpha, \gamma, \varepsilon$ 設定

同じ max_steps

同じ episode 数

差分は「遷移の確率性」と「報酬の密度」だけ

5. 記録ログと保存タイミング

毎 episode 記録

success / failure

episode length

episode return

episode index / seed / case

first success episode

first success までの累積 step 数

resuccess episode

初回成功後 50 / 100 episode 成功率

Q / V スナップショット

状態価値 : $V(s) = \max_a Q(s,a)$

固定時点 : 0, 100, 500, 1000, 3000, 10000, 30000

イベント時点 : 初回成功直後

イベント時点 : 初回成功 + 50 episode

イベント時点 : 初回成功 + 100 episode

6. 可視化と評価観点

可視化

- A. 学習曲線 (success rate の移動平均)
- B. 初回成功 episode の分布
- C. 再成功までの episode 数の分布
- D. ゴール距離ごとの平均状態価値の推移
- E. 状態価値ヒートマップ

評価観点

- ① 発見困難: 初回成功が遅い/ 未達率が高い
- ② 再現困難: 再成功までが長い/ 初回成功後成功率が低い
- ③ 浸透困難: 価値の立ち上がりが遅い/ ヒートマップの広がりが遅い

仮説: 確率遷移では、細い一本線より“広く薄い帯”が出やすい

学習前仮説↓

仮説(どうなるかの仮説と、仮説の検証から得られる知見まで考える。)

	ゴールの発見が困難		成功しても再現が困難		成功経路の学習困難(信用割り当て)	
シナリオ	初回ゴール到達までのエピソード数	初回ゴール到達までの総ステップ数	初回成功後の再成功までのエピソード数	初回成功後50/100エピソード成功率	ゴール距離ごとの平均状態価値の推移	ゴール近傍の状態価値の広がり方(画像で確認))
①確定遷移疎報酬	疎報酬なので、②より時間はかかるはず	疎報酬なので、②より時間はかかるはず	疎報酬なので、②より時間はかかるはず	疎報酬なので、②より時間はかかるはず	疎報酬なため、②よりは価値の伝播が遅そう。	疎報酬なため、②よりは価値の伝播が遅そう。
②確定遷移密報酬	密報酬かつ確定遷移なので少ないはず。	密報酬かつ確定遷移なので少ないはず。	確定遷移なので少ないはず。	確定遷移なので少ないはず。	確定遷移なので早く価値が推移するはず。	確定遷移なので早く価値が推移するはず。
③確率遷移疎報酬	探索の難易度が上がるため大きくなりそう。	探索の難易度が上がるため大きくなりそう。	確率遷移で軌跡を再現しにくいいため多そう。	確率遷移で軌跡を再現しにくいため少なそう。	確率遷移で価値が見積もりになるので遅そう。	確率遷移で価値が見積もりになるので遅そう。
④確率遷移密報酬	③よりは速そう。	③よりは速そう。	ヒント自体はあるため早くなりそう。	ヒント自体はあるため高くなりそう。	ヒント自体はあるため早くなりそう。	ヒント自体はあるため早くなりそう。

仮説(どうなるかの仮説と、仮説の検証から得られる知見まで考える。)

- どうなるかの仮説

- 確率遷移になると、確定遷移の時よりも探索が困難になるため、ゴールの発見の困難さが高まるはず。
- 同じ軌跡を再現しても確率で違う結果になるため、成功の再現に必要なエピソード数は伸びそう。
- 成功経路については、確率遷移だとゴールへの辿り着き方にバリエーションが生まれそうなので、価値のヒートマップの色のつき方は確定遷移よりもより広く薄く色がつくになりそう。


- 得られる知見の仮説

- 確率遷移と疎報酬が組み合わさると、特に最初の探索が難しくなる。
- ゴールに行くことに整合的な密報酬があれば探索が楽になり、その結果として、成功の再現がずっとしやすくなる。密報酬は探索だけでなく、成功後の価値伝播も助ける。
 - 初回成功の時から、ゴールまでの過程にも学習が進むため。
 - ゴールだけでなく途中の経路にも価値が付き、成功経路が強化されやすいため。
- 成功経路については、確定遷移の場合よりも、確率遷移の時はゴールまでの行き方がバラバラになることが予想されるため、価値のヒートマップもより広く薄く色がつくことになりそう。


学習後の検証↓

heatmap_ep0


det_dence




det_sparse



stoch_dence




stoch_sparse




heatmap_ep1000


det_dence




det_sparse



stoch_dence



stoch_sparse



heatmap_ep3000


ep3000の時点では、確率遷移はまだ価値が十分広
まっていない。

↓


可能性①: そもそも成功が少ない。

可能性②: 成功しているが価値の割り当てが進んでい
ない。


det_dence




det_sparse



stoch_dence




stoch_sparse




heatmap_ep10000


det_dence




det_sparse



stoch_dence




stoch_sparse




heatmap_ep30000


det_dence




det_sparse



stoch_dence




stoch_sparse




heatmap_first_success_plus_50


det_dence




det_sparse



stoch_dence




stoch_sparse




heatmap_first_success_plus_100


det_dence




det_sparse



stoch_dence






stoch_sparse




first_success_histograms

横軸＝初成功した時のエピソード数
縦軸＝その範囲に入ったseedの本数。

探索の難しさ、最初の成功発見のしやすさ、seed間の初成功までのばらつきを見る。





いきなり成功している数が多く見えるが、これはグラフの横軸が広いためそうになっている様に見える。





確率遷移では初成功までにすごく時間がかかっているものがある。

resuccess_gap_histograms

初めて成功した後、
次にもう一度成功する
までに何エピソード
かかったか。




密報酬のほうが、一
度成功した後再現で
きる可能性が高い。




横軸の幅に注意。
とはいえ、確率遷移
でも、密報酬のほう
が明らかに成功の再
現がしやすいそう。

success_rate_moving_average




average_episode_length




distance_value_event


det_dense: event-based value by distance to goal




det_sparse: event-based value by distance to goal







stoch_dense: event-based value by distance to goal



stoch_sparse: event-based value by distance to goal



distance_value_fixed



仮説(どうなるかの仮説と、仮説の検証から得られる知見まで考える。)

- どうなるかの仮説

- 確率遷移になると、確定遷移の時よりも探索が困難になるため、ゴールの発見の困難さが高まるはず。
 - →「first_success_histograms」により検証できた。平均的にも確率遷移のほうが時間がかかってそうで、初成功までに 3000 エピソード近くかかっているものも存在した。
- 同じ軌跡を再現しても確率で違う結果になるため、成功の再現に必要なエピソード数は伸びそう。
 - 「resuccess_gap_histograms」により検証できた。密報酬によって成功の再現率を高めることができることを学んだ。
- 成功経路については、確率遷移だとゴールへの辿り着き方にバリエーションが生まれそうなので、価値のヒートマップの色のつき方は確定遷移よりもより広く薄く色がつくになりそう。
 - 「heatmap」により検証できた。成功経路については確定遷移のほうが広く薄く色がついた。確率遷移では、特に上手く行くルートが他よりも際立って色がついていた。なので、仮説とはむしろ逆の結果になった。生き残りやすい経路だけが相対的に強く選別される結果となった。確率遷移では、確率で動いても大丈夫なロバストな通路への集中が起きているように見える。

仮説(どうなるかの仮説と、仮説の検証から得られる知見まで考える。)

- 得られる知見の仮説

- 確率遷移と疎報酬が組み合わさると、特に最初の探索が難しくなる。
 - 検証できた。
- ゴールに行くことに整合的な密報酬があれば探索が楽になり、その結果として、成功の再現がずっとしやすくなる。密報酬は探索だけでなく、成功後の価値伝播も助ける。
 - 初回成功の時から、ゴールまでの過程にも学習が進むため。
 - 「first_success_histograms」により検証できた。実際は、密報酬があっても初成功の間にはそこまで差がないように見える。ヒートマップを見る限り、確かにスタート地点付近の価値の立ち上がりは早いのだが、成功速度にはあまり影響しない？
 - ゴールだけでなく途中の経路にも価値が付き、成功経路が強化されやすいため。
 - 「heatmap」により検証できた。密報酬と疎報酬で成功経路についての価値の広がり方にはあまり差がないように見える。密報酬ではスタート地点付近の価値は確かに上昇している。これは単に報酬設計の結果生まれた現象に過ぎなそう。
- 成功経路については、確定遷移の場合よりも、確率遷移の時はゴールまでの行き方がバラバラになることが予想されるため、価値のヒートマップもより広く薄く色がつくことになりそう。
 - 検証できた。

学び

- 取り組み方についての学び
 - この問題は、最終的に獲得した報酬の量というよりも、「価値の立ち上がり」「初成功の速さ」「成功の再現率」「最終成功率」に分解して見たほうが学びが多い。
- Frozen Lakeの問題からの学び
 - 確率遷移は単にノイズが増えるだけでなく、探索の初動と成功の再現を両方悪化させる。
 - 密報酬は、初回発見よりも発見後の安定化・再現化に効いている可能性が高い。
 - 価値伝播の速さと初成功の速さは同じではない。
 - 確率遷移によって経路の多様化が起きるとは限らず、むしろロバストな経路への集中が怒ることがある。

試行② Frozen Lake(通常版、穴なし版、復活あり版)

問題設定、学習意図

- 問題設定

- 通常のFrozen Lakeに加えて、「穴なし版」と「穴に落ちてもエピソードが終わらず、スタート位置から復帰できる版」を試行した。

- 学習意図

- Frozen Lakeの問題における「穴」の影響を知るため。
- この「穴」は、問題の性質としては「失敗の不可逆性」を意味している。
- 失敗の不可逆性とは、その失敗をしてしまうとエピソードが終了してしまう（終端化する）ような性質のこと。
 - ここでは、失敗＝罰則を必ずしも意味しない。実際、Frozen Lakeでは穴に落ちても罰則は受けない。
- 今回の目標は、失敗の不可逆性が問題に及ぼす影響を、条件を分けた差分から探ることである。

失敗の不可逆性の考察

- 失敗の不可逆性とは、その失敗をしてしまうとエピソードが終了してしまう (終端化する) ような性質のこと。
- エピソードが途中で打ち切られると、以下のようなことが起きる。
 - ①その先の探索が打ち切られる。
 - ②その試行中にゴールへ辿り着く可能性が消える。
 - ③その軌跡から先の価値伝播がとまる。
- つまり、探索の機会と、その探索から得られるかもしれない学習の価値伝播が失われるということである。
- Q学習の視点で見れば、通常版の終端状態が「 $\text{target}=0$ 」になるのに対して、復活あり版は「 $\text{target}=0+\gamma \cdot \max_{a'}(Q(s_{\text{start}}, a'))$ 」となる。穴に落ちる行動が「そこで終わり」なのか「遠回りだが続けられる」のかが違う。

各条件

- ①通常版
 - 穴に落ちても罰則は受けないが、そこが終端状態となる。
 - その結果、終端状態以降の探索の機会や学習の機会が失われる。
- ②穴なし版
 - 穴がないため、確率遷移等ありのただの問題になる。
- ③復活あり版
 - 穴に落ちてもスタート位置で復活して再挑戦できる。エピソード数単位で比較すれば、通常版よりも穴の密集した個所などの探索はよりできるようになっているかもしれない。
 -

各条件同士の対照

- ②穴なし版 vs ③復活あり版
 - 穴の存在そのもの、つまり危険領域による進路制約の影響を見る対照。
- ①通常版 vs ③復活あり版
 - 失敗の不可逆性の影響を見る対照
 - 成功率など、ステップ数ベースではあまり差が出ないかもしれないが、総ステップ数ベースで見ると差が大きくなる可能性がある。
 - また、価値の染み出し方や再成功の安定性では差が出る可能性がある。
- ①通常版 vs ②穴なし版
 - 両方まとめた総効果

成功の再現性や、終盤性能に違いはあるか？(実験前仮説)

- 成功体験の困難さ。
 - 復活あり版の方が1エピソードの中で再挑戦しやすいので、成功体験は積みやすいはず。(初成功の分布のデータを参考に検証。)
- 成功しても再現できない。
 - 復活あり版では、結果としては非常に1回あたりの軌跡が長くなるはずである。成功体験の軌跡が長くなるならば、その軌跡の再現は難しくなるかもしれない。(再成功の分布のデータを参考に検証。)
- 成功経路を学べない。
 - 復活あり版では、場合によっては、成功体験の付き方として、途中で穴に落ちるところまで含めた成功ルートを学習してしまうかもしれない。その意味で、最短な成功経路を学ぶというのは逆に難しいかもしれない。(これは何のデータで検証できるだろうか？)

(自分用メモ)仮説をもっと考えたい。自分で作った仮説からでないと、学びは得られない。手を動かすだけでは得られるものは極端に少なくなる。

結果の分析

- 結果の評価軸
 - 初回成功までの“試行回数”として難しいのか
 - 初回成功までの“相互作用ステップ数”として難しいのか
 - 一度成功したあと再現できるか
 - 最終的な到達性能が落ちるのか

●

初回成功までの“試行回数”として難しいのか
初回成功までの“相互作用ステップ数”として難しいのか

エピソード数では復活あり版のほうがよく見えるが、総ステップ数では復活あり版のほうがむしろずっと長い

・初回成功までの平均エピソード数 ・初回成功までの平均ステップ数	det_sparse	det_dense	stoch_sparse	stoch_dense
holeless_control				
holes_respawn_t o_start				
original_holes_te rminal				

初回成

•

•

•

これだ
[tern

各エピソードの特徴

- 通常盤

- 穴に落ちたら速終了
- そのため失敗エピソードが短い
- だから初回成功までのエピソード数はとても多い。
- しかし総ステップ数は意外と少ない。

- 復活あり版

- 穴に落ちてもエピソードが終わらない。
- そのため1エピソードが長くなりやすい。
- 失敗しても延々と彷徨う。
- だからエピソード数では長く見えても総ステップ数は多い。

